


# 第四章 遥感图像分类

主讲教师：尹继豪

宇航学院

航天信息工程系





# 提 纲

一

遥感图像场景分类基础

二

传统场景分类方法

三

深度学习场景分类方法



# 一


## 遥感图像场景分类基础

- 场景分类定义
- 场景分类方法
- 常用数据集与评价指标

## (一) 场景分类定义

遥感图像场景分类是指通过分析一系列遥感图像的场景特征，以此实现对每一幅遥感图像**预测特定的场景类别标签**。


场景类别标签通常可以被定义为特定的场景主题，比如飞机场、公路、体育场等。




机场



公路



体育场



剧院



## (一) 场景分类定义

根据是否需要提供已知**类别标签**的训练样本，对分类器进行训练，可将遥感图像分类方法划分为**非监督分类**和**监督分类**。

- **非监督分类**——事先没有类别先验信息
- **监督分类**——事先已经知道类别的信息

本课程主要讲解有监督的遥感图像场景分类，**即已知部分遥感图像场景的类别属性，该部分数据又称为训练集。**

无监督和分割的区别：是否考虑空间邻接（无监督分类还是基于特征的）



## (二) 场景分类算法


有监督的场景分类基本过程是：首先根据已知样本的先验知识确定判别准则，**计算判别函数**，然后将未知类别的样本值代入判别函数，依据判别准则对该样本所属的类别进行判定。

这个过程中，**利用已知类别样本的特征与类别信息求解判别函数的过程称为学习或训练**。根据判别函数学习方式的不同，目前场景分类算法分为基于传统机器学习的方法和基于深度学习的方法。



## (三) 场景分类常用数据集

| 数据集         | 类别数 | 每种类别包含的图像数 | 总图像数  | 图像大小    |
|-------------|-----|------------|-------|---------|
| UC Merced   | 21  | 100        | 2100  | 256*256 |
| SIRI-WHU    | 12  | 200        | 2400  | 200*200 |
| WHU-RS19    | 19  | ~50        | 1005  | 600*600 |
| RSC11       | 11  | ~100       | 1232  | 512*512 |
| RSSCN7      | 7   | 400        | 2800  | 400*400 |
| AID         | 30  | 200~400    | 10000 | 600*600 |
| NWPU-RESISC | 45  | 700        | 31500 | 256*256 |







## (四) 分类精度评价指标

对遥感图像分类完成后，需要**客观的指标**对分类结果进行评价，确定分类的精度和可靠性，通常从精确度、时间复杂度和内存占用率几个方面进行评估。

以**混淆矩阵**为基础产生的各种分类精度指标（总精确度和Kappa系数），是客观评价遥感图像分类结果好坏的主要依据。

混淆矩阵是一个 $c \times c$ 大小的矩阵，矩阵的**每一列代表了预测类别**，每一列的总数表示预测为该类别的数据的数目；每一行**代表了真实归属类别**，每一行的数据总数表示该类别的真实数据的数目。





## 评价指标——混淆矩阵示例

实际的共45个类1样本中，有43个样本被正确分类，2个错分为类2，0个错分成类3；

实际的共51个类2样本中，有45个样本被正确分类，5个错分为了类1，1个错分为了类3；

实际的共54个类3样本中，有49个样本被正确分类，2个错分为了类1，3个错分为了类2。

|      |    | 分类类别 |    |    |    |
|------|----|------|----|----|----|
|      |    | 类1   | 类2 | 类3 | 行和 |
| 实际类别 | 类1 | 43   | 2  | 0  | 45 |
|      | 类2 | 5    | 45 | 1  | 51 |
|      | 类3 | 2    | 3  | 49 | 54 |
|      | 列和 | 50   | 50 | 50 |    |

共150个样本



由混淆矩阵可以定义以下几种常用的分类精度判别指标

- 总体精度(Overall Accuracy): 被**正确分类的像元总和除以总像元数**, 也即混淆矩阵的对角线元素之和除以矩阵元素总和

$$OA = \frac{\sum_{i=1}^c N_{ii}}{N}$$

- 召回率(Recall): 分类器**正确划分出的第*i*类样本与第*i*类样本总数的比例**, 也即混淆矩阵的第(*i*, *i*)个元素除以**第*i*行元素和**

$$R_i = \frac{N_{ii}}{\sum_{k=1}^c N_{ik}}$$



- 准确率 (precision): 分类器划分的第  $i$  类样本中划分正确的比例, 也即混淆矩阵的第  $(i, i)$  个元素除以第  $i$  列元素和

$$P_i = \frac{N_{ii}}{\sum_{k=1}^c N_{ki}}$$

由以上三类精度判别指标可评价所给例子分类结果的好坏。



## □ 评价指标——分类精度示例

### 总体精度

$$OA = (43+45+49)/150=91.3\%$$

### 类1的召回率 (对角线除以行和)

$$R_1 = 43/45=95.6\%$$

### 类1的准确率 (对角线除以列和)

$$P_1 = 43/50=86\%$$

|      |    | 分类类别 |    |    |    |
|------|----|------|----|----|----|
|      |    | 类1   | 类2 | 类3 | 行和 |
| 实际类别 | 类1 | 43   | 2  | 0  | 45 |
|      | 类2 | 5    | 45 | 1  | 51 |
|      | 类3 | 2    | 3  | 49 | 54 |
|      | 列和 | 50   | 50 | 50 |    |



## □ 评价指标—— Kappa系数

在前述的三个评价指标中，总体精度可以反映一张图像整体的分类好坏，它直接计算正确划分的比例，计算简单。但是实际的分类问题中，**各个类别的样本数量往往不均衡**。在这种不均衡数据集上直接计算总体精度，会导致精度由大类别决定。

因此，为了更客观评价总体分类精度，往往采用Kappa系数指标。



## □ 评价指标—— Kappa系数

Kappa系数是**用于一致性检验**的指标，也可以用于衡量分类效果的好坏，对于分类问题，所谓一致性就是模型预测结果和实际分类结果是否一致。Kappa系数的计算**可以由混淆矩阵计算得到**，基于混淆矩阵的Kappa系数计算公式如下

$$Kappa = \frac{p_o - p_e}{1 - p_e}, \quad p_o = \frac{\text{对角线元素之和}}{\text{整个矩阵元素之和}}, \quad p_e = \frac{\sum_i \text{第}i\text{行元素之和} \cdot \text{第}i\text{列元素之和}}{(\text{样本总数})^2}$$

可以看出， $p_o$ 即总体精度； $p_e$ 即所有类别分别对应的“实际与预测数量的乘积”之总和，除以“样本总数的平方”。越不平衡的混淆矩阵，比如某一对角线的值远大于其他， $p_e$ 就会越大，而Kappa值就越小，**惩罚了偏向性**。



## □ 评价指标—— Kappa系数

考虑下面两个混淆矩阵，样本总数与总体精度均相同，但第一个不平衡，第二个平衡

$$\textcircled{1} \begin{bmatrix} 8 & 1 \\ 1 & 2 \end{bmatrix}$$

$$\textcircled{2} \begin{bmatrix} 5 & 1 \\ 1 & 5 \end{bmatrix}$$

$$p_{e1} = (9 * 9 + 3 * 3) / (12 * 12) = 0.625 \quad Kappa_1 = 0.556$$

$$p_{e2} = (6 * 6 + 6 * 6) / (12 * 12) = 0.5 \quad Kappa_2 = 0.667$$

以Kappa系数为评价指标，第二个混淆矩阵代表的分类结果更好。





## □ 评价指标—— Kappa系数

Kappa系数的取值在-1到1之间，**越大的Kappa系数意味着分类精度越好**。使用Kappa系数判断分类精度的建议参考标准为

| Kappa系数   | 分类精度 |
|-----------|------|
| <0.00     | 很差   |
| 0.00~0.20 | 差    |
| 0.20~0.40 | 一般   |
| 0.40~0.60 | 好    |
| 0.60~0.80 | 很好   |
| 0.80~1.00 | 极好   |



## 二


# 传统场景分类方法

- 基于局部描述子的场景分类方法
- 基于全局统计特征的场景分类方法



## (一) 基于局部描述子的场景分类方法


基于局部描述子的场景分类流程如图所示，其包括场景**局部特征提取**、**特征降维**、**分类器决策**三个部分。





## □ 局部特征提取算法——LBP 特征

通过比较中心像素与邻近8个像素的大小，将其编码为一个0~255的十进制数来描述纹理，其计算速度快，且具有旋转不变性。




**原始LBP：从左上角开始编码，01111100→114**

**旋转不变LBP：8个方向中编码最小的值，即00011111→31**



## □ 局部特征提取算法——Gabor特征

Gabor特征是一种可以用来描述图像纹理信息的特征，Gabor滤波器的频率和方向与人类的视觉系统类似，适合于纹理表示与判别。Gabor特征通过在频率域上对信号进行加窗，从而描述信号的局部频率信息。




不同方向和频率的Gabor滤波器



## □ 局部特征提取算法——HOG特征

HOG(Histograms of Oriented Gradients)由Navneet Dalal和Bill Triggs于2005年提出，它是通过计算**局部区域的梯度直方图**来构成特征，并使用**局部重叠部分的对比度归一化**来提高精度。

其基本流程如下：





## □ 局部特征提取算法——HOG特征

- 1) 输入图像并灰度化
- 2) 采用Gamma校正法对输入图像进行颜色空间的归一化

在图像亮度不均匀时，利用Gamma校正改善图像的灰度和对比度，从而降低图像局部的阴影和光照变化所造成的影响，同时可以抑制噪声的干扰。



## □ 局部特征提取算法——HOG特征

- 3) 计算图像每个像素的梯度（包括大小和方向）

主要是为了**捕获轮廓信息，同时进一步弱化光照的干扰**。像素点 $(x, y)$ 的梯度幅值 $G$ 和梯度方向 $\theta$ 分别为：

$$G(x, y) = \sqrt{G_x(x, y)^2 + G_y(x, y)^2}$$

$$\theta(x, y) = \arctan \frac{G_y(x, y)}{G_x(x, y)}$$

其中 $G_x(x, y) = I(x + 1, y) - I(x - 1, y)$ ,

$G_y(x, y) = I(x, y + 1) - I(x, y - 1)$ 。






## □ 局部特征提取算法——HOG特征

### ➤ 4) 将图像划分成若干Cell块并计算其梯度直方图

以 $8 \times 8$ 个像素为一格，将整张图像划分为均匀间隔的单位网格，每个网格都是一个Cell块。与SIFT类似，把 $360^\circ$ 均分成9个方向，每个Cell块中对所有点的梯度值进行统计并加权投影到9个方向，最终得到梯度直方图，即Cell块的特征向量。




这里写的多少个特征向量就是说特征是多少维度的，和SIFT对应的的话，是36对应128



## □ 局部特征提取算法——HOG特征

### ➤ 5) Cell块组合成Block块，块内归一化梯度直方图

由于局部光照的变化，以及前景和背景对比度的变化，使得梯度强度的变化范围非常大，这就需要**对梯度强度做归一化**。把每四个相邻的Cell块组合成Block块，每两个Block块之间都会有一部分重叠。





## □ 局部特征提取算法——HOG特征

### ➤ 6) 生成HOG特征向量

对每个Block块将其中四个cell块的特征向量串联起来并归一化，便得到Block块的HOG特征向量。

对于 $64 \times 128$ 的图像而言，每 $8 \times 8$ 个像素组成一个Cell块，每个Cell块有9个特征向量；每 $2 \times 2$ 个Cell块组成一个Block块，所以每个Block块有 $4 \times 9 = 36$ 个特征向量。

水平方向有7个窗口，垂直方向有15个窗口，所以这张图像共有 $36 \times 7 \times 15 = 3780$ 个HOG特征向量。



## □ 局部特征提取算法——HOG特征

HOG特征的特点：


1. **边缘**结构特征→描述局部的**形状信息**
2. **位置**和**方向**空间的量化→抑制**平移**和**旋转**带来的影响
3. **局部区域归一化**直方图→部分抵消**光照变化**带来的影响
4. 一定程度**忽略光照的影响**→所表征数据的**维度降低**
5. **分块分单元**→表征图像**局部**像素点之间的关系




## □ 局部特征提取算法——HOG特征



原始图像灰度图



HOG特征图



灰度图与HOG特征



## □ 特征降维算法


经过特征提取后，遥感影像被表示为**高维的局部特征向量**。然而，由于维度过高，直接对其进行分类会存在信息冗余多和计算量大的问题，因此需要对特征进行降维。

特征降维是一种将**数据特征数量减少的技术**，同时尽可能保留**相关信息**，目前主流的方法包括主成分分析（PCA）、独立成分分析（ICA）等。



## □ 特征降维算法——主成分分析

主成分变换是一种使用最广泛的数据降维算法，**将原来变量重新组合成一组新的相互无关的几个综合变量**，从而根据实际需要取出几个较少的总和变量尽可能多地反映原来变量的信息的统计方法。





## □ 特征降维算法——独立成分分析

独立主成分分析是一种常用的特征降维算法，它通过寻找独立成分来实现数据降维。与线性降维方法PCA不同，ICA是基于独立性的非线性降维方法。

ICA的基本思想是将多元随机变量分解成互相独立的非高斯随机子分量的线性组合，迭代优化得到估计的独立成分 $s$ 和混合矩阵 $A$ ，通过最大化独立性的方法来求解独立成分。





## □ 分类器决策——支持向量机SVM

支持向量机 (Support Vector Machine, SVM) , 是一类按监督学习方式对数据进行**二元分类**的广义**线性分类器**, 其决策边界是训练样本求解出的**最大边距超平面**。

支持向量机作为机器学习中经典的分类模型, 广泛地应用于统计分类以及回归分析中。支持向量机分类算法, 也是遥感分类任务中常用监督分类算法。




## □ 分类器决策——支持向量机SVM

### ➤ 原始SVM

分类算法的目标是在样本空间中**寻找一个超平面**，将不同类别的样本分开。

能将两类样本分开的超平面实际上有无数个，但并非都是很好的分类超平面。SVM的思想即是**选择“正中间”的分类超平面**，其容忍性好、鲁棒性高、泛化能力最强。




线性可分的二分类情形



➤ SVM应用于遥感图像场景分类

□ 引入软间隔

实际应用中，能够**完全线性可分**的情况是很少的，相比于原始SVM希望将样本完全分开的苛刻条件，软间隔思想是**允许个别样本点出现在间隔带里面**，在约束条件中加入松弛余量 $\xi_i$ 。





## ➤ SVM应用于遥感图像分类

### □ 引入核方法

遥感分类任务中，地物特征的分布往往复杂，通过**线性决策面难以分类**。核方法改变样本的特征空间，**将低维空间线性不可分的样本映射到高维空间中**，让样本点在高维空间能够线性可分。





## ➤ SVM应用于遥感图像分类

核方法通过**非线性的映射函数** $\phi(x)$ 将样本 $x$ 的低维特征空间 $\mathcal{X}$ 映射到高维特征空间 $\mathcal{H}$

$$\phi(x): \mathcal{X} \rightarrow \mathcal{H}$$

而**核函数** $K(x_i, x_j)$ 为两两样本映射函数的**内积**

$$K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$$

常用的核函数包括:

### 1. 线性核 (Linear Kernel)

- 适用场景: 数据本身近似线性可分; 高维稀疏数据 (如文本分类)。
- 优点: 计算快、可解释性强、不易过拟合。
- 表达式:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$$

高斯核函数

$$K(x_i, x_j) = e^{-\frac{\|x_i - x_j\|^2}{2\sigma^2}}$$

多项式核函数

$$K(x_i, x_j) = (x_i^T x_j + c)^q$$



## □ 分类器决策——支持向量机SVM

➤ SVM应用于遥感图像分类

### □ 引入一对多法


大部分遥感分类任务是多元分类任务，原始SVM只能进行二元分类，需对其进行拓展以适用于多分类的情形，常用的方法是一对多法 (One-Versus-Rest, OVR)。

一对多法的思想是在训练时把某个类别的样本归为一类，其他剩余的样本归为另一类，依此类推，这样K个类别的样本就构造出了K个SVM。分类时将未知样本划分为计算出的分类函数值最大的那一类。



## (二) 基于全局统计特征的场景分类方法

基于全局统计特征的方法本质上是将**影像场景中低层视觉特征聚合并量化**，以其**统计分布信息表示图像的语义特征**，而较少关注具体地物或目标的构成，使其能够更好的泛化于不同场景。





## (二) 基于全局统计特征的场景分类方法

1. 通过特征提取和聚类，将聚类中心定义为“视觉词”，构建遥感影像的视觉词典，实现图像特征的降维。
2. 每幅影像按照视觉词典映射为一个“文档”。
3. 利用概率主题模型分析文档的词频，实现对遥感影像的场景分类。





## □ 特征聚类算法——K-Means算法

K-Means算法是最常用的聚类算法，主要思想是：在给定**K个初始类簇中心点**的情况下，把每个点划分到离其最近的类簇中心点所代表的类簇中，所有点分配完毕之后，根据一个类簇内的所有点**重新计算该类簇的中心点(取平均值)**，然后再迭代地进行分配点和更新类簇中心点的步骤，直至类簇中心点的变化很小，或者达到指定的迭代次数。



## □ 特征聚类算法——K-Means算法

### ➤ 算法原理——初始聚类中心

假定给定的遥感图像样本 $X$ ，包含 $n$ 个局部图像特征

$$X = \{X_1, X_2, X_3, \dots, X_n\}$$

其中：每个像素提取的特征为 $p$ 维。

首先初始化 $K$ 个聚类中心 $\{C_1, C_2, C_3, \dots, C_k\}$ ,  $1 < k \leq n$ ，然后计算每个特征到每个聚类中心的距离，这里我们采用欧式距离

$$dis(X_i, C_k) = \sqrt{\sum_{t=1}^p (X_{it} - C_{kt})^2}$$



## □ 特征聚类算法——K-Means算法

### ➤ 算法原理——最近邻分类

依次比较每一个对象到每一个聚类中心的距离，将对象分配到距离最近的聚类中心的类簇中，得到 $k$ 个类簇 $\{S_1, S_2, S_3, \dots, S_k\}$

接下来更新类簇中心，由类簇内的所有对象求均值得到

$$C_l = \frac{\sum_{X_i \in S_l} X_i}{|S_l|}$$

其中， $C_l$ 表示第 $l$ 个类簇中心， $|S_l|$ 表示第 $l$ 个类簇包含的像素个数， $X_i$ 表示类簇中的像素特征。



## □ 特征聚类算法——K-Means算法

### ➤ 算法原理——迭代更新

当更新的类簇中心与上一轮的类簇中心位置相比，变化非常小时，停止迭代，一般也会**预先设定最大的迭代轮数**。

最后得到聚类中心与聚类结果

聚类中心

$$\{C_1, C_2, C_3, \dots, C_k\}, 1 < k \leq n$$

聚类结果

$$\{S_1, S_2, S_3, \dots, S_k\}, 1 < k \leq n$$



## □ 概率主题模型——最大似然分类

基于全局统计特征的场景分类方法将上述流程得到的聚类中心视作一系列视觉词汇，之后采用视觉词袋模型Bag of Words(BoW)对其进行建模，将文本中出现的单词转换为词袋来表示文本。在BoW中，每个特征被视为一个单词，而每幅遥感影像被视为一个文档。

之后，采用概率主题模型（如最大似然估计）对其进行语义挖掘，判别其所属的场景主题类别。利用最大似然估计求解模型参数，在此基础上，对于任何一个场景图像，可推理出它属于各类的概率，取最大概率对应的类作为分类结果。



## □ 概率主题模型——最大似然分类

### ➤ 算法原理

将图像 $x$ 属于 $C_i$ 类的后验概率  $p(C_i|x)$  作为模型的判别函数

$$g_i(x) = p(C_i|x)$$

根据贝叶斯公式，有

$$g_i(x) = p(C_i|x) = p(x|C_i)p(C_i)/p(x)$$

其中 $p(x)$ 与类别无关，可认为是一常数，在混合高斯分布的假设下，由训练区的样本可先计算出先验概率 $p(C_i)$ 与 $C_i$ 类的概率分布函数 $p(x|C_i)$ 。  
依次比较 $g_i(x)(i = 1, 2, \dots)$ 的大小，将像素 $x$ 划分到后验概率最大的类。




### 三

## 深度学习场景分类方法

- 整体框架
- 经典自然图像深度学习分类模型
- 基于注意力机制的场景分类
- 基于自蒸馏的遥感场景细粒度分类



## (一) 整体框架







## (一) 整体框架

**数据集：**遥感数据集应包括各种数据源、传感器和地物类型，通常分为7:1:2的训练、验证和测试集。

**模型组网：**通常由卷积、激活、池化和全连接层组成，目的是从遥感图像提取深度特征并进行分类。

**学习优化：**数据通过网络模型进行非线性映射，计算损失后进行梯度反传迭代优化，每k次迭代用验证集评估模型，选择最优的参数在测试集上预测。





## (二) 经典自然图像深度学习分类模型——CNN

### ➤ 卷积运算

**局部特征提取：**模型在图像上滑动一个小的窗口或卷积核，有效地捕捉到图像的局部信息，如边缘、纹理和形状。

**参数更新学习：**在模型训练过程中，卷积核的参数不断地进行更新和优化，以更好地匹配与图像中的特定特征。






## (二) 经典自然图像深度学习分类模型——CNN

### ➤ 池化（下采样）

**降低数据维度：**池化操作通过减少卷积层输出的空间维度，有效地降低了数据的复杂性和计算需求。

**增强局部感受野：**通过池化操作，模型可以在更大的空间区域内捕获特征，从而增强其对局部结构和模式的感知。






## (二) 经典自然图像深度学习分类模型——CNN

### ➤ 全连接层（多层感知机）


全连接层在神经网络中将前一层的所有神经元与当前层的每个神经元连接，起到综合前面特征并输出最终预测或分类结果的作用。





## (二) 经典自然图像深度学习分类模型


**AlexNet:** 深度学习历史上的关键模型，由其深度结构和ReLU激活函数引领了卷积神经网络的新时代。





## (二) 经典自然图像深度学习分类模型


**GoogleNet**：引入了Inception模块，通过多尺度的卷积核并行处理，提高了网络性能而不增加计算复杂度。





## (二) 经典自然图像深度学习分类模型

**ResNet**：通过使用“残差连接”解决了深度网络的梯度消失问题，使得构建几百甚至上千层的网络成为可能。








## (二) 经典自然图像深度学习分类模型

**DenseNet**：网络采用密集连接模式，每一层都与前面的所有层有直接连接，促进了特征的传播与重用。








### (三) 基于注意力机制的场景分类

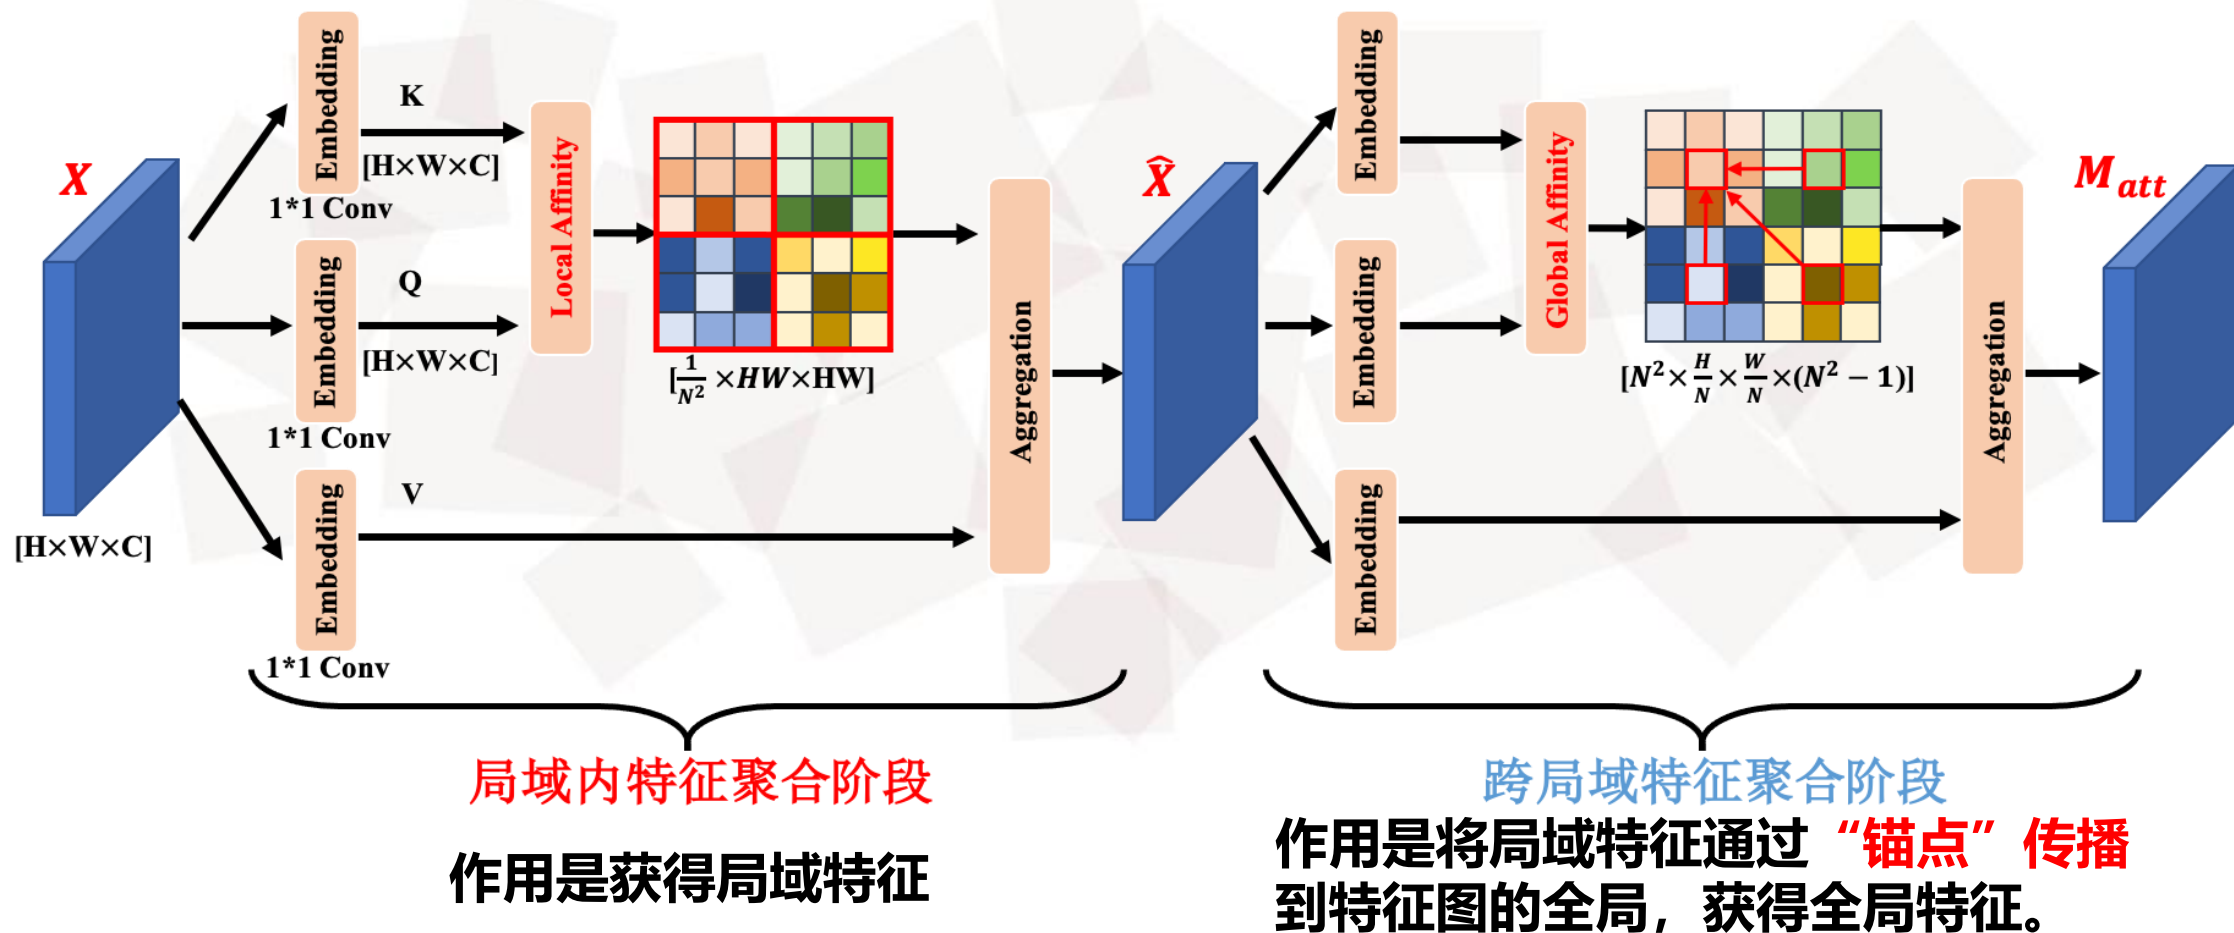
遥感图像由于其宽幅场景、复杂背景和多噪点特点，主要的分类特征往往仅占小部分，而大部分背景可能带有噪声或对分类不起作用。

注意力机制模仿人类视觉，通过快速扫描图像来确定关注焦点，并将更多资源投入这一区域以获取细节，同时抑制不相关信息。在深度学习中，这种机制帮助模型从大量信息中选择关键数据，并加强其特征提取能力。





### (三) 基于注意力机制的场景分类——两阶段局部注意力机制结构





#### (四) 基于自蒸馏的遥感场景细粒度分类

在遥感场景分类中，不同类别间具有高度的相似性，但传统的one-hot编码方法忽略了图像类别间的关联。为更精确地分类，除了类别信息，还需为模型提供与输入图片内容相关的类间关联信息。



居民区



商业区



工业区




家庭公园



#### (四) 基于自蒸馏的遥感场景细粒度分类

利用神经网络多层次输出的预测向量来探索类别之间的相关性。通过将全连接层输出的预测向量进行softmax处理得到置信概率向量，为主网络提供类间的关联信息。





1. 基于SVM进行遥感场景分类的原理及步骤？
2. 基于全局统计特征的场景分类方法的原理及步骤？
3. 依据混淆矩阵，解算地物分类的总精度OA、Kappa系数，每类的准确率P、召回率R等指标。





**谢 谢**

