


第五章 遥感图像分割

主讲教师：尹继豪

宇航学院

航天信息工程系





提 纲

一

遥感图像分割概述

二

传统遥感图像分割算法

三

深度学习遥感图像分割算法



一

遥感图像分割概述


- 遥感图像分割定义
- 遥感图像分割算法
- 常用数据集及评价标准




(一) 遥感图像分割定义

遥感图像包含的目标多种多样，有诸如农作物、建筑物等地物目标，也有云层、无人机等空中目标。一般来说，对遥感图像进行分割，可能**只对其中的某些部分感兴趣**。例如在城市规划中，只对房屋等目标比较关心。

这些目标在图像中具有独特的性质，**需要将其分离出来**，并提取其特有的特征，最后进行识别、分类等进一步的处理。



(a) 原图



(b) 分割图



(一) 遥感图像分割定义

图像分割技术是按照图像内部特征，**将图像划分为不同类型的区域**，要求区域间的**分割边缘必须精确划定**，且被分割物体的内部特征具有一致性或相似性，每个区域属于同一类，不同区域则归属于不同的类。

图像分割技术应用于光学遥感领域时，旨在根据实际**语义信息**，将遥感图像划分为一系列具有道路、农田、村庄、工业区等地物类别标签的区域。



(二) 遥感图像分割算法

遥感图像分割算法种类繁多，不同发展阶段下具体任务也存在差异，分类依据一直比较模糊。

早期图像分割算法根据像素、边缘、区域三类方法即可进行划分。为了涵盖更丰富的图像分割方法，更多的划分方式被提出。例如从驱动模式出发，分为图像驱动、模型驱动和同质性特征度量三个类别；基于人类视觉系统感知和视觉信息逐层稀疏化加工的特性，从加工的图像特征的角度进行划分。

为了整合不同时期流行的方法，图像分割算法可以划分为以下三类：

- 传统图像分割算法
- 传统语义分割算法
- 基于深度学习的图像分割算法



(二) 遥感图像分割算法

其中，传统语义分割大多基于无监督或有监督的经典机器学习算法来完成。无监督方法包括K-means和ISODATA等聚类算法，有监督方法则直接利用图像低级的像素信息，或构建局部描述子后，通过构建SVM、纹理基元森林、随机森林等分类器，对图像完成像素级的分类。

然而，深度学习的兴起使语义分割算法的性能和速度都得到了大幅提高。时至今日，图像分割往往被用来指代语义分割。研究人员普遍利用深度学习方法来完成语义分割，传统语义分割也逐渐淡出。

因此本章将侧重于介绍传统图像分割算法与基于深度学习的图像分割算法两部分内容。



(三) 常用数据集与评价指标—ISPRS数据集

ISPRS提供了两个机载图像数据集Vaihingen和Postdam, **包括超高分辨率的正射影片(TOP)和相应的数字地表模型(DSMs)**。这两个数据集都覆盖了城市场景区域, 其中Vaihingen是一个相对较小的村庄, 有许多独立的建筑和少量的多层建筑; Postdam是一个典型的历史城市, 有着大的建筑群、狭窄的街道和密集的居民区域。



(a) TOP

(b) DSM

(c) 真实标签图

ISPRS Vaihingen 数据集



(a) TOP

(b) DSM

(c) 真实标签图

ISPRS Postdam 数据集



(三) 常用数据集与评价指标—GID数据集

自2014年启动以来，高分二号（GF-2）卫星已被用于土地调查、环境监测、作物估算、建设规划等重要应用。GID是一个基于GF-2影像的大规模土地覆盖数据集，它包含我国60多个不同城市的150幅高质量GF-2影像，这些影像覆盖的地理区域超过了5万平方千米。


GID由两个部分组成：一个是**大规模的土地覆盖物分类集**，另一个是**精细的土地覆盖物分类集**。




(四) 常用数据集与评价指标—GID数据集

大规模分类集包含150幅像素级标注的GF-2图像，包含5个类别，图像尺寸为6800 × 7200；

精细分类集由3万个多尺度图像小块和10幅像素级标注的GF-2图像组成，均包含15个类别，小块尺寸为56~224。



GID大规模分类集



GID精细分类集



(四) 常用数据集与评价指标一定性标准

- 图像分割后的区域对于某些特征(如灰度、纹理等)应该一致, 区域**内部特征单一而没有空洞**;
- 不同区域间的特征应该**明显不同**;
- 每个分割区域的边缘应该**平滑、无毛刺而且精确**。



(四) 常用数据集与评价指标—定量标准

- Pixel Accuracy(PA, 像素精度)
- Mean Pixel Accuracy (MPA, 平均像素精度)
- Mean Intersection over Union (MIoU, 平均交并比)
- Frequency Weighted Intersection over Union (FWIoU, 频权交并比)



(四) 常用数据集与评价指标—定量标准

除了蒙对的


➤ Mean Intersection over Union (MIoU, 平均交并比)

$$MIOU = \frac{1}{k+1} \sum_{i=0}^k \frac{TP}{FN + FP + TP}, k \text{ 为类别数}$$

TP: 预测正确, 预测是正类 (真实是正类)

FN: 预测错误, 预测是负类 (真实是正类)

FP: 预测错误, 预测是正类 (真实是负类)





二

传统遥感图像分割算法

- 基于像素的图像分割
- 基于边缘的图像分割
- 基于区域的图像分割
- 基于统计的图像分割



(一) 基于像素的图像分割

基于像素的**阈值分割法**主要考虑图像的灰度特征，利用**不同阈值实现图像的分割**，特别适用于**目标与背景对比度强**的自然图像。

阈值分割法假设目标内部相邻像素的灰度值相似，但目标与背景的灰度值总体上有差异。因此图像的灰度直方图**呈现双峰**的特点，将阈值选在**谷底**，即可将两峰分开。

使用阈值进行图像分割时，灰度值落在指定阈值范围内的像素被判属于目标，其他被排除在目标之外。



(一) 基于像素的图像分割

下图是阈值分割法的一个实例，图(a)，(b)分别是原始图像和分割结果，图(c)是原始图像的直方图。


如果要将地面从水体背景中分离出来，观察图像和直方图可以看出，代表水源的高亮度峰约为25，其右侧具有一个代表陆地的**弱峰**，约为60，可以设置**阈值T为50**，逐点处理即可得到分割结果。



(a) 原始图像



(b) 分割结果



(c) 灰度直方图



(一) 基于像素的图像分割

人工经验选择的方法虽然能用，但是不能实现自动的阈值选取，效率较低，对于具有大量不同样本的分割任务并不适用。

对于需要自动确定阈值的任务，可以选择**最大类间方差法**，也称为**大津阈值法(OTSU)**。该方法选择的阈值将图像分为前景和背景两部分，使前景和背景的**类间方差尽可能大**，**类内方差尽可能小**，这使得构成图像的两部分之间的差别最大，错分概率最小。



(一) 基于像素的图像分割—最大类间方差法 (OTSU)

假设图像存在阈值 T 将全部像素分为两类 C_1 和 C_2 ，这两类像素各自的灰度均值记为 m_1 和 m_2 ，占全部图像的比例记为 p_1 和 p_2 ，整幅图像的灰度均值记为 m_G ，类间方差记为 g 。

根据以上定义有：

$$p_1 + p_2 = 1 \quad (1)$$

$$p_1 * m_1 + p_2 * m_2 = m_G \quad (2)$$

$$g = p_1(m_1 - m_G)^2 + p_2(m_2 - m_G)^2 \quad (3)$$



(一) 基于像素的图像分割——最大类间方差法 (OTSU)

将式(1)(2)代入式(3)可得:

$$\begin{aligned} g &= p_1 p_2 (m_1 - m_2)^2 \\ &= p_1 p_2 [m_1 - (m_G - p_1 * m_1) / p_2]^2 \quad (4) \\ &= \frac{p_1}{1 - p_1} (m_1 - m_G)^2 \end{aligned}$$

对灰度级进行遍历，根据式(4)计算使类间方差g最大的阈值T。



(一) 基于像素的图像分割

基于图像像素的阈值分割法原理简单并且无需先验知识，计算成本低且耗时少，利用OTSU等算法可以实现自动选取阈值。但是这类方法**仅将图像灰度级作为依据**，未利用到图像中的空间信息，因此在处理具有复杂地物特征的遥感图像时**抗噪性能差**，分割效果不理想。

因此，**遥感图像的阈值分割方法**，往往会在OTSU算法的基础上进行**改进^[1]**，针对遥感图像灰度级多、信息量大、边界模糊、结构和纹理复杂等特征，基于新的阈值判断准则对遥感图像进行**多阈值分割**，实现一次对多类目标同时分割。

[1] 陈明,王行风.基于模拟退火改进的多阈值遥感图像分割[J].信息系统工程,2011(08):73-75.



(一) 基于像素的图像分割—改进的OTSU算法

将OTSU算法中的阈值变为**阈值向量**，记为：

$$T \triangleq [T_0, T_1, \dots, T_{c-1}], \quad c > 0$$

向量T将全部像素分为C+1类，各类像素的灰度均值记为 $m_0, m_1, \dots, m_c$ ，占全部图像的比例记为 $p_0, p_1, \dots, p_c$ ，整幅图像的灰度均值记为 m_G ，类间方差记为 g 。



(一) 基于像素的图像分割—改进的OTSU算法

同理可以计算类间方差为：


$$g = \sum_{k=0}^c p_k (m_k - m_G)^2, \quad c \text{ 是类别数}$$

一般来说，可以使用遍历的方法选取最佳阈值向量，然而随着阈值个数的增加，遍历寻找最佳阈值向量的时间复杂度将大幅提高，此时可以使用模拟退火等算法快速寻找最优解。



(一) 基于像素的图像分割—改进的OTSU算法

相比单独进行阈值分割的方法，多阈值分割可以较好分割建筑物、水系、农田等目标，分割更精确。它可以识别和捕捉图像中的多个特征或目标。这在需要进行详细分析的遥感图像应用场景中非常有益。



原始图像



多阈值分割



(二) 基于边缘的图像分割

通常情况下，基于边缘的分割方法指的是基于灰度值的边缘检测，又被称为**梯度分割法**，即利用图像边缘的特点进行图像分割。

图像边缘指图像中相邻区块之间**像素特征发生突变**的地带，这个区域的像素灰度值不连续、梯度大，因此图像边缘对于图像来说是较重要的信息。

梯度分割法主要包括以下两个步骤：

- **边缘检测**
- **边缘连接**



(二) 基于边缘的图像分割—边缘检测

边缘检测指采取不同策略搜索图像中的边缘点，获取图像中的边界信息。主要包括**微分算子边缘检测法**、边缘跟踪法、霍夫变换法、曲线拟合法等方法。其中，微分算子边缘检测法的应用最为广泛，适用于各类图像的边缘检测。


微分算子依据其计算方式可以分为**一阶微分算子**和**二阶微分算子**。



(二) 基于边缘的图像分割—边缘检测

一阶微分算子依据图像在边缘处一阶导数最大的特性，对图像每个像素点做卷积运算，然后选取合适的阈值提取图像的边缘。常见的一阶微分算子有Sobel算子、Robert算子和Prewitt算子。

二阶微分算子通过寻找二阶导数的零点确定边缘点的位置。常见的二阶微分算子为Laplacian算子。





(二) 基于边缘的图像分割—边缘检测

在实际的图像分割任务中，常使用更加精确的边缘检测算子 **Canny算子**。Canny算子检测出的边缘具有**低错误率、高精确度**和**单一点响应（边缘唯一）**的特点。

Canny算子边缘检测包括以下四个步骤：

1. 滤波降噪处理
2. 差分计算幅值和方向
3. 非极大值抑制
4. 滞后阈值



(二) 基于边缘的图像分割—Canny算子边缘检测

1. 滤波降噪处理

理想的图像信息是无噪声的，但是现实中由于采集设备、环境干扰等多方面的原因，导致采集到的图像信息含有大量噪声信息，其中最常见的是**椒盐噪声**和**高斯噪声**。


Canny算子是一种在**抗噪声干扰**和**精确定位**之间寻求最佳折中方案的边缘检测方法。一般在检测前，使用**高斯滤波**去除噪声，下面是常见的3X3的卷积模板：



(二) 基于边缘的图像分割—Canny算子边缘检测

1. 滤波降噪处理

$$K = \begin{bmatrix} 1/16 & 2/16 & 1/16 \\ 2/16 & 4/16 & 2/16 \\ 1/16 & 2/16 & 1/16 \end{bmatrix}$$



高斯滤波可以将图像中的噪声部分过滤出来，避免后面进行边缘检测时将错误的噪声信息误识别为边缘。

滤波核的维数不应过大，否则可能会平滑掉边缘信息，使边缘检测算子无法正确检测到真实边缘。



(二) 基于边缘的图像分割—Canny算子边缘检测

2. 差分计算幅值和方向

使用一阶微分算子可以得到图像在x和y方向上偏导数的两个矩阵，Canny算子中选择了**Sobel算子**进行计算，例：

$$I = \begin{bmatrix} a0 & a1 & a2 \\ a3 & c & a5 \\ a6 & a7 & a8 \end{bmatrix}, \quad S_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}, \quad S_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix}$$

$$G_x = 2 * a5 + a2 + a8 - (2 * a3 + a0 + a6)$$

$$G_y = 2 * a7 + a6 + a8 - (2 * a1 + a0 + a2)$$

C处的梯度幅值和方向即为：

$$G_c = \sqrt{G_x^2 + G_y^2}$$

$$\theta_c = \arctan(G_y / G_x)$$



(二) 基于边缘的图像分割—Canny算子边缘检测

3. 非极大值抑制

基于梯度值提取的边缘仍然较模糊，可能会有重边的现象，因此Canny算子利用了**非极大值抑制的技术进行边缘稀疏**，可以使边缘具有单一点响应的性质。

单一点响应：对每一个真实的边缘点，**检测子应只返回一个点**，即避免右图中产生的重边现象，仅得到绿色的真实边缘。



重边现象




(二) 基于边缘的图像分割—Canny算子边缘检测

3. 非极大值抑制

对梯度图像中的每个像素进行非极大值抑制的过程为：**对比当前像素与正负梯度方向上的两个相邻像素的梯度强度**，如果当前像素的梯度强度最大，则将该像素点保留为边缘点，否则该像素点被抑制，即置0。

右图点 P 表示当前像素， P_1 ， P_2 表示正负梯度方向上的两个像素。计算梯度方向上两个相邻像素的梯度强度时，通常使用**线性插值法**。





(二) 基于边缘的图像分割—Canny算子边缘检测

4. 滞后阈值

非极大值抑制得到的结果是一个二值图像，非边缘点的灰度值为0，边缘点的灰度值为255。该结果中去除了重边，但是仍然可能会有噪声等原因产生的**伪边缘**，因此需要使用**滞后阈值法（双阈值）**进行处理。


滞后阈值法通过设置两个阈值 T_{min} 和 T_{max} 对边缘像素进行筛选，梯度**大于 T_{max}** 的像素点作为“**确定边缘**”被保留；梯度**小于 T_{min}** 的像素点被认为一定不属于边缘，被丢弃。



(二) 基于边缘的图像分割—Canny算子边缘检测

4. 滞后阈值

对于梯度大小介于 T_{min} 和 T_{max} 之间的像素点，如果他们是**连接到“确定边缘”上的像素**，则被视为边缘，否则被丢弃。



A为“确定边缘”。C介于 T_{min} 和 T_{max} 之间且**与A相连**，也被视为边缘；B介于 T_{min} 和 T_{max} 之间但没有连接到任何“确定边缘”，被丢弃。



(二) 基于边缘的图像分割—改进的边缘检测

经典Canny算子虽然在简单轮廓的边缘检测上有良好的表现，但是由于遥感图像过于复杂，真实的地物边缘可能表现为弱边缘，**高斯滤波很难平衡去噪与保留边缘的需求**。下面介绍一种**基于小波变换的自适应去噪方法**^[2]，既可以解决噪声减弱和边缘信息保护的矛盾，也可以避开传统小波变换阈值选取的难点。

该方法主要步骤如下：

1. 对原始图像进行小波分解
2. 计算高频成分的统计特征
3. 修正小波系数
4. 小波重构

[2] 余龙昆. 应用启发式边缘生长的遥感影像分割[J].应用科学学报,2012,30(02):173-180.



(二) 基于边缘的图像分割—改进的边缘检测

1. 对原始图像进行小波分解

利用小波变换的算法对原始图像进行小波分解，
获得**1个低频成分和3个高频成分**。

LL ₁	HL ₁
LH ₁	HH ₁

2. 计算高频成分的统计特征

根据下式计算其**均值m**和**标准差σ**，其中， f_i 是原始小波分解系数，
包括 LL_1 、 HL_1 、 LH_1 、 HH_1 四个成分的系数。

$$m = \sum_{i=1}^n f_i$$
$$\sigma = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (f_i - m)^2}$$



(二) 基于边缘的图像分割—改进的边缘检测

3. 修正小波系数

由于图像信号的小波系数与图像噪声的小波系数相比具有更大的能量幅值，因此可以在小波频域对小波系数进行修正，**突出幅值大的属于信号的小波系数，抑制幅值小的属于噪声的小波系数**。小波系数的修正主要通过步骤2得到的高频成分均值 m 和标准差 σ 自适应地进行计算，具体修正公式为：

$$f'_i = \frac{f_i}{(1 + (\sqrt{2} - 1)(\frac{\sigma}{f_i - m})^2)}$$




(二) 基于边缘的图像分割—改进的边缘检测

4. 小波重构

使用小波重构算法，根据修正后的小波系数重构影像。重构后的图像**噪声能量将得到极大削弱**，基于重构图像进行边缘检测时，**伪边缘也相应的减少**，同时保留了较多的图像边缘信息。



原图像



边缘检测结果图



(二) 基于边缘的图像分割—边缘连接

由于边缘检测过程仅利用了局部信息，检测出的边缘是断裂的、不连续的，不能保证**区域的封闭性**，因此需要通过**边缘连接或轮廓生成算法**来封闭区域。

高分辨率遥感图像提取出的边缘繁多且相互关系复杂，在判断连接关系时需要更严格的约束条件，因此往往需要同时考虑**空间**和**光谱**特点，使**连接异质性**最小。

(二) 基于边缘的图像分割


遥感图像中边缘检测的干扰因素较多，从实验结果看出，使用**自适应小波去噪的Canny边缘检测**方法，能够充分利用遥感图像信息进行边缘连接，可以获得理想的分割效果。



(a)原始图像



(b)边缘检测



(c)边缘连接



(d)区域标识

基于边缘的方法进行遥感图像分割



(三) 基于区域的图像分割

区域分割法指基于**像素相似性**进行图像分割的方法。它利用图像局部的空间信息，基于像素间的**连通性**和**邻接性**将子区域聚合成一个更大的区域，能有效地克服边缘检测技术对于不连续区域的分割缺陷。简单来说，区域分割法就是**从物体内部开始向外扩展至物体的边界**。

区域分割法认为同一区域内的相邻像素具有相似的值，它一般包括**区域生长法**和**区域分裂-合并法**。



(三) 基于区域的图像分割—区域生长法

区域生长法从**给定的初始值**（种子）开始，采用不同的策略连接相似的相邻像素。其基本思想是将图像中满足某种**相似性准则**的像素集合起来构成区域。

区域生长算法一般分为三个步骤：**确定生长种子点**，选定感兴趣目标区域内的种子像素；**确定生长准则**，将种子像素周围符合生长准则的像素合并到种子像素的所在区域，并作为新的种子像素向外生长；**确定生长停止条件**，没有像素可以合并时就停止生长，获得分割区域。



(三) 基于区域的图像分割—区域生长法

区域生长方法的两个关键问题：

1. 选择一组能正确代表区域的种子点

种子点的选取常借助先验知识，在缺乏先验知识的情况下，则可先借助生长准则对每个像素进行聚类计算。如果计算结果呈现聚集的情况，则接近聚集中心的像素可选为种子点。

2. 确定生长过程中能将相邻像素包括进来的规则

生长准则的选取不仅依赖于具体问题，还与所处理图像有关。需考虑像素间的连通性和邻近性，否则有时会出现无意义的分割结果。

种子点和生长准则的选取不当将导致图像出现过分割或欠分割现象。



(三) 基于区域的图像分割—区域生长法

区域生长法的典型代表是利用数学形态学的**分水岭变换算法**。

分水岭 (Watershed) 算法是基于**地理形态分析**的图像分割算法，模仿地理结构（比如山川、沟壑，盆地）来实现对不同物体的分类。


传统分水岭算法**将图像视作地貌**，且每点的**海拔高度**都是利用对应的图像像素点**灰度值**表示的。其中，每个局部极小值和它延展到的区域统称为**集水盆地**，这些盆地的边界即为**分水岭**。



(三) 基于区域的图像分割—区域生长法

用于二值化的**灰度阈值**可以理解为集水盆地中的**水平面**，比水平面低的区域会被淹没。

刚开始用水填充每个孤立的山谷，当水平面上升到一定高度时，水就会**溢出当前山谷**。为了防止水的汇集，需要在不同山谷间**修建大坝**。这些大坝形成的线就对整个图像进行了**分区**，实现了对图像的分割。





(三) 基于区域的图像分割—区域生长法

分水岭算法流程：

1. **寻找起始注水点**，即**梯度图像中的局部极小值点**。可以通过遍历像素灰度值是否小于4邻域(8邻域)内的全部像素进行判断。
2. **标记初始集水盆地边界**，即所有局部极小值点的4邻域(8邻域)。初始集水盆地边界存在重合则可**将重合点直接设置为边缘**。
3. **增加水平面**，即增加灰度阈值。如果当前存在积水盆地边界灰度值在水平面以下，则边界被淹没，该点的邻域成为新的边界，**出现重合边界则设置大坝，确定边缘**。
4. **直到水平面达到灰度最大值**，停止算法，大坝则对整个图像像素进行了分区。



(三) 基于区域的图像分割—区域生长法

分水岭算法**计算快**，边缘检测**精度高**。

但是由于图像中噪声点或其他因素的干扰，存在大量很小的局部极值点，分水岭算法常出现**过分割**现象。因此可以借助先验知识，使用标记图像等方法，指导分水岭算法的分割。



分水岭算法过分割现象



(三) 基于区域的图像分割—区域分裂-合并法

区域分裂合并法从**整幅图像**开始，将大区域分裂为小区域，符合条件的小区域再合并为大区域。

其基本思想是先确定一个**分裂合并的准则**，即**区域特征一致性的测度**。当图像中某个区域的特征不一致时就将该区域**分裂成4个相等的子区域**，当相邻的子区域满足一致性特征时则将它们合成一个大区域，直至所有区域不再满足分裂-合并的条件为止。

R_{11}	R_{12}	R_2
R_{13}	R_{14}	
R_3		R_4



(三) 基于区域的图像分割—区域分裂-合并法

区域分裂-合并算法既可以**先分裂再合并**，也可以**分裂、合并运算同时进行**，经过连续的分裂和合并，得到图像的精确分割效果。

在一定程度上，区域分裂-合并法和区域生长法很接近，当区域分裂到**单一像素点**后，根据某种特征一致性准则进行区域合并的过程就可以认为是**单一像素点的区域生长方法**。区别在于区域分裂-合并法**不需要预先指定种子点**，区域生长法则**无需分裂过程**。



(三) 基于区域的图像分割—区域分裂-合并法

区域分裂-合并算法的具体算法步骤为：

1. 对任意区域 R_i ，如果 $P(R_i) = FALSE$ ，则分裂区域为4个相连的无重叠区域，其中 P 表示分裂-合并准则；
2. 对相邻的两个区域 R_i 和 R_j ，如果 $P(R_i \cup R_j) = TRUE$ ，则合并两个区域，其中 R_i 和 R_j 可以尺寸不同；
3. 当再也没有可以进行合并或分裂的区域时，分割结束。




(三) 基于区域的图像分割—区域分裂-合并法


对于图像(a)中的目标，确定分裂合并准则：

$$P(R) = \begin{cases} TRUE & R \text{中全部像素灰度值相同} \\ FALSE & otherwise \end{cases}$$


则区域分裂-合并法的分割过程为(b)-(e)。




(a)原图像




(b)分裂过程1



(c)分裂过程2



(d)分裂-合并过程3




(e)分割结果




(三) 基于区域的图像分割

区域生长法和区域分裂-合并法能够结合遥感图像的**光谱和形状特征**，在遥感图像分割任务上有较多的研究成果。

总的来说，区域分割法的**抗噪性强**，且能够得到**紧凑形状**的分割区域，对于**多波段的遥感图像**来说，技术可扩展性优于阈值法和梯度分割法。



(a)原图像



(b)区域生长法分割结果



(四) 基于统计的图像分割

基于统计的分割通过引入数学理论或图论，对图像像素的邻域关系进行建模，**基于最大后验概率等估计准则设计分割的目标函数**，并进一步求解全局最优的分割决策。**马尔科夫随机场和条件随机场等都是常用于建模的方法。**

将图像的像素点分布视为一个典型的马尔可夫随机场，在此基础上完成对每个像素点打标签。可以有效地表达遥感图像的空间信息，整合图像的光谱特征，有效提高复杂图像区域的分割效果。



三

深度学习遥感图像分割算法

- 经典深度学习分割算法
- 基于目标空间通道信息的遥感图像分割
- 基于场景上下文信息的遥感图像分割




基于深度学习的遥感图像分割大部分指语义分割，很少进行实例级或全景的分割。由于深度神经网络能提取到深层特征，在图像分类、目标检测上都取得了重大突破，因此也逐渐被迁移到遥感图像分割中，并依据遥感图像的多光谱、高地物复杂度等区别于自然图像的特点进行改进。至今已有大量基于深度学习的遥感图像分割算法，精度远超常规的分割方法。

一般来说，基于深度学习的遥感图像分割整体框架主要包括以下四步基本的流程。



基于深度学习的遥感图像分割整体框架：

1. 数据**裁切与预处理**；
2. backbone**下采样编码**，提取特征；
3. 分割head**上采样解码**，恢复分割图；
4. 训练过程**计算loss反向传播**直至收敛，推理过程预测得到分割图。






(一) 经典深度学习分割算法—FCN网络

为了更好的利用深度学习完成图像分割任务，Jonathan Long等人^[3]在2015年首次将卷积神经网络最后的全连接层替换为卷积层，形成了全新的神经网络——全卷积网络(Fully Convolutional Networks, FCN)。

全卷积神经网络将用于分类映射的全连接层替换成卷积层，通过反卷积操作对获得的特征图进行上采样到原始输入图像大小，同时结合中间池化层信息生成图像预测分割图。




图中数字表示不同特征图，即通道数

[3] Long J, Shelhamer E, Darrell T. Fully convolutional networks for semantic segmentation, Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 3431-3440.



(一) 经典深度学习分割算法—FCN网络


在利用全卷积神经网络进行遥感图像分割时，也可以根据遥感图像的特征进行改进，例如**增加海拔信息**、**融合光谱识别指数**等，提高分割精度。



(a)原图像



(b)FCN




(c)改进FCN



(一) 经典深度学习分割算法—U-net网络

U-Net起源于医疗图像分割^[4]，参数少、计算快且适用于多类场景，最早于2015年提出。它的结构是标准的**编码器-解码器结构**，典型特点是U型对称，左侧可视为一个编码器，右侧可视为一个解码器。

编码器整体表现为逐渐缩小空间尺度，**以获取更多的上下文信息**。解码器与编码器对称，空间尺度逐渐扩张，**增加分割对象的细节，从而实现精准的定位**。该网络使用跳跃连接，融合细节和整体特征，同时强调位置与类别信息。




[4] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C] //International Conference on Medical image computing and computer-assisted intervention. Springer, Cham, 2015: 234-241.



(一) 经典深度学习分割算法—DeepLab系列网络

以上模型中的两个关键步骤为：**池化减小图像尺寸增大感受野**和**上采样扩大图像尺寸**，但尺寸先减小再增大的过程中会损失信息，因此希望找到一种操作，即使**不池化也能获得更大的感受野**。

DeepLab^[5]是Google提出的一系列模型，它采用了**空洞卷积代替池化层**来处理上述问题，获取到了更多的上下文信息。其中，空洞卷积是通过在标准卷积中注入空洞来扩大感受野，可以在不损失信息的同时关注到远距离信息。



空洞卷积


[5] Liang-Chieh Chen, G. Papandreou, I. Kokkinos, K. Murphy, and A. Yuille. Semantic image segmentation with deep convolutional nets and fully connected CRFs, ICLR, 2015.



(一) 经典深度学习分割算法—HRNet

上述分割网络通过下采样得到强语义信息，再上采样恢复高分辨率位置信息，这种做法会导致**大量的有效信息在不断的上下采样过程中丢失**。

HRNet^[6]将不同分辨率特征图的**串联结构改为并联结构**，使不同分辨率的特征图交流信息的途径更短。并行多个分辨率的分支，不断进行不同分支之间的信息交互，可以兼顾强语义信息和精准位置信息的目的。



HRNet网络结构

[6] Wang J, Sun K, Cheng T, et al. Deep high-resolution representation learning for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2020, 43(10): 3349-3364.



(二) 基于目标空间通道信息的遥感图像分割

对于经典的深度学习分割算法来说，遥感图像在特征提取阶段往往忽略了全局的上下文信息。同时，经典深度学习分割算法不够适应于其高分辨率的特点，计算复杂度相对较高。


2020年，SCAttNet^[7]参考经典深度学习方法中较热门的注意力机制，设计了轻量级的空间注意力和通道注意力网络，更加关注于特征图中有意义的语义信息。

[7] Li H, Qiu K, Chen L, et al. SCAttNet: Semantic segmentation network with spatial and channel attention mechanism for high-resolution remote sensing images[J]. IEEE Geoscience and Remote Sensing Letters, 2020, 18(5): 905-909.



(二) 基于目标空间通道信息的遥感图像分割

SCAttNet的完整流程包括：首先利用不同的骨干网络（ResNet等）对输入图像提取特征，再依次将特征图输入到**通道注意力模块**和**空间注意力模块**进行**通道维度和空间维度的特征增强**，对输出的特征进行卷积和Softmax，最终得到语义分割结果。



SCAttNet网络结构



(二) 基于目标空间通道信息的遥感图像分割

对于一幅高分辨率遥感图像，它获得的特征图在不同通道所表达的信息也不同，因此SCAttNet提出了通道注意力模块，得到通道注意力图，用于表示遥感地物的不同信息。


空间注意力则关注空间中当前任务感兴趣的区域。在高分辨率遥感影像中，地物的表现形式多样，分布复杂。因此，利用空间注意力有助于聚集空间信息，关注全局的同类地物，**因此更利于获取分散的小型地物特征。**



(二) 基于目标空间通道信息的遥感图像分割

在加入注意力模块后，SCAttNet网络可以更好地聚焦于目标，同时抑制了其他类别的影响。例如右图中其只在汽车类中有较强的响应，而其他区域的注意力权重很低。而在原有的SegNet分割网络中，其他大部分背景区域也表现出了一定的响应值，这可能会对汽车类的判别产生干扰。

借助于注意力模块对网络的特征表达的增强，能够实现对目标地物更明确关注的效果。




网络特征热力图可视化



(三) 基于场景上下文信息的遥感图像分割

2021年，HRCNet^[8]在将空间和通道信息融合至提取特征的过程中同时考虑了轻量级的设计，引入了特征增强的特征金字塔模块来保留更多尺度的全局上下文信息，设计了边界感知模块来获得更精确的边界信息。整体框架如右图所示，主要分为骨干网络、分割头以及多级损失函数三部分。




HRCNet网络结构

[8] Xu, Z.; Zhang, W.; Zhang, T.; Li, J. HRCNet: High-Resolution Context Extraction Network for Semantic Segmentation of Remote Sensing Images. Remote Sens. 2021, 13, 71.



(三) 基于场景上下文信息的遥感图像分割

HRCNet考虑到**遥感图像存在大量小型地物需要进行分割**，采用了高分辨率特征提取骨干网络HRNet，同时进行轻量级设计适应遥感图像尺寸较大的特点。



轻量HRNet

为了在特征提取阶段添加全局上下文信息，每条支路的每个Stage中又加入了轻量级双重注意力模块，这里轻量级具体指减少参与计算的特征图数目。


总体来说，以上设计兼顾了特征提取的效率与充分的空间信息，保证了全局上下文的关联。



(三) 基于场景上下文信息的遥感图像分割

HRCNet的分割头主要包括了**特征融合、边界感知模块、语义编码模块的结合**。

其中对骨干网络输出的遥感图像多尺度特征进行融合时，主要依赖于增强的特征金字塔模块，它主要吸收了密集连接、空洞空间卷积池化金字塔、及特征金字塔三种结构的优势，以充分利用高级语义信息。



特征增强的特征金字塔



(三) 基于场景上下文信息的遥感图像分割

遥感图像地物背景复杂，不同地物间的边界相对更难区分，HRCNet通过边界感知模块融合高分辨率和结构信息以及丰富的高级语义信息，二者融合的结果被视为预测的边界，因此边界感知模块可使网络聚焦于边界信息并进行监督。

相反地，语义编码模块进行了全局判断，其输出用以完成图像级的分类。



1. 最大类间方差法的基本原理及计算方法。
2. Canny算子的基本原理及优势？
3. 基于区域的图像分割方法有哪几种，具体说明。
4. 简述基于深度学习的遥感图像分割整体框架。



谢 谢

