


第七章 遥感图像目标检测

主讲教师：尹继豪

宇航学院
航天信息工程系





提 纲

一

目标检测概述

二

传统目标检测算法

三

深度学习目标检测算法



—


目标检测概述

- 目标检测定义
- 目标检测算法
- 常用数据集与评价指标



□ 目标检测定义

目标检测的主要任务是在图像中**定位并识别感兴趣的目标**。待处理的图像输入后，传统算法主要基于目标**几何及统计特征**对图像进行分块特征提取，随后利用提取到的特征对图像块进行判别，找到目标所属的图像块。



□ 目标检测定义

目标检测在军事对抗中用以获得及时准确的战场信息、捕捉战略打击目标、提供精确的定位信息等。在**环境监测**、**城市规划**等民用领域，也起着举足轻重的作用。



□ 目标检测意义

(一) 军事领域

1. 军事侦察
2. 导弹预警
3. 海洋监视
4. 武器制导



□ 目标检测意义

(二) 环境监测领域

1. 土地覆盖监测
2. 森林覆盖监测
3. 草地覆盖监测
4. 湿地资源监测
5. 生态环境质量评价



□ 目标检测意义

(三) 城市规划领域

1. 城市扩张监测
2. 城市热岛监测
3. 城市绿地调查
4. 固体废弃物监测
5. 城市环境评价





□ 目标检测算法

光学遥感领域具代表性的目标检测有**可见光图像目标检测**、**红外图像目标检测**和**高光谱图像目标检测**。

可见光遥感图像的目标检测是指对包括整个可见光波段的黑白影像上目标的分类和定位。可见光遥感图像与传统图像的目标检测既具有相似性又有独特的特点，其具有信息量大、边缘细节丰富等特点。

红外遥感图像的背景连续且灰度暗，多数红外成像中，目标与检测器距离远，目标占图像面积小，缺少颜色和纹理特征。



□ 目标检测算法

高光谱图像目标检测指对于一张高光谱图像，将目标从背景和噪声中分离出来。在没有先验信息的情况下，将与周围环境**存在光谱差异的光谱点**判定为目标。这项技术的难点有：

1. 高光谱图像波段数多，**信息冗余**；
2. **背景噪声**对目标有较强的干扰；
3. **混合像元**（同一像元内往往存在多种地物）大量存在。

目标检测概述

□ 常用可见光数据集DOTA

DOTA数据集来自中国资源卫星应用中心的Google Earth采集到的**RGB图像**和GF-2、JL-1卫星采集到的**全色图像**，每张图像的大小范围在 800×800 到 $20,000 \times 20,000$ 个像素之间。



目标检测概述

□ 常用数据集DOTA

DOTA数据集的标注格式为($x_1, y_1, x_2, y_2, x_3, y_3, x_4, y_4, category, difficult$), 其中(x_i, y_i)表示斜框第*i*个顶点的坐标, 顶点按顺时针排序, 起始顶点一般为目标的左上角或中心, *category*为目标类别, *difficult*为检测难度 (0代表易检测, 1代表难检测)。每张图像标注信息保存在与图像名相同的txt的文件中。

```
x1, y1, x2, y2, x3, y3, x4, y4, category, difficult  
x1, y1, x2, y2, x3, y3, x4, y4, category, difficult  
...
```




□ 常用可见光数据集DOTA

DOTA数据集还在持续更新和完善，目前该数据集有三个版本：

- DOTA-v1.0：包含15个常见类别，2,806张图像，共计188,282个实例，其中训练集、验证集和测试集的占比分别为1/2、1/6和1/3。
- DOTA-v1.5：额外对极小的实例（小于10个像素）进行了标注，并且新增了一个“container crane”类别，总共403,318个实例。
- DOTA-v2.0：包含18个常见类别、11,268张图像，共计1,793,658个实例，新增了“airport”和“helipad”两个类别，训练集有1,830张图像和268,627个实例，验证集有593张图像和81,048个实例。

目标检测概述

□ 常用可见光数据集UCAS-AOD


UCAS-AOD数据集是由中国科学院大学制作的遥感影像数据集，包括从2014年的Google Earth航拍采集到的**车辆数据集**和**飞机数据集**。车辆数据集包含310张图像，共2,819个实例，分为250张图像和60张图像两个子集。飞机数据集包含600张图像，共3,210个实例，分为500张图像和100张图像两个子集。



目标检测概述

□ 常用红外数据集NUAA-SIRST


NUAA-SIRST包含427幅来自不同场景、包含**小目标的红外图像**，一共480个小目标实例，其中50%的图像被选作训练集，20%作为验证集，30%测试集。



目标检测概述

□ 常用红外数据集UAV-MIRST

UAV-MIRST数据集针对固定翼无人机目标的红外序列图像检测跟踪问题，设计了22个典型场景，每个典型场景对应1个数据段、共计22个数据段、30条航迹、16,177帧图像、16,944个目标及标注。




目标检测概述

□ 常用高光谱数据集Avon

Avon高光谱数据，**空间分辨率为1m**，**光谱分辨率为5nm**，在400-2,450nm之间有360个光谱波段。下图示例中，覆盖了美国纽约罗切斯特南部Avon的一个汽车公园，图像中总共67个目标像元需要被检测。



(a) 伪彩色图像



(b) 目标真实分布


目标检测概述

□ 常用高光谱数据集San Diego

San Diego高光谱数据，**空间分辨率为3.5m，光谱分辨率为10nm**，在370-2,510nm之间有224个光谱波段。下图示例中，有6架飞机总共132个目标像元需要被检测。



(a) 伪彩色图像




(b) 目标真实分布

目标检测概述

评价指标——精确率与召回率

精确率(Precision)与召回率(Recall)是常见的两个评价指标，记：

1. 真实标签为正样本，被预测为正样本的数量为 tp (true positive)
2. 真实标签为正样本，被预测为负样本的数量为 fn (false negative)
3. 真实标签为负样本，被预测为正样本的数量为 fp (false positive)
4. 真实标签为负样本，被预测为负样本的数量为 tn (true negative)



目标检测概述


□ 评测指标——精确率与召回率

精确率是指在预测正样本中，识别正确的正样本所占的比例：

$$\text{Precision} = \frac{tp}{tp + fp}$$

召回率是指在实例正样本中，识别正确的正样本所占的比例：

$$\text{recall} = \frac{tp}{tp + fn}$$





□ 评测指标——精确率与召回率

衡量模型优劣时，若希望**降低虚警率**，则选择精确率较高的模型，若希望**降低漏检率**，则选择召回率较高的模型。当兼顾两个评价指标时，可以选择 F_1 值作为评价指标， F_1 值为精确率和召回率的调和平均数：

$$\frac{2}{F_1} = \frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}$$


目标检测算法模型的 F_1 值越大，说明该算法的性能越优。

目标检测概述

□ 评测指标——AP(Average Precision)

P-R曲线展示模型表现，不同阈值下有不同的 Precision、Recall。 阈值设定较大则 Recall 趋近于 0，Precision 趋近于 1，阈值设定较小则相反。对召回率从 0 到 1 每隔 0.1 的间距进行采点，对于每个阈值 r ，计算召回率大于 r 的最大的准确度，最后取平均值得到 AP。

$$AP = \frac{1}{11} \sum_{r=(0:0.1:1)} \max P(R > r)$$






□ 评测指标——ROC曲线

ROC(Receiver Operating Characteristic Curve)曲线是另一种直观反映模型优劣的方法，它是反映虚警率和精确率连续变量的综合指标，ROC曲线上每个点反映着对同一信号刺激的感受性。

ROC曲线的绘制与PR曲线绘制方法大致相同，通过绘制不同阈值下的精确率与虚警率的关系得到。



目标检测概述


□ 评测指标—— ROC曲线

ROC曲线的横轴为**虚警率**，即假正例率，代表分类器预测的正样本中实际负样本占有所有负样本的比率：

$$\text{FPR}(\text{false positive rate}) = \frac{fp}{fp + tn}$$

ROC曲线的纵轴为**精确率**，即真正例率，代表分类器预测的正样本中实际正样本占有所有正样本的比率：

$$\text{TPR}(\text{true positive rate}) = \frac{tp}{tp + fp}$$





□ 评测指标——FPS

FPS(Frame Per Second)可以对算法检测速度进行评价，**指每秒帧率，即每秒内可以处理的图片数量。**

由于不同硬件平台在运行同一算法时速度存在差异，而该差异非算法本身设计造成，因此在进行FPS对比时，需要在同一硬件下进行。而对于不同大小的图像，算法处理时间也有差异，因此FPS评价指标需要处理一张图片，通过计算不同算法所需时间来评估检测速度，**时间越短，速度越快，说明该算法性能越好。**



二

传统目标检测算法

- 传统可见光遥感图像检测算法
- 传统红外遥感图像检测算法
- 传统高光谱图像检测算法



传统的目标检测一般分为三个阶段：

1. **区域选择**：对目标的位置进行定位。采用**滑动窗口**的策略对整幅图像进行遍历以确定目标的位置，滑动窗口需要设置不同的尺度、不同的长宽比。
2. **特征提取**：提取特征时要考虑目标的形态多样性、光照变化多样性、背景多样性等因素。常用的特征有**Haar**、**HOG**等。
3. **分类**：根据第二步提取到的特征对目标进行分类，分类器主要有**SVM**、**AdaBoost**等。



□ 传统可见光遥感图像检测算法——VJ检测器方法

VJ检测器由Paul Viola和Michael Jones于2001年提出，利用**Haar特征**来描述每个窗口，并通过**Adaboost分类器**进行分类。

VJ检测器的关键要素：

1. **积分图**(Integral Image)——特征的快速计算方法
2. **级联结构**(Cascade Structure)——高效的分类策略

□ 传统可见光遥感图像检测算法——VJ检测器方法






□ 传统可见光遥感图像检测算法——VJ检测器方法

用滑窗对不同尺度的图像进行扫描，并利用Haar特征来描述每个窗口。

在窗口的某个位置取一个矩形小块，然后将这个矩形小块划分为黑色和白色两部分，用白色部分像素点灰度值的和减去黑色部分像素点灰度值的和，得到一个Haar特征的值。




几种典型的矩形特征



□ 传统可见光遥感图像检测算法——VJ检测器方法

Haar特征反映了局部区域之间的**相对明暗关系**，能够为目标和背景的区分提供有效的信息。但是由于提取Haar特征时每次都需要计算局部区域内多个像素点灰度值之和，因此计算速度慢。

为此VJ检测器引入了**积分图来加速Haar特征的提取**。




积分图示例



□ 传统可见光遥感图像检测算法——VJ检测器方法

积分图是一张和输入图像一样大的图，但其每个点上不再是存放这个点的灰度值，而是存放从**图像左上角到该点所确定的矩形区域内全部点的灰度值之和**：

$$ii(x, y) = \sum_{x' \leq x, y' \leq y} i(x', y')$$



蓝色区域像素和： $3+2+5+4 = 46+10-20-22 = 14$



□ 传统可见光遥感图像检测算法——VJ检测器方法

积分图极大地加速了Haar特征的提取，其优势在于：

1. 每次计算局部区域像素点的灰度值之和**仅需要做3次加减法**，与局部区域的大小无关；
2. **避免了在相同像素点上重复求和**，只在最开始计算一次，相邻的窗口有很大的重叠部分，对应的Haar特征也会重叠，如果每次都重新计算像素点的灰度值之和，则重叠部分的计算是重复的。



□ 传统可见光遥感图像检测算法——VJ检测器方法

➤ 级联结构(Cascade Structure):

造成检测速度慢的根本原因在于输入规模过大，希望能够通过粗略地观察快速排除掉大部分窗口，只剩下少部分窗口需要进行仔细的判别，则总体的时间开销会极大地降低。


从这样的想法出发，VJ检测器采用一种**级联结构**来达到逐步降低输入规模的目的。



□ 传统可见光遥感图像检测算法——VJ检测器方法

➤ 级联结构(Cascade Structure):

将多个分类器级联在一起，从前往后，分类器的复杂程度和计算代价逐渐增大，对于给定的一个窗口，先由排在最前面也最简单的分类器对其进行分类，如果这个窗口被认为不存在目标，那么就不再送到后面的分类器进行分类，直接排除；否则就送到下一级分类器继续进行判别，直到其被排除。或者被所有的分类器都认为存在目标。





□ 传统可见光遥感图像检测算法——VJ检测器方法

Boosting方法就是一种典型的级联结构，其目标是学习一个**加性模型**：

$$h(x) = \sum_{t=1}^T \alpha_t h_t(x)$$

其中 $h_t(x)$ 是弱分类器， α_t 是弱分类器的集成权重， $h(x)$ 是强分类器。

Boosting方法的关键是如何训练每个弱分类器 $h_t(x)$ 及其权重 α_t ，最具代表性的是**Adaboost分类器**。



□ 传统可见光遥感图像检测算法——VJ检测器方法

➤ Adaboost(Adaptive Boosting)分类器:

Adaboost分类器的思路是，采用**迭代的方法学习每个弱分类器**，即按照一定的顺序依次训练每个弱分类器。假设已经训练了 m 个弱分类器，在训练第 $m + 1$ 个弱分类器时，**增加已有弱分类器分错样本的权重**，使得第 $m + 1$ 个弱分类器“更关注”已有弱分类器**分错的样本**，这样**增加每个弱分类器的差异**，最终提升集成分类器的准确率。



□ 传统红外遥感图像检测算法

传统的单帧红外弱小目标检测算法大都是知识驱动算法，大体可分为以下三类算法：**基于滤波的算法、基于对比度的算法以及基于低秩理论的算法。**

➤ 基于滤波的红外图像目标检测算法

通过设计合适的滤波模板来突出目标并抑制背景，主要的滤波方法有形态学滤波、均值滤波、中值滤波。这类算法计算量小，但对复杂背景的应对能力有限。



□ 传统红外遥感图像检测算法

➤ 基于对比度的红外目标检测算法

利用人类视觉系统，**关注图像局部对比度变化，通过设计滑窗来计算局部对比度检测目标。**除了经典局部对比度算法，还有多尺度局部对比度、局部熵度量和局部信杂比度量方法。


➤ 基于低秩理论的红外目标检测算法

利用背景的低秩和目标的稀疏性，**通过稀疏表示将目标检测转化为数学优化问题。**代表性算法有主成分分析、结合缨帽变换的低秩重建。



□ 传统红外遥感图像检测算法——LCM检测器方法

LCM (local contrast measure)
算法该算法的核心思想是**增强图像中的小目标区域，同时抑制图像中的背景区域**。通过小目标和周围背景的灰度差异来实现目标的识别。





□ 传统红外遥感图像检测算法——LCM检测器方法

用一个 $n \times n$ 的kernel在整张图片上进行滑动。

kernel的中间有一个红色框，代表目标区域。红色框之外的区域代表目标的邻域背景。

kernel被划分为了9个区域（每个区域内并不只是包含一个像素点），每个区域上的数字代表区域的序号。当kernel的正中央（0号区域）滑到目标位置，可以计算出0号区域和周围8邻域的灰度差异。





传统红外遥感图像检测算法——LCM检测器方法

用kernel计算0号区域和8邻域的灰度差异，具体步骤如下：

- 计算出目标临近区域的平均灰度值 m

$$m_i = \frac{1}{N_u} \sum_{j=1}^{N_u} I_j^i$$



- 局部对比度显著图 C

$$c_i^0 = \frac{L_0}{m_i}$$

$$C_n = \min_i L_0 \times c_i^0 = \min_i \frac{L_0^2}{m_i}$$

L_0 代表 0号区域像素点的最大值,
 n 代表 kernel的编号

- 对显著图 C 进行阈值分割操作，即可提取出目标区域



□ 传统高光谱图像检测算法

➤ 基于约束能量最小化的高光谱图像目标检测

该方法**适用于已知目标光谱信息的情况**，需要提前获取典型目标的光谱特性曲线，能够对较大视野范围内的高光谱图像进行检测。

➤ 基于统计模型的高光谱图像目标检测

该类算法不需要提前知道目标的光谱向量，其中经典算法RXD应用广泛，在高光谱异常目标检测中表现出良好泛化性。



□ 基于约束能量最小化的高光谱图像目标检测

基于**约束能量最小化**(CEM, Constrained Energy Minimization)的高光谱图像目标检测是根据不同地物的光谱差别，有效提取光谱信息并进行目标检测。

该方法适用于**已知目标光谱信息**的情况，需要提前获取高光谱图像中典型目标的光谱特性曲线，能够对较大视野范围内的高光谱图像进行检测。



□ 基于约束能量最小化的高光谱图像目标检测

CEM算法根据不同地物的**光谱特性曲线**各不相同的特点，利用目标光谱信息建立**FIR**(Finite Impulse Response)**滤波器**，**通过相似地物、阻塞差异地物**，对原高光谱图像进行多次滤波后，能量集中处即为目标。

FIR是一种**非递归型线性时不变数字滤波器**，对于高光谱图像输出的是给定向量的相似性度量矩阵，随着滤波次数的增加，滤波输出结果能量逐步降低，能量分布逐步稀疏，这时目标就能被检出。

□ 基于约束能量最小化的高光谱图像目标检测





□ 基于约束能量最小化的高光谱图像目标检测

该算法的**核心是构建FIR滤波器**，通过该滤波器实现目标检测，因此要求精确提取已知目标的光谱向量。



该算法的优点是**检测精度高**，当目标向量较好的表征目标特性时，检测效果良好。



□ 基于约束能量最小化的高光谱图像目标检测

基于约束能量最小化的高光谱图像目标检测结果：



检测区域



检测结果




□ 基于RXD的高光谱图像异常检测

基于RXD(Reed-Xiaoli Detector)的高光谱图像异常检测，首先依据光谱差异信息生成**像素目标概率图**，其次建立邻域像素目标概率与中心像素目标概率的**影响传递函数**，最后设计结合邻域像素目标检测概率的**空间交互模型**，从而抑制目标内部噪声，降低目标检测虚警率。


该方法适用于**未知目标信息**的情况，针对背景简单、局部相似性大的高光谱图像有较好的检测效果。

□ 基于RXD的高光谱图像异常检测


一般情况下，高光谱图像的背景区域服从**类间均值快变、类内方差慢变的多维高斯随机分布**，若其中存在目标，则高斯模型参数出现异常变化，通过设置阈值即可判断是否存在目标。



检测模板



RXD算子较大



RXD算子较小

高光谱数据

计算均值

构造异常检测
算子

阈值分割

异常检测结果



□ 基于RXD的高光谱图像异常检测


RXD算法不需要提前知道目标的光谱向量，因此应用广泛，在多光谱和高光谱异常目标检测中均表现出了良好的性能。

该算法的不足之处是存在较高的虚警率，原因主要体现在以下两个方面：一方面，该算法假设背景服从单一的多元高斯分布，但是由于真实高光谱图像通常包含复杂的地物特性，简单的高斯分布难以准确描述真实的数据特性；另一方面，该算法存在协方差计算问题，主要表现在小样本情况下高维数据的协方差不满秩或低秩的问题，以及异常目标的干扰引起的统计估计不准确问题。




□ 基于RXD的高光谱图像异常检测

基于RXD的高光谱图像异常检测结果：



检测区域



检测结果



三


深度学习目标检测算法

- 整体框架
- 基于YOLO改进的可见光遥感目标检测算法
- 基于密集连接U-Net改进的红外遥感目标检测算法
- 基于自编码网络改进的高光谱遥感目标检测算法




□ 整体框架

基于深度学习的遥感图像目标检测算法可按输出的形式划分：**基于深度学习的目标检测回归算法、目标像素分割算法。**



目标检测回归



目标像素分割



□ 整体框架——目标检测回归算法


深度学习在目标检测中的应用，使得不论是在检测准确度还是在检测速度上都有很大突破。

基于深度学习的目标检测器主要分为**两阶段检测**和**单阶段检测**两种：前者在传统算法的基础上，结合神经网络以**先提取特征再进行分类**的方式来检测，其代表为Faster-RCNN；后者将多个步骤合到一个网络中完成，力图实现**一步到位的目标检测**，其代表为YOLO。



□ 基于YOLO改进的可见光遥感目标检测算法

YOLO将整幅图分为若干个网格，每个目标中心所在的网格即为**锚点**，负责预测该目标。通过锚点对应的**多尺度、多长宽比的模板**进行回归，同时完成定位和分类任务。






□ 基于YOLO改进的可见光遥感目标检测算法

YOLO舍弃候选框提取，**直接采用回归的方法进行物体分类和候选框预测**。这样的改进简化了网络结构，将检测速度提升至了Faster R-CNN的10倍左右。至此，基于深度学习的目标检测算法能够满足**实时性**的需求。

检测器	训练集	测试集	模型	FPS
Faster RCNN	07	07	VGG-16	10
Faster RCNN	07+12	07	VGG-16	11
Faster RCNN	07	07	ResNet101	9
Faster RCNN	07+12	07	ResNet101	9
Yolov1	07+12	07	---	45
Tiny Yolov1	07+12	07	---	192
Yolov2(544*544)	07+12	07	Darknet19	87
Yolov2(480*480)	07+12	07	Darknet19	124
Yolov2(416*416)	07+12	07	Darknet19	133
Yolov2(352*352)	07+12	07	Darknet19	145
Yolov2(288*288)	07+12	07	Darknet19	154
Yolov3(544*544)	07+12	07	Darknet53	43
Yolov3(480*480)	07+12	07	Darknet53	55
Yolov3(416*416)	07+12	07	Darknet53	61
Yolov3(352*352)	07+12	07	Darknet53	70
Yolov3(288*288)	07+12	07	Darknet53	76



□ 基于YOLO改进的可见光遥感目标检测算法





□ 基于YOLO改进的可见光遥感目标检测算法

针对可见光遥感图像目标检测任务改进的算法——PP-YOLO-R，主要作出了如下改进：

- PP-YOLO-R引入**ProbIoU Loss**作为回归损失函数以避免**边界不连续问题**；
- PP-YOLO-R在旋转目标检测任务上提出了**旋转任务的对齐学习**；
- PP-YOLO-R设计了解耦的角度预测头，通过DFL (Distribution Focal Loss) 学习**角度的一般分布**；
- PP-YOLO-R添加了一个可学习的**门控单元**，用于控制网络中**前一层的信息**。



□ 基于YOLO改进的可见光遥感目标检测算法

YOLO

较高的推理速度

架构简单易于理解和使用

难以处理遮挡、密集目标等复杂场景

PP-YOLO-R

旋转任务对齐学习

ProbIoU损失避免边界不连续


DFL损失有利于获得更准确的角度预测



□ 整体框架——目标像素分割算法

- (1) 数据裁切与预处理;
- (2) 主干网络下采样编码, 在图像上提取特征;
- (3) 解码网络上采样恢复, 将特征尺度恢复到原图大小;
- (4) 利用卷积神经网络作为分割头, 在最终特征上进行目标分割。

代表算法为U-Net、Deeplab等






□ 基于密集连接U-Net改进的红外遥感目标检测算法

在2015年Ronnerberger等人提出了深度学习U-Net模型，一种呈现为U形的卷积神经网络。


该模型一经提出便被广泛应用于各种医学图像分割、遥感图像分类、人体姿势估计等领域。





□ 基于密集连接U-Net改进的红外遥感目标检测算法

- 在U-Net网络下采样的过程中，特征空间分辨率不断减少，最终得到**语义信息最丰富、特征维数最多**的高层特征，因此分类、回归得以精确进行。
- 在U-Net网络上采样的过程中，逐渐恢复特征空间信息，而在这个过程中需要下采样过程中特征的**跨层连接**，最终经过检测头得到分类、回归结果。






□ 基于密集连接U-Net改进的红外遥感目标检测算法

与通用目标的检测相比，红外目标检测由于成像机理与应用场景的不同，最终目标的成像特性有所不同，主要的区别有：


- 由于成像距离远，红外目标在图像中的像素占比很小，往往小于整体图像的0.5%；
- 红外目标通常具有较低的信噪比或信杂比，更容易被较强的噪声与复杂背景淹没；
- 红外目标缺少形状纹理等有效表观特征。






□ 基于密集连接U-Net改进的红外遥感目标检测算法

DNA-Net模型通过端到尾的方式**堆叠多个U-Net模型**，将前一个U-Net模型的输出作为下一个U-Net模型的输入，使模型进行自上而下和自下而上的**反复推理**，并重新预测初始特征和整个图像的特征，从而提高检测精度。






基于密集连接U-Net改进的红外遥感目标检测算法






□ 基于密集连接U-Net改进的红外遥感目标检测算法






□ 基于自编码网络改进的高光谱遥感目标检测算法

自编码网络是一种通过神经网络对输入数据进行降维的算法，由一个编码器与一个解码器组成。**编码器可将高维的输入压缩成低维的隐藏层，解码器可以把隐藏层恢复成输入，达到从高维输入到低维编码这样一个压缩目的。**




□ 基于自编码器网络改进的高光谱遥感目标检测算法

自编码器用于高光谱目标检测的基本思想为：通过编码-解码过程对高光谱图像背景数据进行学习，并以最小化重构误差进行解码重构，最终找到目标。



□ 基于自编码网络改进的高光谱遥感目标检测算法




上式中， σ 为激活函数。解码器利用权重矩阵 W' 和偏置 b' 将隐藏层 Z 映射到重构层 I'



□ 基于自编码网络改进的高光谱遥感目标检测算法

基于3D卷积自动编码网络的高光谱目标检测3D-CAE模型将高光谱图像立方体看做一个整体，可以准确有效的提取高光谱图像**深层空谱结合的特征**，直接生成**3D特征立方体**，能更加充分利用高光谱图像的空谱信息和结构特性。





□ 基于自编码网络改进的高光谱遥感目标检测算法

传统自编码器

全连接方式学习数据特征

无法学习数据的内在特征

二维或以上的数据丢失结构信息

基于3D卷积自编码器

3D卷积方式学习数据特征

保留光谱和空间的特征

更好的学习到高光谱图像内在特征



- 1. 目标检测算法的评价指标都有哪些？**
- 2. 传统目标检测算法的基本步骤？**
- 3. 传统可见光遥感图像检测的算法有哪些，举例说明。**
- 4. 传统高光谱遥感图像检测的算法有哪些，举例说明。**
- 5. 基于深度学习的可见光遥感图像检测算法有哪些，举例说明。**



谢 谢

