



视觉SLAM基础

主讲：崔林艳

单位：宇航学院 图像处理中心

开课专业：飞行器控制与信息工程



第1章 视觉SLAM基础

CONTENTS PAGE


- 1.1 绪论
- 1.2 SLAM的数学描述
- 1.3 三维空间刚体运动
- 1.4 李群与李代数
- 1.5 相机模型
- 1.6 批量状态估计问题
- 1.7 非线性最小二乘
- 1.8 小结

1.5 相机模型

- “机器人如何表示自身运动”的问题：三维空间表示、李群与李代数



- “机器人如何观测外部世界”，也就是观测方程部分。在以相机为主的视觉SLAM中，观测主要是指相机成像的过程。



1.5 相机模型

1.5.1 针孔相机模型

1.5.2 双目相机模型

1.5.3 深度相机模型


1.5 相机模型

1.5.1 针孔相机模型

1.5.2 双目相机模型

1.5.3 深度相机模型

1.5.1 针孔相机模型



相机将三维世界中的坐标点（单位为米）映射到二维图像平面（单位为像素）的过程能够用一个几何模型进行描述。

↓ 投影过程

a) 针孔模型



最为简单，常用且有效，描述了一束光线通过针孔之后，在针孔背面投影成像的关系。



b) 畸变模型




相机镜头上透镜的存在，使得光线投影到成像平面的过程中会产生畸变。

把外部的三维点投影到相机内部成像平面，构成相机的内参数

1.5.1 针孔相机模型

三维世界中的蜡烛投影到二维成像平面





小孔成像

1.5.1 针孔相机模型

- **相机坐标系**: $O-x-y-z$, 通常习惯上让 z 轴指向相机光心, x 向右, y 向下。 O 为摄像机的光心, 也是针孔模型中的针孔。
- 位于现实世界的空间点 P , 经过小孔 O 投影之后, 落在**物理成像平面** $O'-x'-y'-z'$ 上, 成像点为 P' 。

针孔相机模型



1.5.1 针孔相机模型

- 设 P 的坐标为 $[X, Y, Z]^T$,
- P' 的坐标为 $[X', Y', Z']^T$,
- 物理成像平面到小孔距离为 f (焦距) ,





根据三角形相似关系, 有:

$$\frac{Z}{f} = -\frac{X}{X'} = -\frac{Y}{Y'}$$


负号表示成的像是倒立的。

针孔相机模型




1.5.1 针孔相机模型

- 为了简化模型，可以把成像平面对称到相机前方，和三维空间点一起位于相机坐标系的同一侧：



$$\frac{Z}{f} = -\frac{X}{X'} = -\frac{Y}{Y'}$$

成像平面对称
到相机前方




$$\frac{Z}{f} = \frac{X}{X'} = \frac{Y}{Y'}$$

整理得到


$$\begin{aligned} X' &= f \frac{X}{Z} \\ Y' &= f \frac{Y}{Z} \end{aligned}$$

描述了点P和它的像P'之间的空间关系




1.5.1 针孔相机模型

- 相机获得的是像素，需要在物理成像平面上对像进行采样和量化。
- 为了描述传感器将感受到的光线转换成图像像素的过程，设在物理成像平面上固定着一个像素平面 $o'-u-v$ ，在该像素平面上对应的像 P' 的像素坐标为 $[u, v]^T$



1.5.1 针孔相机模型

- **像素坐标系的定义：**原点位于图像的左上角， u 轴向右与 x 轴平行， v 轴向下与 y 轴平行。像素坐标系与物理成像平面之间，相差了一个**缩放**和一个原点的**平移**。



设像素坐标系在 u 轴上缩放了 α 倍，在 v 轴上缩放了 β 倍。同时，原点平移了 $[c_x, c_y]^T$ 。此时，像点的坐标与像素坐标 $[u, v]^T$ 的关系为：

$$\begin{cases} u = \alpha X' + c_x \\ v = \beta Y' + c_y \end{cases}$$

代入

$$\begin{cases} X' = f \frac{X}{Z} \\ Y' = f \frac{Y}{Z} \end{cases}$$

$$\begin{cases} u = f_x \frac{X}{Z} + c_x \\ v = f_y \frac{Y}{Z} + c_y \end{cases}$$

其中： $f_x = \alpha f$ ， $f_y = \beta f$

f 的单位为米； α 和 β 的单位为像素每米
 f_x ， f_y 单位为像素

1.5.1 针孔相机模型

$$\begin{cases} u = f_x \frac{X}{Z} + c_x \\ v = f_y \frac{Y}{Z} + c_y \end{cases}$$

矩阵形式

$$\begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = \frac{1}{Z} \begin{pmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} X \\ Y \\ Z \end{pmatrix} \triangleq \frac{1}{Z} K P.$$

传统习惯(将Z挪到左侧)

$$Z \begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = \begin{pmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} X \\ Y \\ Z \end{pmatrix} \triangleq K P.$$

相机内参数矩阵 K (Camera Intrinsics)

相机的内参通常在相机生产之后就已固定，不会在使用过程中发生变化。

1.5.1 针孔相机模型

- 相机在运动，相机的位姿由它的旋转矩阵 R 和平移向量 t 来描述。

$$Z P_{uv} = Z \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \underbrace{K}_{\text{②}} \underbrace{(R P_w + t)}_{\text{①}} = \underbrace{K T}_{\text{②}} \underbrace{P_w}_{\text{①}}$$

↑

描述了点 P 的世界坐标 P_w 到像素坐标 P_{uv} 的投影关系

- ① 点 P 从世界坐标变到相机坐标系；
② 点 P 从相机坐标系变换到像素坐标系；

- 其中，相机的位姿 (R, t) 或 T 称为**相机的外参数**（Camera Extrinsics）
- 相比于不变的相机内参，相机外参会随着相机运动发生变化；
- 外参是SLAM估计的目标，代表载体的运动轨迹。

1.5.1 针孔相机模型

- 两侧都是齐次坐标

$$ZP_{uv} = Z \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = K(RP_w + t) = KTP_w.$$

P_w : 世界坐标系下的齐次坐标

- 齐次坐标乘上非零常数后表达相同的含义，可以将公式中的 Z 项去掉：

$$P_{uv} = K \boxed{TP_w}$$


- **Step1.** 将世界坐标系下的齐次坐标 P_w 变换到相机坐标系下 TP_w 。

$$\tilde{P}_c = \begin{bmatrix} X' \\ Y' \\ Z' \end{bmatrix} = \left(TP_w \right)_{(1:3)}$$


为了使它与 $K(3*3$ 矩阵)相乘，
需要取 TP_w 的前三维组成向量。

$$T = \begin{bmatrix} R & t \\ 0^T & 1 \end{bmatrix} \quad 4*4 \text{ 矩阵}$$

P_w : $4*1$ 列向量 (齐次坐标)
 TP_w 为 $4*1$ 列向量 (齐次坐标)

$$P_w = \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}$$

1.5.1 针孔相机模型

- **Step1.** 把一个世界坐标系下的齐次坐标 P_w 变换到相机坐标系下。

- **Step2.** 按照齐次坐标的方式进行归一化处理，得到在相机归一化平面（ $z=1$ ）上的投影 P_c ：

- **Step3.** P_c 经过相机内参之后得到像素坐标 P_{uv}

$$\tilde{P}_c = \begin{bmatrix} X' \\ Y' \\ Z' \end{bmatrix} = (TP_w)_{(1:3)}$$

↓ 转换到相机归一化平面

$$P_c = \begin{bmatrix} X' / Z' \\ Y' / Z' \\ 1 \end{bmatrix}$$

↓ 转换到像素坐标系


$$P_{uv} = KP_c \quad K = \begin{pmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{pmatrix}$$

- 以上坐标转换过程，最终实现了世界坐标系下的点 P_w （为4*1列的齐次坐标）到像素坐标 P_{uv} （为3*1列的齐次坐标）的转换。即首先从世界坐标系下 P_w 通过相机外参 T 转换到相机坐标系；然后经过归一化处理，转换到相机归一化平面下（ P_c ）；最后利用相机内参 K ，转换到像素坐标系下 P_{uv} 。

1.5.1 针孔相机模型

➤ 畸变

- 透镜对成像过程中光线的传播产生的影响：
 - 透镜自身的形状对光线传播的影响：例如**径向畸变**。
 - 在机械组装过程中，透镜和成像平面不可能完全平行，这也会使得光线穿过透镜投影到成像面时的位置发生变化。例如**切向畸变**。



广角镜头畸变




鱼眼镜头畸变


1.5.1 针孔相机模型

➤ 由透镜形状引起的畸变称为径向畸变


- 在针孔模型中，一条直线投影到像素平面上还是一条直线。可是，在实际拍摄的照片中，摄像机的透镜往往使得真实环境中的一条直线在图片中变成了曲线。越靠近图像的边缘，此现象越明显。
- 由于实际加工制作的透镜往往是中心对称的，这使得不规则的畸变通常径向对称。它们主要分为两大类：桶形畸变和枕形畸变。



正常图像




桶形失真



枕形失真

1.5.1 针孔相机模型

- 除了透镜的形状会引入径向畸变之外，在相机的组装过程中透镜和成像面不能严格平行也会引入切向畸变。



1.5.1 针孔相机模型

➤ 径向畸变和切向畸变的数学描述

考虑相机归一化平面上的任意一点 p ，坐标为 $[x, y]^T$ ，通常这些畸变满足多项式形式：

- 径向畸变：

$$\begin{aligned}x_{distorted} &= x(1 + k_1r^2 + k_2r^4 + k_3r^6) \\y_{distorted} &= y(1 + k_1r^2 + k_2r^4 + k_3r^6)\end{aligned}$$

- 切向畸变：

$$\begin{aligned}x_{distorted} &= x + 2p_1xy + p_2(r^2 + 2x^2) \\y_{distorted} &= y + p_1(r^2 + 2y^2) + 2p_2xy\end{aligned}$$

$[x_{distorted}, y_{distorted}]^T$ ：畸变后点的归一化坐标坐标

1.5.1 针孔相机模型

➤ 径向畸变和切向畸变的数学描述

- 将径向畸变和切向畸变的多项式描述公式联合起来，对于相机坐标系中的一点 $P(X,Y,Z)$ ，能够通过5个畸变系数 (k_1, k_2, k_3, p_1, p_2) 找到这个点在像素平面上的位置：

1. 将三维空间点投影到相机归一化平面。设它的归一化坐标为 $[x, y]^T$

2. 对归一化平面上的点计算径向畸变和切向畸变：

$$\begin{cases} x_{\text{distorted}} = x(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) + 2p_1 xy + p_2(r^2 + 2x^2) \\ y_{\text{distorted}} = y(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) + p_1(r^2 + 2y^2) + 2p_2 xy \end{cases}$$

3. 将畸变后的点通过内参数矩阵投影到像素平面，得到该点在图像上的位置：

$$\begin{cases} u = f_x x_{\text{distorted}} + c_x \\ v = f_y y_{\text{distorted}} + c_y \end{cases}$$

1.5.1 针孔相机模型

➤ 小结：单目相机的成像过程

- 四种坐标：世界坐标、相机坐标、相机归一化平面坐标和像素坐标

单目相机成像过程



1. 首先，世界坐标系下有一个固定的点 P ，世界坐标为 P_w ；
2. 由于相机在运动，它的运动由 R, t 或变换矩阵 $T \in SE(3)$ 描述。 P 的相机坐标为：
 $\tilde{P}_c = RP_w + t$ 。
3. 这时的 $\tilde{P}_c$ 仍有 X, Y, Z 三个量，把它们投影到归一化平面 $Z = 1$ 上，得到 P 的归一化相机坐标： $P_c = [X/Z, Y/Z, 1]^T$ 。
4. 最后， P 的归一化坐标经过内参后，对应到它的像素坐标： $P_{uv} = KP_c$ 。

投影顺序：世界坐标系-》相机坐标系-》相机归一化平面-》像素坐标系

1.5 相机模型

1.5.1 针孔相机模型


1.5.2 双目相机模型

1.5.3 深度相机模型

1.5.2 双目相机模型

➤ 针孔相机模型问题分析：


- 描述了单个相机的成像模型，然而仅根据一个像素无法确定该空间点具体位置。
- 原因：从相机光心到归一化平面连线上的所有点，都可以投影至该像素点。只有当 P 的深度确定时（比如通过双目或RGB-D相机），才能确切地知道它的空间位置。



像素点可能存在的位置


1.5.2 双目相机模型

- **双目相机的原理：**通过同步采集左右相机的图像，**计算图像间视差**，**来估计每一个像素的深度**。
- ① 在左右双目相机中，可以把两个相机都看作针孔相机。它们是水平放置的，意味着两个相机的光圈中心都位于 x 轴上。
 - ② 左右双目相机之间的距离称为双目相机的基线（baseline，记为 b ），是双目相机的重要参数。



1.5.2 双目相机模型

- 空间点 P ，它在左眼相机和右眼相机各成一像，记 P_L, P_R ；
- 理想情况下，由于左右相机只在 x 轴上有位移，因此 P 的像也只在 x 轴上（对应图像的 u 轴）有差异。记它的左侧坐标为 u_L ，右侧坐标为 u_R 。



双目相机的成像模型。 O_L, O_R 为左右光圈中心，蓝色框为成像平面， f 为焦距。 u_L 和 u_R 为成像平面的坐标。按照图中坐标定义， u_R 应该是负数，因此图中标出的距离为 $-u_R$


1.5.2 双目相机模型

➤ 根据三角形 $\triangle PP_L P_R$ 和 $\triangle PO_L O_R$ 的相似关系，得到：

$$\frac{z-f}{z} = \frac{b-u_L+u_R}{b} \quad \xrightarrow{\text{整理得到}} \quad z = \frac{fb}{d}$$

$$d = u_L - u_R$$

左右图横坐标之差，称为视差
(Disparity)




1.5.2 双目相机模型

$$z = \frac{fb}{d}$$

$d = u_L - u_R$ 左右图横坐标之差，称为**视差 (Disparity)**

- 根据视差，可以估计像素与相机之间的距离 z 。视差与距离成反比，视差越大，距离越近。
- 距离公式简单，但视差 d 本身不容易计算：需要知道左眼图像某个像素出现在右眼图像的哪一个位置（对应关系）。
- 只有在图像纹理变化丰富的区域才能计算视差。



双目相机的数据：左眼图像，右眼图像。通过左右眼的差异，能够判断场景中物体离相机距离。

1.5 相机模型

1.5.1 针孔相机模型


1.5.2 双目相机模型

1.5.3 深度相机模型

1.5.3 深度相机模型

□ 深度相机能够主动测量每个像素的深度，目前RGB-D相机按照原理分两类：


- A. 通过红外结构光（Structed Light）来测量像素距离；
- B. 通过飞行时间法（Time-of-flight, TOF）原理测量像素距离。



1.5.3 深度相机模型


A. 通过红外结构光（Structed Light）来测量像素距离

原理：向探测目标发射一束光线（通常是红外光）。在**结构光原理**中，相机根据返回的结构光图案，计算物体与自身之间的距离；



深度摄像头 D435


英特尔® 实感™ D435 在我们推出的所有摄像头中视场深度传感器上配置全局快门，是快速移动应用的理想选择。



1.5.3 深度相机模型

B. 通过飞行时间法（Time-of-flight, TOF）原理测量像素距离。

原理：相机向目标发射脉冲光，然后根据发送到返回之间的光束飞行时间，确定物体与自身之间的距离。



Kinect v2

（包含：彩色摄像头、深度（红外）摄像头、红外投影机）



1.5.3 深度相机模型

- 在测量深度之后，RGB-D相机完成深度与彩色图像素之间的配对，**输出一一对应的彩色图和深度图**。可以在同一个图像位置，读取到色彩信息和距离信息；
- RGB-D相机局限性：**发射-接收的测量方式**，其使用范围比较受限。
 - ①用红外光进行深度值测量的RGB-D相机，容易受到日光或其他传感器发射的红外光干扰，因此不能在室外使用；
 - ②同时使用多个RGB-D相机时也会相互干扰。
 - ③对于透射材质物体，因为接收不到反射光，无法测量这些点的位置。




1.5.3 深度相机模型


➤ RGB-D相机内外参应用举例：

- 已知条件：3对RGB-D图像，以及每张图像的内参和外参。
- **求解问题：**1) 根据RGB-D图像和相机内参，计算任何一个像素在相机坐标系下的位置。2) 根据相机姿态（外参），计算出这些像素在世界坐标系下的位置，从而构建三维点云。

RGB图



深度图



1.5.3 深度相机模型

Step1: 读取彩色和深度图像对和位姿信息

Step2: 根据如下公式，计算获取

- ① 根据RGB-D图像和相机内参，计算任何一个像素在相机坐标系下的位置。
- ② 根据相机姿态（外参），计算出这些像素在世界坐标系下的位置，从而构建三维点云。

➤ 相机坐标 p_c 到像素坐标 $(u; v; d)$ 的关系为

$$d \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = K p_c.$$

反推 p_c 的形式

设 $p_c = [x; y; z]$

$$z = d$$

$$x = \frac{u - c_x}{f_x} z$$

$$y = \frac{v - c_y}{f_y} z.$$

根据相机外参 T

得到世界坐标
下对应的 p

$$p_c = T p$$

得到相机坐标下对应的 p_c

1.5.3 深度相机模型



第1章 视觉SLAM基础

CONTENTS PAGE

- 1.1 绪论
- 1.2 SLAM的数学描述
- 1.3 三维空间刚体运动
- 1.4 李群与李代数
- 1.5 相机模型
- 1.6 批量状态估计问题
- 1.7 非线性最小二乘
- 1.8 小结

1.6 批量状态估计问题

➤ 内容回顾:

相机位姿：可由变换矩阵 T_k 表示

$$\begin{cases} \text{运动方程} & \begin{cases} \mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_k, \mathbf{w}_k) \\ \text{观测方程} & \mathbf{z}_{k,j} = h(\mathbf{y}_j, \mathbf{x}_k, \mathbf{v}_{k,j}) \end{cases} \end{cases}$$

x : 旋转+平移

h : 相机观测模型

- 假设在位置 x_k 处对路标 y_j 进行了一次观测，对应到图像上的像素位置 $z_{k,j}$ ，那么观测方程可以表示成：

$$s\mathbf{z}_{k,j} = K \exp(\hat{\xi}) \mathbf{y}_j$$

变换矩阵 T （与李代数 ξ 满足指数关系）

➤ 问题引出:

数据受到各种未知噪声影响，如何在有噪声的数据中进行准确的状态估计？

1.6 批量状态估计问题

➤ 实际SLAM:

- 同一点会被一个相机在不同时间内多次观测，同一个相机在每个时刻观测到的点不止一个。
- 拥有了更多的约束，能够较好地噪声数据中恢复出位姿并建立地图。

1.6 批量状态估计问题

➤ SLAM状态估计流程：

- 已知带噪声的数据 z 和 u ，推断位姿 x 和地图 y ，构成了一个状态估计问题。
- 非线性优化方法（视觉SLAM主流方法），使用所有时刻采集到的数据进行状态估计。

- ① 在非线形优化中，把所有待评估的变量放在一个“状态变量”中：

$$\boldsymbol{x} = \{\boldsymbol{x}_1, \dots, \boldsymbol{x}_N, \boldsymbol{y}_1, \dots, \boldsymbol{y}_M\}$$

- ② 此时，对机器人状态估计，就是求已知输入数据 u 和观测数据 z 的条件下，计算状态 x 的条件概率分布：

$$P(\boldsymbol{x} | \boldsymbol{z}, \boldsymbol{u})$$

- ③ 当没有测量运动的传感器（无 u 数据，实际中经常存在），只有一张张的图像时（对应观测到的数据 z ），即只考虑观测方程带来的数据时，相当于估计 $P(x|z)$ 的条件概率分布。利用贝叶斯法则，有：

$$\underbrace{P(\boldsymbol{x} | \boldsymbol{z})}_{\text{后验概率}} = \frac{P(\boldsymbol{z} | \boldsymbol{x}) P(\boldsymbol{x})}{P(\boldsymbol{z})} \propto \underbrace{P(\boldsymbol{z} | \boldsymbol{x})}_{\text{似然}} \underbrace{P(\boldsymbol{x})}_{\text{先验}}$$

似然是指“在现有的姿态下，可能产生怎样的观测数据”

1.6 批量状态估计问题

➤ SLAM状态估计流程：

- ④ 直接求后验分布非常困难，问题转化：求一个状态最优估计 x^* ，使得在该状态下，后验概率最大化（Maximize a Posterior, MAP）：

$$x_{MAP}^* = \arg \max \underbrace{P(x | z)}_{\text{后验概率}} = \arg \max \underbrace{P(z | x)}_{\text{似然}} \underbrace{P(x)}_{\text{先验}}$$

- ⑤ 根据贝叶斯法则可知，求解最大后验概率，相当于最大化似然和先验的乘积。在不知道机器人位姿大概在什么地方（没有先验部分 $P(x)$ ），可以求解 x 的最大似然估计（Maximize Likelihood Estimation, MLE）

$$x_{MLE}^* = \arg \max P(z|x)$$

直观意义：观测数据 z 已知，最大似然估计的直观意义为“在什么样的状态 x 下，最可能产生现在观测到的数据 z ”；对于SLAM而言：“在什么相机位姿下，最可能观测到现在获取的图像”

1.6 批量状态估计问题

➤ 求解最大似然举例

➤ 例子：某次观测

$$z_{k,j} = \underline{h(y_j, x_k)} + v_{k,j},$$

假设噪声满足高斯分布： $v_k \sim N(0, Q_{k,j})$

➤ 于是观测数据 z 的条件概率为：

$$P(z_{j,k} | x_k, y_j) = N(\underbrace{h(y_j, x_k)}_{\text{均值}}, \underbrace{Q_{k,j}}_{\text{方差}}).$$

该条件概率仍然是一个高斯分布。为了计算使它最大化的 x_k, y_j ，往往使用最小化负对数的方式，来求一个高斯分布的最大似然。

1.6 批量状态估计问题

- Step1: 高斯分布在负对数下有较好的数学形式。考虑一个任意的高维高斯分布 $x \sim N(\mu, \Sigma)$ ，它的概率密度函数展开形式为：

$$P(x) = \frac{1}{\sqrt{(2\pi)^N \det(\Sigma)}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1} (x - \mu)\right).$$

- Step2: 取负对数

取负对数：

$$-\ln(P(x)) = \frac{1}{2} \ln\left((2\pi)^N \det(\Sigma)\right) + \frac{1}{2}(x - \mu)^T \Sigma^{-1} (x - \mu).$$

最小化时，只和此项有关

对原分布求最大化相当于对负对数求最小化。在最小化上式时，第一项与 x 无关，可以略去。于是，只要最小化右侧的二次型项，就得到了对状态的最大似然估计。代入SLAM的观测模型，相当于在求：

$$x^* = \arg \min \left(\underbrace{(z_{k,j} - h(x_k, y_j))}_{\text{噪声}}^T \underbrace{Q_{k,j}^{-1}}_{\text{噪声}} (z_{k,j} - h(x_k, y_j)) \right)$$

噪声

噪声

SLAM观测方程： $z_{k,j} = h(y_j, x_k) + v_{k,j}$, $v_k \sim N(0, Q_{k,j})$

1.6 批量状态估计问题

$$z_{k,j} = h(y_j, x_k) + v_{k,j},$$

$$x^* = \arg \min \left(\underbrace{(z_{k,j} - h(x_k, y_j))}_{\text{噪声}}^T \underbrace{Q_{k,j}^{-1}}_{\text{噪声}} (z_{k,j} - h(x_k, y_j)) \right)$$

该公式等价于最小化噪声项（即误差）的一个二次型，该二次型称为马氏距离。

- Step3: 定义运动和观测数据与估计值之间的误差:

$$\begin{aligned} e_{v,k} &= x_k - f(x_{k-1}, u_k) \\ e_{y,j,k} &= z_{k,j} - h(x_k, y_j), \end{aligned}$$

于是，状态最大似然估计问题转换成了最小二乘问题。

1.6 批量状态估计问题

运动方程

观测方程

$$\begin{cases} \mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_k, \mathbf{w}_k) \\ \mathbf{z}_{k,j} = h(\mathbf{y}_j, \mathbf{x}_k, \mathbf{v}_{k,j}) \end{cases}$$

并求该误差的平方之和

$$J(\mathbf{x}) = \underbrace{\sum_k \mathbf{e}_{v,k}^T \mathbf{R}_k^{-1} \mathbf{e}_{v,k}}_{\text{运动误差部分}} + \underbrace{\sum_k \sum_j \mathbf{e}_{y,k,j}^T \mathbf{Q}_{k,j}^{-1} \mathbf{e}_{y,k,j}}_{\text{观测误差部分}}$$

得到了一个总体意义下的最小二乘问题 (Least Square Problem)，它的最优解等价于状态的最大似然估计。

➤ SLAM最小二乘问题直观解释：

1. 目标函数由许多个误差的（加权的）平方和组成。

- a) 每个误差项仅与一两个状态变量有关。例如运动误差只与 x_{k-1} , x_k 有关，观测误差只与 x_k , y_j 有关。
- b) 每个误差项是一个小规模的约束，最后再把这个误差项的小雅可比矩阵块放到整体的雅可比矩阵中。由于这种做法，称每个误差项对应的优化变量为参数块 (Parameter Block)。

1.6 批量状态估计问题

并求该误差的平方之和

$$J(\mathbf{x}) = \underbrace{\sum_k \mathbf{e}_{v,k}^T \mathbf{R}_k^{-1} \mathbf{e}_{v,k}}_{\text{运动误差部分}} + \underbrace{\sum_k \sum_j \mathbf{e}_{y,k,j}^T \mathbf{Q}_{k,j}^{-1} \mathbf{e}_{y,k,j}}_{\text{观测误差部分}}$$

得到了一个总体意义下的最小二乘问题（Least Square Problem），它的最优解等价于状态的最大似然估计。

➤ SLAM最小二乘问题直观解释：

2. 整体误差由很多小型误差项之和组成，其增量方程的求解会具有一定的稀疏性，使得它们在大规模时也可求解；
3. 如果使用李代数表示，则该问题是无约束的最小二乘问题。但如果用旋转矩阵（变换矩阵）描述位姿，则会引入旋转矩阵自身的约束（旋转矩阵必须是正交矩阵且行列式为1），使优化变得更加困难，体现了李代数优势。
4. 使用了平形式（二范数）度量误差，相当于欧氏空间中距离的平方。

第1章 视觉SLAM基础

CONTENTS PAGE

- 1.1 绪论
- 1.2 视觉SLAM的数学描述
- 1.3 三维空间刚体运动
- 1.4 李群与李代数
- 1.5 相机模型
- 1.6 批量状态估计问题
- 1.7 非线性最小二乘
- 1.8 小结

1.7 非线性最小二乘

➤ 简单问题：

$$\min_{\mathbf{x}} F(\mathbf{x}) = \frac{1}{2} \|f(\mathbf{x})\|_2^2 \quad \text{这里 } \mathbf{x} \in \mathbb{R}^n, f \text{ 为任意标量非线性函数}$$


- 当 f 是数学形式上很简单的函数时，以上问题可以用解析形式来求解。令目标函数的导数为零，然后求解 $\mathbf{x}$ 的最优解。

$$\frac{dF}{d\mathbf{x}} = \mathbf{0}$$

解如上方程，得到导数为零处的极值。可能是极小、极大或者鞍点处的值。

- 当 f 复杂时：

df/dx 难求，或 $df/dx=0$ 很难解



1.7 非线性最小二乘

➤ 迭代求解

- 对于不方便直接求解的最小二乘问题，可以用迭代的方式，从一个初始值出发，不断地更新当前的优化变量，使得目标函数下降。

- ① 给定某个初始值 x_0 ;
- ② 对于第 k 次迭代，寻找一个增量 Δx_k ，使得 $\|f(x_k + \Delta x_k)\|_2^2$ 达到极小值;
- ③ 若 Δx_k 足够小，则停止;
- ④ 否则，令 $x_{k+1} = x_k + \Delta x_k$ ，返回步骤2.

- 问题：增量 Δx_k 如何确定？

1.7 非线性最小二乘

$$\min_{\mathbf{x}} F(\mathbf{x}) = \frac{1}{2} \|\mathbf{f}(\mathbf{x})\|_2^2$$

① 一阶和二阶梯度法

- 在进行第 k 次迭代时，假设在 x_k 处，想要寻到增量 Δx_k ，则最直观的方式是**将目标函数 $F(x)$ 在 x_k 附近进行泰勒展开**：

$$F(x_k + \Delta x_k) \approx F(x_k) + J(x_k)^T \Delta x_k + \frac{1}{2} \Delta x_k^T H(x_k) \Delta x_k$$

$J(x_k)$: $F(x)$ 关于 x 的一阶导数（也称为梯度、雅可比（Jacobian）矩阵）

H : $F(x)$ 关于 x 的二阶导数（海塞（Hessian）矩阵）

- 根据选择保留泰勒展开的一阶或二阶项，对应的求解方法则为**一阶梯度或二阶梯度法**。

1.7 非线性最小二乘

① 一阶和二阶梯度法

a) 如果保留一阶梯度，那么取增量 Δx 为反向的梯度，即可保证函数下降

$$\Delta x^* = -J(x_k)$$

以上仅为方向，通常还会计算该方向上的一个步长 λ ，求得最快的下降方式，称为最速梯度下降法。直观意义：沿着反向梯度前进，在一阶（线性）近似下，目标函数必定下降。

$$J(x_k)$$



1.7 非线性最小二乘

➤ 向量函数对向量求导：

考虑 $F(x)$ 为一个向量函数： $F(x) = [f_1(x), \dots, f_m(x)]^T$

其中每一个 f_k 都是自变量为向量(假设 x 为 n 维列向量)、取值为标量的函数。

• 雅可比矩阵 $J(x)$ ：

$$J = \frac{\partial F}{\partial x^T} = \begin{bmatrix} \frac{\partial f_1}{\partial x^T} \\ \cdot \\ \cdot \\ \cdot \\ \frac{\partial f_m}{\partial x^T} \end{bmatrix} = \begin{bmatrix} \frac{df_1}{dx_1} & \frac{df_1}{dx_2} & \dots & \frac{df_1}{dx_n} \\ \frac{df_2}{dx_1} & \frac{df_2}{dx_2} & \dots & \frac{df_2}{dx_n} \\ \dots & \dots & \dots & \dots \\ \frac{df_m}{dx_1} & \frac{df_m}{dx_2} & \dots & \frac{df_m}{dx_n} \end{bmatrix} \in \mathbb{R}^{m \times n}$$

J 为 $m \times n$ 的雅可比矩阵。



• 如下公式成立： $\frac{\partial A x}{\partial x^T} = A$ (列向量对行向量求导，习惯用此形式)

• 反之，一个行向量函数也可以对列向量求导，结果为之前的转置： $\frac{\partial F^T}{\partial x} = \left(\frac{\partial F}{\partial x^T} \right)^T$ (行向量对列向量求导)

1.7 非线性最小二乘

$$\frac{\partial Ax}{\partial x^T} = A \quad \text{列向量对行向量求导}$$

$$\frac{\partial F^T}{\partial x} = \left(\frac{\partial F}{\partial x^T} \right)^T$$

b) 如果保留二阶梯度，那么增量方程为：

$$\Delta x^* = \arg \min \left(F(x) + J(x)^T \Delta x + \frac{1}{2} \Delta x^T H \Delta x \right)$$

右侧仅包含 Δx 的零次、一次和二次项。求右侧等式关于 Δx 的导数并令它为零，得到：

$$J + H \Delta x = 0 \quad \Rightarrow \quad H \Delta x = -J$$

求解以上线性方程，得到增量 Δx ，该方法称为**牛顿法**。需要计算复杂的Hessian矩阵，在问题规模较大时非常困难。

能否回避Hessian的计算？

Gauss-Newton

Levenberg-Marquadt

1.7 非线性最小二乘

$$\min_x F(x) = \frac{1}{2} \|f(x)\|_2^2$$

② Gauss-Newton (高斯牛顿法)

- 最优化算法中最简单的方法之一，基本思想是**将 $f(x)$ 进行一阶泰勒展开**（注意：不是目标函数 $F(x)$ 而是 $f(x)$ ，否则就变成了牛顿法）。

$$f(x + \Delta x) \approx f(x) + J(x)^T \Delta x \quad x \in \mathbb{R}^n$$

这里的 $J(x)^T$ 为 $f(x)$ 关于 x 的导数，为 $n \times 1$ 的列向量

- 根据前面的框架，当前的目标是寻找增量 Δx ，使得 $\|f(x + \Delta x)\|_2^2$ 达到最小。为了求 Δx ，需要解一个线性的最小二乘问题：

$$\Delta x^* = \arg \min_{\Delta x} \frac{1}{2} \|f(x) + J(x)^T \Delta x\|_2^2$$

- 根据极值条件，将上述**目标函数对 Δx 求导，并令导数为零**。具体分为如下几步：

1.7 非线性最小二乘

$$\Delta x^* = \arg \min_{\Delta x} \frac{1}{2} \left\| f(x) + J(x)^T \Delta x \right\|_2^2$$

- **Step1:** 展开目标函数的平方项

$$\begin{aligned} \frac{1}{2} \left\| f(x) + J(x)^T \Delta x \right\|_2^2 &= \frac{1}{2} \left(f(x) + J(x)^T \Delta x \right)^T \left(f(x) + J(x)^T \Delta x \right) \\ &= \frac{1}{2} \left(\left\| f(x) \right\|_2^2 + 2 f(x)^T J(x)^T \Delta x + \Delta x^T J(x) J(x)^T \Delta x \right) \end{aligned}$$

- **Step2:** 求上式关于 Δx 的导数，并令其为零：

$$J(x) f(x) + J(x) J^T(x) \Delta x = 0 \quad \xrightarrow{\text{得到}} \quad \underbrace{J(x) J^T(x)}_{H(x)} \Delta x = \underbrace{-J(x) f(x)}_{g(x)}$$

- ✓ 以上方程是关于变量 Δx 的线性方程组，称为增量方程，也被称为高斯牛顿方程（Gauss Newton equations）。
- ✓ 将左边的系数定义为 H ，右边定义为 g ，则上述公式可变形为：

$$H \Delta x = g$$

对比牛顿法，Gauss-Newton用 $J^T J$ 作为牛顿法中二阶Hessian矩阵的近似，省略了计算 H 的过程。求解增量方程是整个优化问题的核心。

1.7 非线性最小二乘

$$\underbrace{J(x)J^T(x)}_{H(x)} \Delta x = \underbrace{-J(x)f(x)}_{g(x)}$$

- 高斯牛顿法的算法步骤为：

- 给定初始值 x_0 ;
- 对于第 k 次迭代，求出当前的误差 $f(x_k)$ 和对应的雅可比矩阵 $J(x_k)$;
- 求解增量方程： $H\Delta x_k = g$;
- 若 Δx_k 足够小，则停止。否则，令 $x_{k+1} = x_k + \Delta x_k$ ，返回第2步。

- 可见，增量方程的求解占据主要地位。为了求解增量方程，需要求解 H^{-1} ，需要 H 矩阵可逆。如果求出的步长 Δx 太大，会导致采用的局部近似 $f(x + \Delta x) \approx f(x) + J(x)^T \Delta x$ 不够准确，此时无法保证它的迭代收敛。

1.7 非线性最小二乘

③ Levenberg-Marquadt方法

- 阻尼牛顿法（Damped Newton Method），在SLAM中被广泛采用
- 基本思想：通过给 Δx 添加一个信赖区域（Trust Region），提高近似的鲁棒性。在信赖区域内，认为近似是有效的；出了这个区域，近似可能会出现問題。
- 问题：如何确定信赖区域的范围？

1.7 非线性最小二乘

③ Levenberg-Marquadt方法

- **确定信赖区域的范围：**根据近似模型与实际函数之间的差异来确定该范围，如果差异小(ρ 接近于1)，说明近似好，可以扩大近似的范围；如果差异大，则缩小近似的范围。通过如下公式判断近似程度：

$$\rho = \frac{f(x + \Delta x) - f(x)}{J(x)^T \Delta x}$$

分子：实际函数下降的值；
分母：近似模型下降的值。

1.7 非线性最小二乘

③ Levenberg-Marquadt方法

➤ 实现步骤:

1. 给定初始值 $\mathbf{x}_0$, 以及初始优化半径 μ 。
2. 对于第 k 次迭代, 求解:

$$\min_{\Delta \mathbf{x}_k} \frac{1}{2} \|f(\mathbf{x}_k) + \mathbf{J}(\mathbf{x}_k)^T \Delta \mathbf{x}_k\|_2^2, \quad s.t. \underbrace{\|\mathbf{D} \Delta \mathbf{x}_k\|_2^2}_{\text{不等式约束}} \leq \mu,$$

在Levenberg提出的优化方法中, 通常 $\mathbf{D}$ 取成单位阵 $\mathbf{I}$, 相当于直接把增量 $\Delta \mathbf{x}$ 约束在一个半径为 μ 的球中, 认为只在这个球内的才是有效的。



不等式约束

3. 计算 ρ 。 $\rho = \frac{f(\mathbf{x} + \Delta \mathbf{x}) - f(\mathbf{x})}{\mathbf{J}(\mathbf{x})^T \Delta \mathbf{x}}$ (近似模型与实际函数之间的差异)

4. 若 $\rho > \frac{3}{4}$, 则 $\mu = 2\mu$;

5. 若 $\rho < \frac{1}{4}$, 则 $\mu = 0.5\mu$;



根据计算出来的 ρ 数值, 改变置信区间近似范围, 其中扩大的倍数和阈值都是经验值, 可以替换成别的数值。

6. 如果 ρ 大于某阈值, 认为近似可行。令 $\mathbf{x}_{k+1} = \mathbf{x}_k + \Delta \mathbf{x}_k$ 。
7. 判断算法是否收敛。如不收敛则返回 2, 否则结束。

1.7 非线性最小二乘

③ Levenberg-Marquadt方法

$$\min_{\Delta \mathbf{x}_k} \frac{1}{2} \|f(\mathbf{x}_k) + \mathbf{J}(\mathbf{x}_k)^T \Delta \mathbf{x}_k\|_2^2, \quad s.t. \|D \Delta \mathbf{x}_k\|^2 \leq \mu$$

不等式约束

- 在L-M优化过程中，求解的是带不等式约束的优化问题，可以用Lagrange乘子将它转化为一个无约束优化问题：

$$L(\Delta \mathbf{x}_k, \lambda) = \frac{1}{2} \|f(\mathbf{x}_k) + \mathbf{J}(\mathbf{x}_k)^T \Delta \mathbf{x}_k\|_2^2 + \frac{\lambda}{2} (\|D \Delta \mathbf{x}_k\|^2 - \mu)$$

- 这里 λ 为Lagrange乘子。类似于Gauss Newton中的做法，令该拉格朗日函数关于 $\Delta \mathbf{x}_k$ 的导数为零，得到如下增量方程：

$$(H + \lambda D^T D) \Delta \mathbf{x}_k = g$$

- 可看出，增量方程相比于Gauss Newton，多了一项 $\lambda D^T D$ 。如果考虑简化形式，即 $D=I$ ，相当于求解：

$$(H + \lambda I) \Delta \mathbf{x}_k = g$$

1.7 非线性最小二乘

③ Levenberg-Marquadt方法

$$(H + \lambda I) \Delta x_k = g$$



- ① 当参数 λ 比较小时， H 占主要地位，L-M方法接近于Gauss-Newton法。
- ② 当参数 λ 比较大时， λI 占据主要地位，L-M算法接近于一阶梯度下降法（即最速下降）。
- ③ L-M的求解方式，可在一定程度上避免线性方程组的系数矩阵的非奇异和病态问题，提供更稳定更准确的增量 Δx 。

1.7 非线性最小二乘

➤ 小结:

- SLAM中经常遇到的非线性优化问题：由许多个误差项平方和组成的最小二乘问题。

$$J(x) = \sum_k e_{v,k}^T R_k^{-1} e_{v,k} + \sum_k \sum_j e_{y,k,j}^T Q_{k,j}^{-1} e_{y,k,j}.$$

- 一阶梯度下降法、二阶梯度下降法；
- Gauss-Newton（高斯牛顿法）
- Levenberg-Marquadt方法
- 对于视觉SLAM而言，增量方程中的系数矩阵往往有特定的稀疏形式，可利用稀疏形式的消元、分解，然后再进行求解增量，可以实现高效的求解，达到实时的目的。

1.7 非线性最小二乘

<https://github.com/ceres-solver/ceres-solver>。

➤ Ceres 库：面向通用的最小二乘问题的求解

- 需要用户定义优化问题，然后设置一些选项，输入进 Ceres 求解
- Ceres 求解的最小二乘问题最一般的形式（带边界的核函数最小二乘）：

$$\min_x \quad \frac{1}{2} \sum_i \rho_i \left(\|f_i(x_{i_1}, \dots, x_{i_n})\|^2 \right) \quad s.t. \quad l_j \leq x_j \leq u_j$$

- ✓ 目标函数由许多平方项，经过一个核函数 $\rho(\cdot)$ 之后，求和组成。在最简单的情况下，取 ρ 为恒等函数，则目标函数即为许多项的平方和。此时，优化变量为 $x_1, \dots, x_n$ ， f_i 称为代价函数（Cost function），在 SLAM 中亦可理解为误差项。
- ✓ 最简单的情况下，取 $l_j = -1$ ； $u_j = 1$ （不限制优化变量的边界），并且取 ρ 为恒等函数时，就得到了无约束的最小二乘问题。

- 在 Ceres 中，定义优化变量 x 和每个代价函数 f_i ，再调用 Ceres 进行求解。使用 G-N 或者 L-M 进行梯度下降，并设定梯度下降的条件，Ceres 会在优化之后，将最优估计值返回。

第1章 视觉SLAM基础

CONTENTS PAGE

1.1 绪论

1.2 视觉SLAM的数学描述

1.3 三维空间刚体运动

1.4 李群与李代数

1.5 相机模型

1.6 批量状态估计问题


1.7 非线性最小二乘

1.8 小结

1.8 小结

■ 视觉SLAM定义、应用场景、框架结构

无人驾驶、AR、VR





视觉传感器

前端
视觉里程计

后端
非线性优化

建图

回环检测



1.8 小结

➤ 视觉SLAM数学描述:

运动方程、观测方程

① 机器人从 $k-1$ 时刻运动到 k 时刻:

运动方程
$$\mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_k, \mathbf{w}_k)$$

运动传感器的读数 (也称作输入) $\mathbf{u}_k$

噪声 $\mathbf{w}_k$

② 在 k 时刻 ($\mathbf{x}_k$ 位置上) 观察到了路标 $\mathbf{y}_j$, 产生观测 $\mathbf{z}_{k,j}$:

观测方程
$$\mathbf{z}_{k,j} = h(\mathbf{y}_j, \mathbf{x}_k, \mathbf{v}_{k,j})$$

路标 $\mathbf{y}_j$


观测点 $\mathbf{x}_k$

观测噪声 $\mathbf{v}_{k,j}$

1.8 小结

➤ 三维空间表示：


- 旋转矩阵、旋转向量、欧拉角、四元数
- “机器人如何表示自身运动”的问题：三维空间表示、李群与李代数



1.8 小结

➤ 相机模型：

针孔相机、双目相机、RGB-D深度相机



1.8 小结

➤ SLAM状态估计

相机位姿：可由变换矩阵 T_k 表示

$$\begin{cases} \mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_k, \mathbf{w}_k) \\ \mathbf{z}_{k,j} = h(\mathbf{y}_j, \mathbf{x}_k, \mathbf{v}_{k,j}) \end{cases}.$$

观测模型

$\mathbf{x}$: 旋转+平移
 h : 相机观测模型

- **SLAM问题**：如何在有噪声的数据中进行准确的状态估计？

非线性优化、非线性最小二乘