



北京航空航天大学
BEIHANG UNIVERSITY

模式识别

第二章 线性分类器

北京航空航天大学宇航学院



2 线性分类器

2.1 线性分类器基础


2.3 垂直平分分类器

2.4 Fisher投影准则

2.5 感知准则

2.6 最小错分样本准则

2.7 最小平方误差准则





2.1 线性分类器基础

2.1.1 线性判别函数

2.1.2 广义线性判别函数

2.1.3 多类问题



2.1 线性分类器基础

例 飞机目标和油罐目标两分类

➤ 给定飞机和油罐两类目标如下



遥感图像油罐目标 (w_1 类)




遥感图像飞机目标 (w_2 类)

➤ 提取目标的平均灰度和长宽比

➤ 绘制特征空间映射图

- x_1 代表长宽比
- x_2 代表目标亮度 (平均灰度)

在二维特征空间中，二分类任务可以有多个决策边界 (分类面)





2.1 线性分类器基础

1、线性判别函数

➤ 基本概念

模式识别的目的就是在样本特征空间中寻找两类或多类之间的分界面（决策边界），从而实现对不同模式的**分类**。

【决策面】 在样本特征空间中，将不同种类样本区分开的决策边界也叫决策面或分类面。

【判别函数】 用数学形式描述决策面的函数就是判别函数。

【超平面】 使用线性判别函数描述的决策面是线性的，在低维空间中表现为点、线、面的形式，在高维空间中则称为超平面。

【线性分类器】 这样的线性决策面构成的分类器称作线性分类器。



2.1 线性分类器基础

1、线性判别函数

➤ 线性判别函数的一般形式

在n维特征空间中，特征向量表示为 $x = [x_1, x_2, \dots, x_n]^T$ ，线性判别函数一般形式为

$$g(x) = \omega_1 x_1 + \omega_2 x_2 + \dots + \omega_n x_n + \omega_0 = \omega^T x + \omega_0$$

式中， $\omega_1, \omega_2, \dots, \omega_n$ 称为加权因子， ω_0 为阈值权

将加权因子写成权向量 $\omega = [\omega_1, \omega_2, \dots, \omega_n]^T$ 的形式，则线性判别函数可写为

$$g(x) = \omega^T x + \omega_0$$



2.1 线性分类器基础

1、线性判别函数

➤ 判别规则与决策面

- 在二分类问题中，分别用 ω_1 和 ω_2 表示两类，直接采用线性判别函数 $g(x) = \omega^T x + \omega_0$ 进行分类。对应的判别规则为：

① 若 $g(x) > 0$ ，则 $x \in \omega_1$ 。

② 若 $g(x) < 0$ ，则 $x \in \omega_2$ 。

- 决策面方程为

$$g(x) = \omega^T x + \omega_0 = 0$$




2.1 线性分类器基础


1、线性判别函数

➤ 线性分类器决策面 H 在不同维度特征空间的表现形式


特征维度	一维 ($d = 1$)	二维 ($d = 2$)	三维 ($d = 3$)	多维 ($d > 3$)
决策面情况	点	直线	平面	超平面



一维



二维



三维



2.1 线性分类器基础

1、线性判别函数

➤ 线性判别函数的几何性质

$$g(\mathbf{x}) = \omega_1 x_1 + \omega_2 x_2 + \cdots + \omega_n x_n + \omega_0 = \omega^T \mathbf{x} + \omega_0$$


① 法向量方向为 $\mathbf{w}$

② 原点到决策面的欧式距离为

$$d = \frac{|w_0|}{\sqrt{w_1^2 + w_2^2}} = \frac{|w_0|}{\|\mathbf{w}\|}$$

① 样本 $\mathbf{x}$ 到决策面的欧氏距离为

$$z = \left| \frac{g(\mathbf{x})}{\sqrt{w_1^2 + w_2^2}} \right|$$





2.1 线性分类器基础

2、广义线性判别函数

➤ 增广向量与增广特征空间

- 定义广义线性判别函数为 $a^T y$, 令

$$y = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \\ x_d \end{bmatrix} = \begin{bmatrix} 1 \\ \mathbf{x} \end{bmatrix}, a = \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_d \end{bmatrix} = \begin{bmatrix} w_0 \\ \mathbf{w} \end{bmatrix}$$

式中, a 称为增广权向量, y 称为增广样本向量, $a^T y$ 称为广义 (或增广) 线性判别函数。增广特征向量所在的特征空间称为增广特征空间, 记为 Y 。

- $a^T y=0$ 在 Y 空间确定了一个过原点的超平面, 在设计某些线性分类器时, 过原点的超平面便于求解和计算。增广的 Y 特征空间比原始的 X 特征空间维数增加了一维, 但样本间的欧氏距离保持不变, 且不影响分类器的优化设计。




2.1 线性分类器基础


2、广义线性判别函数

➤ 增广变换前后特征空间和决策面情况对比

以一维特征为例，增广变换后，维数增加为二维，判别函数变成了广义线性判别函数，这时的决策面为一条直线，但实际上与原始一维空间的解是等价的。



(a) 变换前



(b) 变换后



2.1 线性分类器基础

3、多类问题

➤ 二分类与多分类

- 二分类问题是模式识别的基本问题。
- 多类分类问题可以通过两种典型做法分解成若干个二分类问题，这样就可以通过组合多个二分类器、采用多个线性判别函数进行分类。
 - ① **一对其余**，在训练时依次把某个类别的样本归为一类，其他剩余的样本归为另一类，也就是把多类样本转化为类与“类的非”这两类。
 - ② **一对一**，对多个类别中每两个类别进行分类。假设 c 个类别，一共 $c(c-1)/2$ 个分类器，投票多的为胜者。



2.2 垂直平分分类器

1、垂直平分分类器的定义与设计

➤ 垂直平分分类器的定义


- 是以样本的均值点作为代表点，取两类样本均值点的垂直平分线（或垂直平分面）作为决策面的分类器。

➤ 垂直平分分类器的特点

- 对样本集没有具体要求，只需要求取样本均值，算法简单，运算量小，易于设计。

➤ 垂直平分分类器的设计

- ① 分别求出两类样本的均值点 m_1 和 m_2
- ② 连接 m_1 和 m_2 形成直线，求该直线的垂直平分线





2.2 垂直平分分类器

2、垂直平分分类器的判别函数与决策规则

➤ 垂直平分分类器的判别函数 假设 ω_1 是正类

① 由垂直条件得： $(m_1 - m_2)^T x + w_0 = 0$

② 由平分条件得： $w_0 = -\frac{1}{2}(m_1 - m_2)^T(m_1 + m_2)$

③ 将②代入①，得垂直平分分类器的判别函数为： $g(x) = (m_1 - m_2)^T \left(x - \frac{m_1 + m_2}{2} \right)$

④ 决策面H的方程为： $g(x) = (m_1 - m_2)^T \left(x - \frac{m_1 + m_2}{2} \right) = 0$

➤ 垂直平分分类器的决策规则

- 对于未知样本 x ，若 $g(x) > 0$ ，则 $x \in \omega_1$ ；否则 $x \in \omega_2$ （默认决策面的法向量指向 ω_1 类）。
- 使用分类器时，只要将未知样本 x 的值代入判别函数进行计算，根据上述决策规则即可判断 x 所属的类别。



2.2 垂直平分分类器

3、垂直平分分类器的举例

➤ 已知两类的训练样本： $\omega_1: \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 2 \end{bmatrix}$ 和 $\omega_2: \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 2 \\ 1 \end{bmatrix}$ ，现有一个类别未知样本 $\begin{bmatrix} 2 \\ 3 \end{bmatrix}$ ，试用垂直平分分类器判别该样本属于哪一类。

① 两类样本的均值为： $m_1 = \frac{1}{2}(\begin{bmatrix} 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 2 \end{bmatrix}) = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$ ； $m_2 = \frac{1}{2}(\begin{bmatrix} 2 \\ 0 \end{bmatrix} + \begin{bmatrix} 2 \\ 1 \end{bmatrix}) = \begin{bmatrix} 2 \\ \frac{1}{2} \end{bmatrix}$

② 将 m_1 、 m_2 和 x 代入判别函数的方程得：

$$g(x) = (m_1 - m_2)^T \left(x - \frac{m_1 + m_2}{2} \right) = \begin{bmatrix} -2 & \frac{1}{2} \end{bmatrix} \left(\begin{bmatrix} 2 \\ 3 \end{bmatrix} - \begin{bmatrix} 1 \\ \frac{3}{4} \end{bmatrix} \right) = -2 + \frac{9}{8} = -\frac{7}{8} < 0$$

③ 由决策规则可知，判别函数值小于零，故样本决策为第二类，即 $x \in \omega_2$ 。



2.2 垂直平分分类器

4、最小距离分类器

- 定义判别函数为欧氏距离（非线性）


$$G_1(x) = d_1(x) = ||x - m_1||$$

$$G_2(x) = d_2(x) = ||x - m_2||$$

- 垂直平分分类器等价的最小距离决策规则为

- ① 对于未知样本 x ，若 $d_1(x) < d_2(x)$ ，则 x 决策为 ω_1 类；
- ② 若 $d_1(x) > d_2(x)$ ，则 x 决策为 ω_2 类。

- 因此，垂直平分分类器又叫最小距离分类器。





2.3 Fisher投影准则

1、维数灾难与降维

➤ **维数问题：特征个数多、特征空间维数高、计算量大**

- ① 如果分类时所用的特征个数太多，将形成高维特征空间，高维空间不论对分类器的理论设计还是分类器的实际运用，都会带来“灾难性”后果。
- ② 特征个数越多，计算量就越大，导致分类器设计困难和分类困难。

➤ **设计思路**


需要进行**降维处理**，将高维空间投影到低维空间就是典型的方法。



2.3 Fisher投影准则

2、Fisher投影要解决的问题

- 将 d 维空间的样本投影到一维坐标轴上，原始 d 维空间的分类问题被转换为一维空间上的分类问题。
- 在不同方向上投影后，样本在一维坐标轴上的分布不同，有的适合分类，有的不适合分类。
- 因此一维坐标轴的方向不是随意的，需进行优化求解
- Fisher投影准则所要解决的问题：如何根据样本集情况，求解最佳的（最易于分类的）投影线方向。






2.3 Fisher投影准则

2、Fisher投影要解决的问题

两类 d 维情况下，设样本集 $X = \{x_1, x_2, \dots, x_n\}$ ，其中 ω_1 类有 n_1 个，记为 X_1 ， ω_2 类有 n_2 个，记为 X_2 。又设 y 是 x 样本在**投影向量** p 上的投影点，（ p 是一个列向量，维度等于 x 的特征维度； y 是标量，一维上的一个点）。

当选择不同方向的投影向量 p 时，样本投影后的可分离程度就不同，从而会直接影响最后的分类效果。

因此，需要定义Fisher投影准则，求解**最佳的投影方向** p^* 。





2.3 Fisher投影准则

2、Fisher准则函数

➤ 定义Fisher投影准则所用到的重要参数及其相关计算公式

空间	X 空间	Y 空间
样本均值	$\mathbf{m}_1 = \frac{1}{n} \sum_{\mathbf{x} \in \mathbf{X}_1} \mathbf{x}$ $\mathbf{m}_2 = \frac{1}{n} \sum_{\mathbf{x} \in \mathbf{X}_2} \mathbf{x}$	$\tilde{\mathbf{m}}_1 = \frac{1}{n} \sum_{y \in Y_1} y = \frac{1}{n} \sum_{\mathbf{x} \in \mathbf{X}_1} \mathbf{p}^T \mathbf{x} = \mathbf{p}^T \mathbf{m}_1$ $\tilde{\mathbf{m}}_2 = \frac{1}{n} \sum_{y \in Y_2} y = \frac{1}{n} \sum_{\mathbf{x} \in \mathbf{X}_2} \mathbf{p}^T \mathbf{x} = \mathbf{p}^T \mathbf{m}_2$
类内离散度矩阵	$\mathbf{S}_1 = \sum_{\mathbf{x} \in \mathbf{X}_1} (\mathbf{x} - \mathbf{m}_1) (\mathbf{x} - \mathbf{m}_1)^T$ $\mathbf{S}_2 = \sum_{\mathbf{x} \in \mathbf{X}_2} (\mathbf{x} - \mathbf{m}_2) (\mathbf{x} - \mathbf{m}_2)^T$	$\tilde{\mathbf{S}}_1^2 = \sum_{y \in Y_1} (y - \tilde{\mathbf{m}}_1)^2$ $\tilde{\mathbf{S}}_2^2 = \sum_{y \in Y_2} (y - \tilde{\mathbf{m}}_2)^2$
总类内离散度矩阵	$\mathbf{S}_w = \mathbf{S}_1 + \mathbf{S}_2$	$\tilde{\mathbf{S}}_w = \tilde{\mathbf{S}}_1^2 + \tilde{\mathbf{S}}_2^2$
类间离散度矩阵	$\mathbf{S}_B = (\mathbf{m}_1 - \mathbf{m}_2) (\mathbf{m}_1 - \mathbf{m}_2)^T$	$\tilde{\mathbf{S}}_B = (\tilde{\mathbf{m}}_1 - \tilde{\mathbf{m}}_2)^2$



2.3 Fisher投影准则

2、Fisher准则函数


➤ Fisher准则函数定义

Fisher准则函数的表达式为

$$J_F(p) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1^2 + \tilde{S}_2^2}$$

➤ Fisher投影准则的物理含义

- ① 投影后各类样本尽可能集中（分母 $\tilde{S}_1^2 + \tilde{S}_2^2$ 越小越好）。
- ② 投影后两类样本之间尽量远离（分子 $\tilde{m}_1 - \tilde{m}_2$ 越大越好）。





2.3 Fisher投影准则

2、Fisher准则函数

➤ 找到最佳的投影方向 p^*

找到最佳的投影方向即是求使 $J_F(p)$ 达到极大值的 p^* 向量方向。将Fisher准则函数的分子和分母分别处理：

$$(\tilde{m}_1 - \tilde{m}_2)^2 = (p^T m_1 - p^T m_2)(p^T m_1 - p^T m_2)^T = p^T (m_1 - m_2)(m_1 - m_2)^T p = p^T S_B p$$

将 $y = p^T x$ 代入 $\tilde{S}_i^2 = \sum_{y \in Y_i} (y - \tilde{m}_i)^2$ ，得到

$$\tilde{S}_i^2 = p^T S_i p, \quad \tilde{S}_1^2 + \tilde{S}_2^2 = p^T S_w p$$

代入准则函数 $J_F(p)$ ，最终得到：

$$J_F(p) = \frac{p^T S_B p}{p^T S_w p}$$



2.3 Fisher投影准则

2、Fisher准则函数

➤ 求 $J_F(p)$ 的极大值

$J_F(p) = \frac{p^T S_B p}{p^T S_w p}$ 的分子和分母都是关于 p 的二次型，其取值与 p 的模长无关，因此，分母

部分可以视为常数，即 $c = p^T S_w p \neq 0$

采用拉格朗日乘子法求解 $J_F(p)$ 的极大值。

条件=0的话加减无所谓

定义拉格朗日函数为： $L(p, \lambda) = p^T S_B p - \lambda(p^T S_w p - c)$

对 p 求偏导数，并令偏导数为零： $\frac{\partial L(p, \lambda)}{\partial p} = 2(S_B p^* - \lambda S_w p^*) = 0$

得到： $S_B p^* = \lambda S_w p^*$



2.3 Fisher投影准则

2、Fisher准则函数

➤ 找到最佳的投影方向 p^*

$$S_B p^* = \lambda S_W p^*$$

由于 S_W 是对称和半正定矩阵，当样本数目 $n > d$ 时， S_W 是非奇异的，可对其求逆，即

$$\lambda p^* = S_W^{-1} S_B p^* \quad (1)$$

可以看出，极值问题被转化为求矩阵 $S_W^{-1} S_B$ 的特征值和特征向量，其中 λ 是特征值， p^* 是对应的特征向量。

另外：

$$S_B p^* = (m_1 - m_2)(m_1 - m_2)^T p^* = (m_1 - m_2)r \quad (2)$$

其中 $r = (m_1 - m_2)^T p^*$ 是标量，可见 $S_B p^*$ 总是在 $(m_1 - m_2)$ 的方向上。



2.3 Fisher投影准则

2、Fisher准则函数

➤ 找到最佳的投影方向 p^*

$$\lambda p^* = S_w^{-1} S_B p^* \quad (1)$$

$$S_B p^* = (m_1 - m_2)(m_1 - m_2)^T p^* = (m_1 - m_2)r \quad (2)$$

将 (2) 式代入 (1) 式得:

$$p^* = \frac{r}{\lambda} S_w^{-1} (m_1 - m_2)$$

式中, $\frac{r}{\lambda}$ 是一个比例因子, 与投影向量 p^* 的方向无关, 删除后可得:

$$p^* = S_w^{-1} (m_1 - m_2)$$

p^* 就是使 $J_F(p)$ 取极大值时的解, 也就是**d维X空间到一维Y空间的**最佳投影方向****。



2.3 Fisher投影准则

3、Fisher准则函数的应用

- **例4** 已知两类分类问题，两类的训练样本分别为： ω_1 类样本 $\begin{bmatrix} 0 \\ 0 \end{bmatrix}$ ， $\begin{bmatrix} 0 \\ 2 \end{bmatrix}$ 和 ω_2 类样本 $\begin{bmatrix} 0 \\ 2 \end{bmatrix}$ ， $\begin{bmatrix} 1 \\ 2 \end{bmatrix}$ ，试求取Fisher投影方向向量 p^* 。

$$\mathbf{m}_1 = \frac{1}{n} \sum_{x \in X_1} \mathbf{x}, \quad \mathbf{m}_2 = \frac{1}{n} \sum_{x \in X_2} \mathbf{x},$$

$$\mathbf{S}_1 = \sum_{x \in X_1} (\mathbf{x} - \mathbf{m}_1) (\mathbf{x} - \mathbf{m}_1)^T, \quad \mathbf{S}_2 = \sum_{x \in X_2} (\mathbf{x} - \mathbf{m}_2) (\mathbf{x} - \mathbf{m}_2)^T$$

$$\mathbf{S}_w = \mathbf{S}_1 + \mathbf{S}_2$$



2.3 Fisher投影准则

3、Fisher准则函数的应用

- **例4** 已知两类分类问题，两类的训练样本分别为： ω_1 类样本 $\begin{bmatrix} 0 \\ 0 \end{bmatrix}$, $\begin{bmatrix} 0 \\ 2 \end{bmatrix}$ 和 ω_2 类样本 $\begin{bmatrix} 0 \\ 2 \end{bmatrix}$, $\begin{bmatrix} 1 \\ 2 \end{bmatrix}$ ，试求取Fisher投影方向向量 p^* 。

$$m_1 = \frac{1}{n} \sum_{x \in X_1} x = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad m_2 = \frac{1}{n} \sum_{x \in X_2} x = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

$$S_1 = \sum_{x \in X_1} (x - m_1)(x - m_1)^T = \begin{bmatrix} 0 & 0 \\ 0 & 2 \end{bmatrix}, \quad S_2 = \sum_{x \in X_2} (x - m_2)(x - m_2)^T = \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & 0 \end{bmatrix}$$

$$S_w = S_1 + S_2 = \begin{bmatrix} \frac{1}{2} & 0 \\ 0 & 2 \end{bmatrix}, \quad S_w^{-1} = \begin{bmatrix} 2 & 0 \\ 0 & \frac{1}{2} \end{bmatrix}$$

$$p^* = S_w^{-1}(m_1 - m_2) = \begin{bmatrix} -1 \\ 1 \\ -\frac{1}{2} \end{bmatrix}$$



2.4 感知准则

2.4.1 线性可分

2.4.2 感知器模型

2.4.3 解向量和解区

2.4.4 感知准则函数

2.4.5 梯度下降法



2.4 感知准则

1、线性可分

➤ 样本集的线性可分性

- 至少存在一个权向量（即决策面），能将样本集中的每个样本都正确分类，否则就是线性不可分的。
- 在两类样本线性可分情况下，将属于 ω_2 的样本各特征分量同时乘以-1，这个过程称为线性可分样本集的规范化。规范化以后，样本集所有样本均满足 $\mathbf{a}^T \mathbf{y} > 0, n = 1, 2, \dots, N$ ，可求出解向量 $\mathbf{a}^*$ 。

➤ 感知准则的目的：给定样本集，求 $\mathbf{a}^*$ ，使得所有样本分类正确



2.4 感知准则


2、感知器模型

➤ 感知器模型的输入输出关系

- 感知器是一个具有单层计算单元的神经元模型，感知器具有多输入和单输出。

- 其输入/输出关系如下： $y = f(\sum_{i=1}^d w_i x_i - \theta)$

其中， x_i 为输入； y 为输出； θ 为阈值。





2.4 感知准则

2、感知器模型

➤ 感知器模型的输入输出关系

如果该神经元没有内部状态的转变，且 f 为一个阶跃函数，其输出表达式为

$$y = f\left(\sum_{i=1}^d w_i x_i - \theta\right) = \begin{cases} 1, & \sum_{i=1}^d w_i x_i - \theta > 0 \\ -1, & \sum_{i=1}^d w_i x_i - \theta \leq 0 \end{cases}$$

权值 w_i 和阈值 θ 可以通过训练学习来调整，从而实现线性分类。

当感知器用于两类目标分类时，相当于在样本的高维（ d 维）特征空间中，用一个超平面把两类样本区分开，如果两类是线性可分的，则算法一定收敛。



2.4 感知准则

3、解向量和解区

➤ 解向量

对于线性可分的一组样本 $y_1, \dots, y_N$ ，（采用规范化增广样本向量表示），如果一个权向量 α^T 满足：

$$\alpha^T y_i > 0, i = 1, 2, \dots, N$$

则称 α^T 为一个解向量。

➤ 解空间

在权值空间中所有解向量所组成的区域称为解区。




2.4 感知准则

3、解向量和解区

➤ 解区的可视化

权向量和样本向量的维数相同，可以把权向量画到样本空间。对于一个样本 y_i ， $\alpha^T y_i = 0$ 定义了一个过原点的超平面 $\hat{H}_i$ 。对这个样本来说，处于超平面 $\hat{H}_i$ 正侧的任何一个向量都能使 $\alpha^T y_i > 0$ ，因而 α 是对这个样本的一个解。考虑样本集中的所有样本，解区就是每个样本对应的超平面的正侧的交集。






2.4 感知准则

3、解向量和解区

➤ 余量

- 解区中任意一个向量都是解向量，都能把样本正确分开。但如果一个解向量靠近解区的边缘，某些样本的判别函数可能刚刚大于零。考虑到噪声、计算误差等，靠近解区中间的解向量更加可靠。
- 因此，提出**余量**概念，即把解区向中间缩小，不取靠近边缘的解，引入余量 b ，解向量满足

$$\alpha^T y_i > b, i = 1, 2, \dots, N$$





2.4 感知准则

4、感知准则函数

对于**规范化的增广样本集**，感知准则函数可以选取为：

$$J_P(a) = \sum_{y \in Y_e} (-a^T y)$$

其中， Y_e 是被权向量 a 错误分类的样本集合。

对于规范化增广样本集，若权向量 a 使样本集中的样本 y 能正确分类，则有 $a^T y > 0$ 。
反之若错误分类，则 $a^T y \leq 0$ 或 $-a^T y \geq 0$ 。所以 $J_P(a) \geq 0$ 。



2.4 感知准则

4、感知准则函数

对于**规范化的增广样本集**，感知准则函数可以选取为：

$$J_P(a) = \sum_{y \in Y_e} (-a^T y)$$

其中， Y_e 是被权向量 a 错误分类的样本集合。

对于规范化增广样本集，若权向量 a 使样本集中的样本 y 能正确分类，则有 $a^T y > 0$ 。
反之若错误分类，则 $a^T y \leq 0$ 或 $-a^T y \geq 0$ 。所以 $J_P(a) \geq 0$ 。

当且仅当 a 为解向量时， $J_P(a) = 0$ ，此时不存在错分样本。



2.4 感知准则

5、梯度下降法求解极值

➤ 梯度下降法迭代公式

- 函数 $J_P(a)$ 在某点 a_k 的梯度 $\nabla J(a_k)$ 是一个向量，其方向是 $J_P(a)$ 增长最快的方向。因此，负梯度方向是 $J_P(a)$ 减少最快的方向。
- 在求解某个函数的极大值时，沿梯度方向走，可以最快达到极大值点；反之，沿负梯度方向走，可以最快到达极小值点。
- 对于感知准则函数 $J_P(a)$ ，其最小值对应着最优解 a^* 。由此可以得到梯度下降法迭代公式：

$$a_{k+1} = a_k - \rho_k \frac{\nabla J_P(a)}{\|\nabla J_P(a)\|}$$

其中梯度为：

$$\nabla J_P(a) = \frac{\partial J_P(a)}{\partial a} = \sum_{y \in Y_e} (-y) \quad \longleftarrow$$

$$J_P(a) = \sum_{y \in Y_e} (-a^T y)$$

ρ_k 是正的比例因子，可根据迭代次数调整，代表步长



2.4 感知准则

5、梯度下降法求解极值

➤ 梯度下降法的应用

$$\mathbf{a}_{k+1} = \mathbf{a}_k - \rho_k \frac{\nabla J_P(\mathbf{a})}{\|\nabla J_P(\mathbf{a})\|}$$

该迭代公式可以使 $\mathbf{a}$ 在函数 $J_P(\mathbf{a})$ 的负梯度方向上迅速收敛于最优解 $\mathbf{a}^*$ 。其中， ρ 是一个正的比例因子。

更一般地，在应用该方法时，需要先确定一个准则函数，然后选择一个初始的 $\mathbf{a}_0$ ，再通过迭代法找到最优解 $\mathbf{a}^*$ 。



2.5 最小错分样本准则

1、线性不可分

➤ 感知准则函数的局限性

感知准则函数只适用于线性可分的情况。对于样本集线性不可分的情况，算法不收敛，即 $a^T y_i > 0$ 或 $y_i^T a > 0 (i = 1, 2, \dots, n)$ 无确定解，是矛盾不等式组，只能求满足不等式个数最多的解，或者最小错分样本数的解。

➤ 最小错分样本数准则

对于线性不可分情况，**定义一个准则函数**，其极值解对应两类样本集中错分数最少的权向量 a^* ，这种准则称为**最小错分样本数准则**。



2.5 最小错分样本准则

2、最小错分样本数准则

➤ 从不等式组角度理解线性分类器

- 假设样本是线性可分的，对于规范化增广样本向量，线性判别函数可写为 $g(y) = a^T y_i$ ，如果存在权向量 a ，使得 $a^T y_i > 0, i = 1, 2, \dots, n$ ，则样本被正确分类。
- 因此，设计线性分类器的任务可以看成是求一组 n 个线性不等式的解的问题：
 - ① 若不等式组有解，说明样本集是线性可分的，那么就可以找到这个解向量 a^* 。
 - ② 若不等式无解，说明样本集是线性不可分的，那么对于任何权向量 a 都有样本被错误分类，这时可以寻找使最多样本数目的不等式得到满足的权向量 a ，并把它作为最小错分样本数的解 a^* 。



2.5 最小错分样本准则

2、最小错分样本数准则

➤ 从不等式组角度理解线性分类器

将n个不等式 $a^T y_i > 0, i = 1, 2, \dots, n$ 联立并引入余量 $b = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$

其中 $b_i > 0, i = 1, 2, \dots, n$, 得

$$Ya - b > 0$$

式中

$$Y = \begin{bmatrix} y_1^T \\ y_2^T \\ \vdots \\ y_n^T \end{bmatrix} = \begin{bmatrix} y_{11} & y_{12} & \cdots & y_{1,d+1} \\ y_{21} & y_{22} & \cdots & y_{2,d+1} \\ \cdots & \cdots & \cdots & \cdots \\ y_{n1} & y_{n2} & \cdots & y_{n,d+1} \end{bmatrix}$$

y 是增广向量，假设样本 x 的特征有 d 维，则增广向量 $d+1$ 维

b 是一个 n 维向量，可以取值为 $b = [1, 1, \dots, 1]^T$



2.5 最小错分样本准则

2、最小错分样本数准则函数的两种定义形式

➤ 最小错分样本准则1

$$J_{q_1}(a) = \|(Ya - b) - |Ya - b|\|^2 \geq 0$$

- ① 如果 $Ya > b$ ，即样本被正确分类，则 $(Ya - b)$ 与 $|Ya - b|$ 同号，所以 $J_{q_1}(a) = 0$ ；
- ② 如果有样本不满足 $Ya > b$ ，样本被错分，则 $(Ya - b)$ 与 $|Ya - b|$ 异号，有 $J_{q_1}(a) > 0$ 。

不满足的样本（即错分的样本）越多， $J_{q_1}(a)$ 越大。 $J_{q_1}(a)$ 取极小值时的权向量 a 就是最优解 a^* 。



2.5 最小错分样本准则

2、最小错分样本数准则函数的两种定义形式

➤ 最小错分样本准则2

$$J_{q_2}(\mathbf{a}) = \sum_{i=1}^N \frac{1 - \text{sign}(\mathbf{y}_i^T \mathbf{a})}{2}, \text{ 其中, } \text{sign}(\mathbf{y}_i \cdot \mathbf{a}) = \begin{cases} +1 & \mathbf{y}_i^T \cdot \mathbf{a} \geq 0 \\ -1 & \mathbf{y}_i^T \cdot \mathbf{a} < 0 \end{cases}$$

- ① 如果 $\mathbf{y}_i^T \mathbf{a} > b$, 样本被正确分类, 有 $\text{sign}(\mathbf{y}_i \cdot \mathbf{a}) = +1$;
- ② 如果有样本不满足 $\mathbf{y}_i^T \mathbf{a} > b$, 即样本被错分, 则 $\text{sign}(\mathbf{y}_i \cdot \mathbf{a}) = -1$ 。

不满足的样本（即错分的样本）越多，则 $J_{q_1}(\mathbf{a})$ 就越大。显然 $J_{q_1}(\mathbf{a})$ 取极小值时的权向量 $\mathbf{a}$ 就为最优解 $\mathbf{a}^*$ 。

最小错分样本数准则的寻优同样可以采用梯度下降法等优化算法求解。



2.6 最小平方误差准则

1、最小平方误差准则的定义与适用范围

➤ 最小平方误差准则的定义

对于线性不可分情况，定义一个准则函数，其极值解对应两类样本集中错分误差平方和最小的权向量 a^* ，这种准则称为最小平方误差准则。

➤ 最小平方误差准则的适用范围

最小平方误差准则与最小错分样本准则相同，都可以用于样本线性可分和线性不可分的情况。但最小平方误差准则的极值解对应两类样本集中错分误差平方和最小的权向量 a^* ，是工程中常用的优化准则。



2.6 最小平方误差准则

2、最小平方误差准则

➤ 最小平方误差准则的求解

- n 个样本，定义一个 n 维向量 $b = [b_1, b_2, \dots, b_n]^T$ ，其中 b_i 为小的正数，则需要寻找一个权向量 a ，使之满足： $y_i^T \cdot a = b_i > 0, i = 1, 2, \dots, n$ 。
- 联立线性方程组，并简写为矩阵形式： $Y \cdot a = b$ 。式中， Y 为训练样本的增广矩阵，即

$$Y = \begin{pmatrix} y_1^T \\ y_2^T \\ \vdots \\ y_n^T \end{pmatrix} = \begin{pmatrix} y_{11} & y_{12} & \cdots & y_{1,d+1} \\ \vdots & & & \\ y_{n_1 1} & y_{n_1 2} & \cdots & y_{n_1, d+1} \\ y_{(n_1+1)1} & y_{(n_1+1)2} & \cdots & y_{(n_1+1), d+1} \\ \vdots & & & \\ y_{n_1+n_2, 1} & y_{n_1+n_2, 2} & \cdots & y_{n_1+n_2, d+1} \end{pmatrix}$$

b 为 n 维列向量； a 为 $d+1$ 维列向量，设 ω_i 和 ω_j 的样本数分别为 n_1 和 n_2 ，且样本总数 $n = n_1 + n_2$ ， Y 为 $n \times (d+1)$ 维矩阵，一般 $n > d+1$ ，此时 $Y \cdot a = b$ 是矛盾线性方程组，可以采用最小二乘法来求解。



2.6 最小平方误差准则

2、最小平方误差准则

➤ 最小平方误差准则的求解

先定义误差： $e = Y \cdot a - b$ ，则平方误差准则函数为：

$$J_s(a) = \|e\|^2 = \|Y \cdot a - b\|^2 = \sum_{i=1}^n (a^T \cdot y_i - b_i)^2$$

由

$$\frac{\partial J_s(a)}{\partial a} = \sum_{i=1}^N 2(a^T \cdot y_i - b_i) \cdot y_i = 2Y^T \cdot (Y \cdot a - b) = 0$$

可以得到极值，此时最优权向量为：

$$a^* = (Y^T Y)^{-1} Y^T b$$

需要说明， a^* 依赖于余量 b 的选择，确定余量 b 之后可以得到最终的解。



2.6 最小平方误差准则

3、最小平方误差准则的应用

➤ **例5** 已知两类分类问题，两类的训练样本分别为： ω_1 类样本 $\begin{bmatrix} 0 \\ 0 \end{bmatrix}$, $\begin{bmatrix} 0 \\ 2 \end{bmatrix}$ 和 ω_2 类样本 $\begin{bmatrix} 2 \\ 0 \end{bmatrix}$, $\begin{bmatrix} 2 \\ 2 \end{bmatrix}$ ，试求最小平方误差准则解。

① 训练样本的增广矩阵为：

$$Y = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 2 & 1 \\ -2 & 0 & -1 \\ -2 & -2 & -1 \end{bmatrix}$$

② 求X 的伪逆矩阵为：

$$Y^\# = (Y^T Y)^{-1} Y^T = \begin{bmatrix} \frac{1}{4} & -\frac{1}{4} & -\frac{1}{4} & -\frac{1}{4} \\ -\frac{1}{4} & \frac{1}{4} & \frac{1}{4} & -\frac{1}{4} \\ \frac{3}{4} & \frac{1}{4} & -\frac{1}{4} & \frac{1}{4} \end{bmatrix}$$



2.6 最小平方误差准则

3、最小平方误差准则的应用

➤ **例5** 已知两类分类问题，两类的训练样本分别为： ω_1 类样本 $\begin{bmatrix} 0 \\ 0 \end{bmatrix}$, $\begin{bmatrix} 0 \\ 2 \end{bmatrix}$ 和 ω_2 类样本 $\begin{bmatrix} 2 \\ 0 \end{bmatrix}$, $\begin{bmatrix} 2 \\ 2 \end{bmatrix}$ ，试求最小平方误差准则解。

③ 设 $c=1$, $b(1) = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}$, 则 $a(1) = Y^\# b(1) = \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}$

④ 误差向量 $e_1 = Y \cdot a(1) - b(1) = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}$

⑤ 而 e_1 的各分量均为0，则 $a(1)$ 就是所求的解向量 $a^* = \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}$ ，因此决策面方程为：
$$-x_1 + 1 = 0$$



作业

1. 已知A类: $[0, 3]^T, [2, 4]^T, [1, 3]^T, [2, 3]^T, [0, 2]^T$, B类: $[4, 1]^T, [3, 2]^T, [2, 1]^T, [3, 0]^T, [3, 1]^T$, 待分类样本为 $x = [5, 0]^T$, 使用垂直平分分类器对其进行决策。

2. 已知两类样本集:

$$x_1^1 = [0, 0]^T, x_1^2 = [1, 2]^T$$

$$x_2^1 = [1, -1]^T, x_2^2 = [3, 0]^T$$

请使用Fisher投影准则给出最佳投影方向。



北京航空航天大学
BEIHANG UNIVERSITY

德才兼备 知行合一

The end