

北京航空航天大学
BEIHANG UNIVERSITY

模式识别

第三章 贝叶斯分类器

北京航空航天大学宇航学院



主要内容

3.1 贝叶斯决策概述

3.2 最小错误率贝叶斯决策

3.3 最小风险贝叶斯决策

3.4 最小最大贝叶斯决策

3.5 正态分布时的统计决策


3.6 分类器的错误率

3.7 朴素贝叶斯分类器与贝叶斯网络



3 贝叶斯分类器

- 概率统计是现实中应用广泛的数学模型，从概率角度探讨模式识别问题
- 把类别看作随机事件，把描述样本的特征看作随机向量，在给定观测到的样本特征向量的条件下，计算某类随机事件发生的概率
- 根据概率值，对样本的类别进行判断。哪类事件发生的概率高就判别为哪类，分类结果达到概率意义上的最优。





3.1 贝叶斯决策概述

3.1.1 统计分类

3.1.2 先决条件

3.1.3 贝叶斯决策

3.1.4 错误率概念



3.1 贝叶斯决策概述

1、统计分类

➤ 确定性事件

- 确定性的事物或现象在一定条件下**必然会发生或不发生**

➤ 随机性事件

- 随机性的事物或现象有很多可能性，按照一定的概率和统计规律，或者发生或者不发生，在事先不能预知会出现哪种结果



3.1 贝叶斯决策概述

1、统计分类

➤ 线性分类器与贝叶斯分类器

- 提取到的模式**样本特征向量**可以理解为确定性的向量，也可以理解为随机向量，随机向量的分量是随机变量。
- **在线性分类方法中**，通常假设模式样本是确定性的，在此基础上优化设计分类器。
- 假设模式样本都是随机性的，特征向量也是随机的，依据类的先验概率和分布密度函数，使分类结果从概率统计上讲是最佳的，这就是概率统计方法中的贝叶斯决策，即**贝叶斯分类器**。



3.1 贝叶斯决策概述

2、先决条件

➤ 用贝叶斯决策方法进行分类，应满足的已知条件：

- ① 各个模式的类别和类别数；
- ① 各个模式类别（总体）的先验概率；
- ② 各个模式类别（总体）的概率分布。

➤ 相关概念

- 假设待识别的样本有 d 种特征观察值 $x_1, x_2, \dots, x_d$ ，构成 d 维随机特征向量： $x = [x_1 \cdot x_2 \cdots x_d]^T$ 。
- $P(\omega_i)$ 表示 ω_i 类出现的概率，称为**先验概率**。
- $P(x|\omega_i)$ 表示在 ω_i 类的先验概率后验概率条件下 x 的概率，即 ω_i 类样本的概率分布密度（函数），称为**类条件概率密度**。
- 条件概率 $P(\omega_i|x)$ 表示 x 出现的条件下 ω_i 类出现的概率，称为**后验概率**。
- 贝叶斯决策采用后验概率进行分类判别，而后验概率的计算则运用贝叶斯公式。



3.1 贝叶斯决策概述

3、贝叶斯决策

➤ 贝叶斯决策的两种策略

- 在现实任务中，后验概率 $P(\omega_i|x)$ 往往难以直接获得。从这个角度来看，所要实现的是基于有限的训练样本集尽可能准确地估计出后验概率。
- 主要有两种策略：
 - ① 给定 x 可以直接建模 $P(\omega_i|x)$ 来预测 ω_i ，这样得到的是“**判别式模型**”。
 - ② 先对联合概率分布 $P(x, \omega_i)$ 建模，之后由此获得 $P(\omega_i|x)$ ，这样得到的是“**生成式模型**”。



3.1 贝叶斯决策概述

3、贝叶斯决策

➤ 生成式模型

对于“生成式模型”：

$$P(\omega_i|\mathbf{x}) = \frac{P(\mathbf{x}, \omega_i)}{P(\mathbf{x})}$$

根据贝叶斯公式，可以写成为：

$$P(\omega_i|\mathbf{x}) = \frac{P(\omega_i)P(\mathbf{x}|\omega_i)}{P(\mathbf{x})}$$

$P(\mathbf{x}|\omega_i)$ 是样本相对类条件的条件概率，称为“似然”， $P(\mathbf{x})$ 是用于归一化的因子，与类别无关。因此估计 $P(\omega_i|\mathbf{x})$ 的问题就变成了如何基于训练数据来估计先验 $P(\omega_i)$ 和似然 $P(\mathbf{x}|\omega_i)$ 。




3.1 贝叶斯决策概述

4、错误率概念

➤ 错误率

- 几乎所有的分类器在识别时都有可能出现错误分类的情况，这种错误分类的可能性称为分类器识别结果的错误概率，简称错误率。
- 对比之前所学的线性分类器，贝叶斯分类器设计的先决条件更为全面，其结果是概率意义上的最小错误率的分类器，从而实现分类器设计的概率最优解。





3.2 最小错误率贝叶斯决策

1、最小错误率贝叶斯决策的由来

- 无论基于何种决策规则，把待识别的模式对象判别为某类，**错误判别难免会发生**，就是说在用统计准则对某一具体的模式进行分类时，判别结果可能是错误的。
- 在实际分类时，人们希望**尽量减少分类的错误**，从这样的要求出发，可以利用概率论的贝叶斯公式，得出使错误率为最小的分类规则，即**最小错误率贝叶斯决策**。




3.2 最小错误率贝叶斯决策

2、贝叶斯决策可以使得分类的错误率最小

➤ 两类一维问题

- 统计判决的基本方法是根据类的概率和概率密度将模式的特征空间 R 划分成两个子区域 R_1 和 R_2 ，显然 $R_1 \cup R_2 = R, R_1 \cap R_2 = \emptyset$ 。
- 当 $x \in R_1$ 时，判别 $x \in \omega_1$ ；
- 当 $x \in R_2$ 时，判别 $x \in \omega_2$ 。



一维情况下的错误率计算示意图



3.2 最小错误率贝叶斯决策

2、贝叶斯决策可以使得分类的错误率最小

➤ 两类一维问题中可能出现的两种错误

- ① 一种错误是把实际是 ω_1 类的模式误判为 ω_2 类，发生这种错误的原因是属于 ω_1 类的模式分布在特征空间中 R_2 域，从而被误判为 ω_2 类，这时的误判概率为：

$$e_{12} = \int_{R_2} p(x | \omega_1) dx$$

- ② 另一种错误是把实际上是 ω_2 类的模式误判为 ω_1 类，此时的误判概率为：

$$e_{21} = \int_{R_1} p(x | \omega_2) dx$$

- ③ 设 ω_1 和 ω_2 类发生的概率分别为 $P(\omega_1)$ 和 $P(\omega_2)$ ， 则总的误判概率 $P(\omega_e)$ 为：

$$P(e) = P(\omega_1)e_{12} + P(\omega_2)e_{21} = P(\omega_1) \int_{R_2} p(x | \omega_1) dx + P(\omega_2) \int_{R_1} p(x | \omega_2) dx$$



3.2 最小错误率贝叶斯决策

2、贝叶斯决策可以使得分类的错误率最小

➤ 正确率的计算

希望在总体上误判最小，因此所取的判决准则是使误判概率最小，这等价于使正确分类识别的概率即正确率 $P(c)$ 最大，正确率的计算公式为：

$$P(c) = P(\omega_1) \int_{R_1} p(x | \omega_1) dx + P(\omega_2) \int_{R_2} p(x | \omega_2) dx \quad (1)$$

并且

$$\int_{R_2} P(\omega_2) p(x | \omega_2) dx = P(\omega_2) - \int_{R_1} P(\omega_2) p(x | \omega_2) dx \quad (2)$$

将式 (2) 代入式 (1) 得：

$$P(c) = P(\omega_2) + \int_{R_1} [P(\omega_1) p(x | \omega_1) - P(\omega_2) p(x | \omega_2)] dx \quad (3)$$



3.2 最小错误率贝叶斯决策

2、贝叶斯决策可以使得分类的错误率最小

➤ 两类的决策域

$$P(c) = P(\omega_2) + \int_{R_1} [P(\omega_1)p(x|\omega_1) - P(\omega_2)p(x|\omega_2)]dx \quad (3)$$

式 (3) 中, R_1 是未知的, 难以直接求解。根据上式, 为使 $P(c)$ 达到最大, ω_1 的决策域 R_1^* 应是 R 中所有满足条件, 即式 (4) 的样本点组成的集合。

$$P(\omega_1)p(x|\omega_1) > P(\omega_2)p(x|\omega_2) \quad (4)$$

同理 R_2^* 应是 R 中所有满足条件, 即式 (5) 的样本点组成的集合。

$$P(\omega_1)p(x|\omega_1) < P(\omega_2)p(x|\omega_2) \quad (5)$$

任何别的划分所对应的正确率 $P(c)$ 都将小于上述划分时的正确率。



3.2 最小错误率贝叶斯决策

3、最小错误率的贝叶斯决策的判别规则及其等价规则：

➤ 判别规则及等价规则

对于未知 x ：

- ① 如果 $P(\omega_1|x) > P(\omega_2|x)$ ，则 $x \in \omega_1$ ；反之， $x \in \omega_2$ 。
- ② 如果 $p(x|\omega_1)P(\omega_1) > p(x|\omega_2)P(\omega_2)$ ，则 $x \in \omega_1$ ；反之， $x \in \omega_2$ 。
- ③ 如果 $\frac{p(x|\omega_1)}{p(x|\omega_2)} > \frac{P(\omega_2)}{P(\omega_1)}$ ，则 $x \in \omega_1$ ；反之， $x \in \omega_2$ 。
- ④ 如果 $h(x) = -\ln \left[\frac{p(x|\omega_1)}{p(x|\omega_2)} \right] = -\ln p(x|\omega_1) + \ln p(x|\omega_2) < \ln \frac{P(\omega_1)}{P(\omega_2)}$ ，则 $x \in \omega_1$ ；反之， $x \in \omega_2$ 。

其中， $P(\omega_i|x) = \frac{p(x|\omega_i)}{P(x)} P(\omega_i)$ ， $P(x) = \sum_{i=1}^2 P(x|\omega_i)P(\omega_i)$ 。



3.2 最小错误率贝叶斯决策

4、最小错误率贝叶斯决策例题

➤ **例1：**假设在卫星识别任务中两类卫星分别记为 ω_1 、 ω_2 ，先验概率分别为： $P(\omega_1) = 0.6$ ， $P(\omega_2) = 0.4$ 。现有某一待识别的卫星，类条件概率密度分别为： $P(x|\omega_1) = 0.4$ ， $P(x|\omega_2) = 0.3$ 。使用最小错误率贝叶斯决策对该卫星进行分类。

将数据代入贝叶斯公式得到后验概率为：

$$P(\omega_1 | x) = \frac{P(x | \omega_1)}{P(x)} P(\omega_1) = \frac{0.4 \times 0.6}{0.4 \times 0.6 + 0.3 \times 0.4} = \frac{2}{3}$$

由最小错误率贝叶斯决策规则（1）有：

$$\begin{aligned} P(\omega_2 | x) &= 1 - P(\omega_1 | x) = \frac{1}{3} \\ P(\omega_1 | x) &= \frac{2}{3} > P(\omega_2 | x) = \frac{1}{3} \end{aligned}$$

所以把待识别的卫星 x 归类为 ω_1 类。



3.3 最小风险贝叶斯决策

1、最小风险贝叶斯决策的由来

对于随机模式，由于是根据类的概率和概率密度进行分类识别判断，虽然达到了最小错误率，但是误判总是存在的。在实际应用中，不同的误判导致的后果或代价是不同的。

以癌细胞图像识别为例

- 把正常细胞误判为癌细胞会给病人及其家属带来精神上的巨大负担
- 癌细胞误判为正常细胞，可能导致最佳医治时机的错失，甚至造成病患无法医治的后果，损失更大

最小风险贝叶斯决策：基于各种误判造成损失不同而提出的一种决策规则。



3.3 最小风险贝叶斯决策

2、最小风险贝叶斯决策

➤ 损失函数

设模式空间中存在 c 个类别： $\omega_1, \omega_2, \dots, \omega_c$ ，决策空间由 a 个决策组成：

$\alpha_1, \alpha_2, \dots, \alpha_a$ 。其中 α_i 是将未知模式判别为 ω_j 类的决策，或者是拒绝判别的决策。

如果决策和类别一一对应， a 等于 c ，否则 a 可以大于 c 或小于 c 。对一个实际是 ω_j

类的模式采用了决策 α_i 所造成的损失称为损失函数，记为 $\lambda(\alpha_i, \omega_j) = \lambda_{ij}$ 。



3.3 最小风险贝叶斯决策

2、最小风险贝叶斯决策

➤ 损失函数与决策表

将损失函数以决策表的形式列出：

决策	不同类别的损失函数			
	ω_1	ω_2	...	ω_c
α_1	$\lambda(\alpha_1, \omega_1)$	$\lambda(\alpha_1, \omega_2)$	...	$\lambda(\alpha_1, \omega_c)$
α_2	$\lambda(\alpha_2, \omega_1)$	$\lambda(\alpha_2, \omega_2)$	...	$\lambda(\alpha_2, \omega_c)$
...	...	...	...	...
α_a	$\lambda(\alpha_a, \omega_1)$	$\lambda(\alpha_a, \omega_2)$	...	$\lambda(\alpha_a, \omega_c)$



3.3 最小风险贝叶斯决策

2、最小风险贝叶斯决策

➤ 条件期望损失

对于给定的 x ，如果采取决策 α_i ，对应于决策 α_i ， λ 可以在 c 个 $\lambda(\alpha_i, \omega_j) (j = 1, \dots, c)$ 值中任取一个，其相应概率为 $P(\omega_j|x)$ 。因此在采取决策 α_i 情况下的条件期望损失 $R(\alpha_i|x)$ 为：

$$R(\alpha_i|x) = E[\lambda(\alpha_i, \omega_j)|x] = \sum_{j=1}^c \lambda(\alpha_i, \omega_j)P(\omega_j|x), i = 1, 2, \dots, a$$

这里 E 函数是相对各类求全期望。上式是判别 x 属于 ω_i 类时，相应于决策 α_i 的各损失函数以各类后验概率为权重的加权和。

条件期望损失 $R(\alpha_i|x)$ 刻画了未知模式为 x 、决策为 α_i 条件下的平均损失，故也称为**条件平均损失或条件平均风险**。



3.3 最小风险贝叶斯决策

2、最小风险贝叶斯决策

➤ 条件期望损失

设特征空间 R 中判决域为 $R_i (i = 1, 2, \dots, c)$ ，于是求得 $R(\alpha_i|x)$ 关于 x 的数学期望为：

$$R = \sum_{i=1}^c \int_{R_i} R(\alpha_i|x) p(x) dx$$

R 是损失函数 $\lambda_{ij} = \lambda(\alpha_i, \omega_j)$ 关于各类及 x 的数学期望，称为平均风险。

决策规则： 如果 $R(\alpha_j|x) = \min[R(\alpha_i|x)]$ ，则 $\alpha = \alpha_j$ 。



3.3 最小风险贝叶斯决策

2、最小风险贝叶斯决策

➤ 最小风险贝叶斯决策解决实际问题步骤

最小风险贝叶斯决策解决实际问题的步骤如下：

① 在已知 $P(\omega_i), p(x|\omega_j) (j = 1, 2, \dots, c)$ ，及给出待识别的样本 x 的情况下，根据贝叶斯公式计算出后验概率：

$$P(\omega_j|x) = \frac{p(x|\omega_j)P(\omega_j)}{\sum_{j=1}^c p(x|\omega_j)P(\omega_j)}, j = 1, 2, \dots, c$$

② 利用计算得到的后验概率及决策表，计算出采取 $\alpha_i (i = 1, 2, \dots, c)$ 决策时的条件损失：

$$R(\alpha_i|x) = \sum_{j=1}^c \lambda(\alpha_i, \omega_j) P(\omega_j|x), i = 1, 2, \dots, a$$

③ 对②中得到的所有条件风险值进行比较，找出使得条件风险最小的决策 α_k ，则 α_k 就是最小风险贝叶斯决策。



3.3 最小风险贝叶斯决策

3、最小风险贝叶斯决策例题

➤ **例2：**在例1的已知条件的基础上，设 $\lambda_{11} = 0$, $\lambda_{21} = 7$, $\lambda_{12} = 1$, $\lambda_{22} = 0$ ，试以最小风险贝叶斯决策进行分类。

根据前面的计算可得到后验概率为： $P(\omega_1|\mathbf{x}) = \frac{2}{3}$, $P(\omega_2|\mathbf{x}) = \frac{1}{3}$

根据最小风险贝叶斯公式得出条件风险为：

$$R_1(\mathbf{x}) = \sum_{i=1}^2 \lambda_{i1} P(\omega_i|\mathbf{x}) = \lambda_{12} P(\omega_2|\mathbf{x}) = 6 \times \frac{1}{3} = 2$$

$$R_2(\mathbf{x}) = \sum_{i=1}^2 \lambda_{i2} P(\omega_i|\mathbf{x}) = \lambda_{21} P(\omega_1|\mathbf{x}) = 1 \times \frac{2}{3} = \frac{2}{3}$$

由于 $R_1(\mathbf{x}) > R_2(\mathbf{x})$ ，因此应 $\mathbf{x}$ 归类为 ω_2 类。本例的判别结果和最小错误率方法恰好相反，因为“损失函数”在判别决策中起了主导作用。



3.3 最小风险贝叶斯决策

4、最小风险贝叶斯决策与最小错误率的贝叶斯决策的关系。

➤ 0-1损失情况下，二者等价

对于最小风险的贝叶斯决策，当出现0-1损失函数的情况，即

$$\lambda(\alpha_i, \omega_j) = \begin{cases} 0, & i = j \\ 1, & i \neq j \end{cases}, \text{ 其中 } i, j = 1, 2, \dots, c,$$

其中, $i, j = 1, 2, \dots, c$ 。即假定当作出决策正确时，没有任何损失；而当做出错误决策时，损失都是1。这时条件风险为：

$$R(\alpha_i | \mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i, \omega_j) P(\omega_j | \mathbf{x}) = \sum_{\substack{j=1 \\ j \neq i}}^c P(\omega_j | \mathbf{x}) = 1 - P(\omega_i | \mathbf{x})$$

其中 $P(\omega_i | \mathbf{x})$ 为采取决策 α_i 正确时的条件概率。显然这时的最小风险贝叶斯决策规则就等价于选取后验概率 $P(\omega_i | \mathbf{x})$ 为最大的决策规则，而这正是最小错误率的贝叶斯决策规则。



3.3 最小风险贝叶斯决策

4、最小风险贝叶斯决策与最小错误率的贝叶斯决策的关系。

➤ 0-1损失情况下，二者等价

$$R(\alpha_i|\mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i, \omega_j) P(\omega_j|\mathbf{x}) = \sum_{\substack{j=1 \\ j \neq i}}^c P(\omega_j|\mathbf{x}) = 1 - P(\omega_i|\mathbf{x})$$

由此可知，在0-1损失函数的情况下，最小风险贝叶斯决策和最小错误率贝叶斯决策的结果是完全相同的，换句话说就是：最小错误率贝叶斯决策就是在0-1损失函数条件下的最小风险贝叶斯决策，是最小风险贝叶斯决策的特例。



3.4 最小最大贝叶斯决策

1、最小最大贝叶斯决策的由来

最小错误率贝叶斯决策和最小风险贝叶斯决策，主要是针对确定的先验概率等条件下的最佳决策。

然而在实际应用中，各类的先验概率有时不能精确确定，或在分析过程中各类的先验概率是变动的，并且在最小风险贝叶斯决策中还需要确定决策的风险。

此时，若再用固定先验概率条件下的某个最小风险贝叶斯分类器来进行决策，其结果实际上并非是最小风险的。

就是在各类的先验概率变化的情况下，取最大风险为最小的某个最小风险贝叶斯分类器，作为实际使用的分类器。



3.4 最小最大贝叶斯决策

2、最小最大贝叶斯决策

➤ 最小最大贝叶斯决策的定义

对于两类问题，设某个最小风险贝叶斯分类器将特征空间 R 划分为两个子区域 R_1 和 R_2 ，记 λ_{ij} 为将实属 ω_j 类的模式判为 ω_i 的损失函数，则误判的平均风险为：

$$\begin{aligned} R &= \int_{\mathfrak{R}} R(\alpha(\mathbf{x})|\mathbf{x}) p(\mathbf{x}) d\mathbf{x} \\ &= \int_{\mathfrak{R}_1} R(\alpha_1(\mathbf{x})|\mathbf{x}) p(\mathbf{x}) d\mathbf{x} + \int_{\mathfrak{R}_2} R(\alpha_2(\mathbf{x})|\mathbf{x}) p(\mathbf{x}) d\mathbf{x} \\ &= \int_{\mathfrak{R}_1} \sum_{i=1}^2 \lambda_{i1} p(\mathbf{x}|\omega_i) P(\omega_i) d\mathbf{x} + \int_{\mathfrak{R}_2} \sum_{i=1}^2 \lambda_{i2} p(\mathbf{x}|\omega_i) P(\omega_i) d\mathbf{x} \\ &= \lambda_{11} P(\omega_1) \int_{\mathfrak{R}_1} p(\mathbf{x}|\omega_1) d\mathbf{x} + \lambda_{21} P(\omega_2) \int_{\mathfrak{R}_1} p(\mathbf{x}|\omega_2) d\mathbf{x} \\ &\quad + \lambda_{12} P(\omega_1) \int_{\mathfrak{R}_2} p(\mathbf{x}|\omega_1) d\mathbf{x} + \lambda_{22} P(\omega_2) \int_{\mathfrak{R}_2} p(\mathbf{x}|\omega_2) d\mathbf{x} \end{aligned}$$



3.4 最小最大贝叶斯决策

2、最小最大贝叶斯决策

➤ 最小最大贝叶斯决策的定义

再利用条件

$$P(\omega_1) + P(\omega_2) = 1$$

$$\int_{\mathfrak{R}_1} p(\mathbf{x}|\omega_1) d\mathbf{x} + \int_{\mathfrak{R}_2} p(\mathbf{x}|\omega_1) d\mathbf{x} = 1$$

则误判平均风险可化简为：

$$\begin{aligned} R = & \lambda_{22} + (\lambda_{21} - \lambda_{22}) \int_{\mathfrak{R}_1} p(\mathbf{x}|\omega_2) d\mathbf{x} + P(\omega_1)[(\lambda_{11} - \lambda_{22}) \\ & + (\lambda_{12} - \lambda_{11}) \int_{\mathfrak{R}_2} p(\mathbf{x}|\omega_1) d\mathbf{x} + (\lambda_{22} - \lambda_{21}) \int_{\mathfrak{R}_1} p(\mathbf{x}|\omega_2) d\mathbf{x}] \end{aligned}$$

式中，一旦 R_1 和 R_2 被确定，误判平均风险 R 就是先验概率 $P(\omega_1)$ 的线性函数。即

$R \triangleq a + bP(\omega_1)$ ，此时不难求出误判平均风险的上下界（最大损失和最小损失）。





3.4 最小最大贝叶斯决策

2、最小最大贝叶斯决策

➤ 最小最大贝叶斯决策的定义

设 $P(\omega_1)$ 在区间 $[0, 1]$ 中取不同的值，按最小风险贝叶斯决策设计相应的最佳决策域 R_1 和 R_2 ，计算相应的最小风险 R^* ，得到最小风险 R^* 与先验概率 $P(\omega_1)$ 的关系曲线，如图所示。





3.4 最小最大贝叶斯决策


2、最小最大贝叶斯决策

➤ 最小最大贝叶斯决策的定义

- 曲线上A点的切线CD对应 $R \triangleq a + bP(\omega_1)$ ，直线上各点的纵坐标值是固定 $P_A(\omega_1)$ 值下最小风险贝叶斯决策域，该决策域应用于变化的 $P(\omega_1)$ 值情况的误判平均风险值。直线上的误判平均风险大于曲线上的最小误判平均风险。
- 因为 $P(\omega_1)$ 在0和1之间，平均损失值 $a \leq R \leq a + b$ ，可求出该直线最大的误判平均风险值，且极值情况是最小风险贝叶斯决策域 R_1 和 R_2 能使 $R \triangleq a + bP(\omega_1)$ 中的 $b = 0$ ，即

$$b = (\lambda_{11} - \lambda_{22}) + (\lambda_{12} - \lambda_{11}) \int_{\mathfrak{R}_2} p(x|\omega_1)dx + (\lambda_{22} - \lambda_{21}) \int_{\mathfrak{R}_1} p(x|\omega_2)dx = 0$$

- 此时无论 $P(\omega_1)$ 如何变化， R 与 $P(\omega_1)$ 无关，使得平均损失 R 恒等于常数 a ，最大的误判平均风险值是所有最小风险贝叶斯决策中最小的，称为**最小最大风险决策**。





3.4 最小最大贝叶斯决策

2、最小最大贝叶斯决策

➤ 最小最大贝叶斯决策的定义

【结论】 在进行最小风险贝叶斯决策时，若考虑先验概率 $P(\omega_1)$ 有可能改变，或先验概率未知的情况，则应选择使最小贝叶斯风险 R^* 为最大值时的 $P^*(\omega_1)$ 来设计分类器，其风险 R_B^* 相应于其他的 $P(\omega_1)$ 为最大，而能保证在不管 $P(\omega_1)$ 如何变化时，使最大风险为最小，这样的决策称为**最小最大决策**。





3.4 最小最大贝叶斯决策

2、最小最大贝叶斯决策

➤ 最小最大贝叶斯决策的设计过程

- ① 依据最小风险贝叶斯决策求出对应于 $[0, 1]$ 中的各个不同 $P(\omega_1)$ 值的决策域 R_1 和 R_2 ，计算相应决策域的最小平均风险，并最终得到 $R^* - P(\omega_1)$ 曲线；
- ② 求最小最大决策的极值解，即图中曲线的定点（ $b = 0$ 的情况），此时的最小风险贝叶斯决策域就是最小最大决策的决策域，其最大风险控制为最小，适用于先验概率变化的情况。





3.5 正态分布时的统计决策

3.5.1 正态分布

3.5.2 多元正态分布下的最小错误率贝叶斯决策



3.5 正态分布时的统计决策

1、正态分布假设

正态分布假设是工程应用中最普遍的假设，原因如下：

- ①正态分布在数学上比较简单，便于进行分析；**
- ②正态分布在物理上经常是总体分布的合理近似。**

因此，在对正态分布的基本概念和重要性质进行综述的基础上，重点讨论正态分布概率模型的最小错误率贝叶斯决策。



3.5 正态分布时的统计决策

1、正态分布


➤ 单变量正态分布

【单变量概率密度函数】 定义为:

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right]$$

式中, μ 为随机变量 x 的均值; σ^2 为 x 的方差; σ 为标准差。

- $p(x)$ 由两个参数 μ 和 σ^2 来确定, 记为: $p(x) \sim N(\mu, \sigma^2)$
- 正态分布的样本主要集中分布在均值附近, 其分散程度可以用标准差 σ 来衡量, σ 越大表示分散程度也越大
- 从总体抽取样本, 约有95%的样本落在区间 $(\mu - 2\sigma, \mu + 2\sigma)$ 内, 其峰值为 $p(\mu) = \frac{1}{\sqrt{2\pi}\sigma}$





3.5 正态分布时的统计决策

1、正态分布

➤ 多元正态分布

[多元正态分布的概率密度函数]定义为：

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right]$$

式中： $\mathbf{x} = (x_1, x_2, \dots, x_d)^T$ 是 d 维列向量； $\boldsymbol{\mu} = E[\mathbf{x}] = (\mu_1, \mu_2, \dots, \mu_d)^T$ 是 d 维均值向量；

$\Sigma = E[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T] = [\sigma_{ij}^2]_{d \times d}$ 是 $d \times d$ 维的协方差矩阵。



3.5 正态分布时的统计决策

1、正态分布

➤ 多元正态分布

协方差矩阵 Σ 是半正定对称矩阵，表示为：

$$\Sigma = \begin{bmatrix} \sigma^2_{11} & \sigma^2_{12} & \dots & \dots & \sigma^2_{1d} \\ \sigma^2_{12} & \sigma^2_{22} & \dots & \dots & \sigma^2_{2d} \\ . & . & . & . & . \\ . & . & . & . & . \\ \sigma^2_{1d} & \sigma^2_{2d} & \dots & \dots & \sigma^2_{dd} \end{bmatrix}$$

- 限定 Σ 是正定的，使得 $|\Sigma|$ 是一个正数，对角线上的元素 σ^2_{ii} 为相应的 x_i 的方差，非对角线上元素 σ^2_{ij} 为 x_i 和 x_j 的协方差。
- 如果 x_i 和 x_j 相互独立，则 $\sigma^2_{ij} = 0$ 。
- 如果所有非对角线上元素 σ^2_{ij} 均为0，则就变成 $p(x)$ 的各分量的单变量正态密度函数的乘积。





3.5 正态分布时的统计决策

1、正态分布

➤ 多元正态分布

如左图所示为一个二维正态密度的示意图，如果把等概率密度点画出来，它们就是一簇同心的椭圆，如右图所示。





3.5 正态分布时的统计决策

1、正态分布

➤ 多元正态分布的性质

- ① 正态分布的不相关性（若随机变量 x_i 和 x_j 满足 $E[x_i x_j] = E[x_i] \cdot E[x_j]$ ，那么这两个随机变量不相关）等价于独立性；
- ② 正态分布的边缘分布仍然是正态分布；
- ③ 正态分布的条件分布仍然是正态分布；
- ④ 正态分布各分量的线性组合仍然是正态分布。



3.5 正态分布时的统计决策

2、多元正态分布下的最小错误率贝叶斯决策

➤ 决策面

已知最小错误率的贝叶斯决策的判别函数为

$$g_i(\mathbf{x}) = p(\mathbf{x}|\omega_i)P(\omega_i), \quad i = 1, 2, \dots, c$$

如果是多元正态分布的概率密度函数，代入上式并取自然对数，**则判别函数可表示为**

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i)$$

决策面方程为

$$g_i(\mathbf{x}) = g_j(\mathbf{x})$$

即

$$-\frac{1}{2}[(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) - (\mathbf{x} - \boldsymbol{\mu}_j)^T \boldsymbol{\Sigma}_j^{-1}(\mathbf{x} - \boldsymbol{\mu}_j)] - \frac{1}{2} \ln \frac{|\boldsymbol{\Sigma}_i|}{|\boldsymbol{\Sigma}_j|} + \ln \frac{P(\omega_i)}{P(\omega_j)} = 0$$



3.5 正态分布时的统计决策

2、多元正态分布下的最小错误率贝叶斯决策

➤ 条件一情况下的决策面

设各类协方差矩阵相同且 $\Sigma_i = \sigma^2 I (i = 1, 2, \dots, C)$

判别函数可简化为:

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) + \ln P(\omega_i)$$

由于 $|\Sigma_i| = \sigma^{2d}$, $\Sigma_i^{-1} = \frac{1}{\sigma^2} I$

所以

$$g_i(\mathbf{x}) = -\frac{1}{2\sigma^2}(\mathbf{x} - \boldsymbol{\mu}_i)^T(\mathbf{x} - \boldsymbol{\mu}_i) + \ln P(\omega_i)$$

其中, $(\mathbf{x} - \boldsymbol{\mu}_i)^T(\mathbf{x} - \boldsymbol{\mu}_i) = \|\mathbf{x} - \boldsymbol{\mu}_i\|^2 = \sum_{j=1}^d (x_{ij} - \mu_{ij})^2$



3.5 正态分布时的统计决策

2、多元正态分布下的最小错误率贝叶斯决策

➤ 条件一情况下的决策面

假设 c 个类的先验概率 $P(\omega_i)$ 都相同， $g_i(x)$ 中 $\ln P(\omega_i)$ 项可以忽略。这时若要对未知样本 c 进行分类，只要计算 x 到各个类均值 μ_i 的欧氏距离 $\|x - \mu_i\|$ ，然后把 x 归到距离最近的类别中即可，说明此时的最小错误率的贝叶斯决策等价于最小距离或垂直平分的线性分类。



3.5 正态分布时的统计决策

2、多元正态分布下的最小错误率贝叶斯决策

➤ 条件一情况下的决策面

- 垂直平分的线性判别函数为：
$$g_i(x) = -\frac{1}{2\sigma^2} (-2\mu_i^T x + \mu_i^T \mu_i) + \ln P(\omega_i) = w_i^T x + w_{i0}$$

其中， $w_i = \frac{1}{\sigma^2} \mu_i$, $w_{i0} = -\frac{1}{\sigma^2} \mu_i^T \mu_i + \ln P(\omega_i)$

- 决策面方程 $g_i(x) = g_j(x)$ 可以化简为：

$$w^T (x - x_0) = 0$$

其中， $x_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{\sigma^2}{\|\mu_i - \mu_j\|^2} \ln \frac{P(\omega_i)}{P(\omega_j)} (\mu_i - \vec{\mu}_j)$, $w = \mu_i - \mu_j$




3.5 正态分布时的统计决策

2、多元正态分布下的最小错误率贝叶斯决策

➤ 条件一情况下的决策面

如图为一个两类二维模式的例子，决策面为通过 x_0 并正交于向量 ω 的超平面。如果 $P(\omega_i) \neq P(\omega_j)$ ，则决策面向先验概率较小的那一类平移。





3.5 正态分布时的统计决策

2、多元正态分布下的最小错误率贝叶斯决策

➤ 条件二情况下的决策面

设各类协方差矩阵相同且 $\Sigma_i = \Sigma$

此时判别函数可表示为：

$$g_i(x) = -\frac{1}{2} (x - \mu_i)^T \Sigma^{-1} (x - \mu_i) + \ln P(\omega_i)$$

如果再假设各类的先验概率相等，则 $\ln P(\omega_i)$ 可以忽略掉。这时决策规则为按

最小马氏距离（Mahalanobis距离）的平方 $(x - \mu_i)^T \Sigma^{-1} (x - \mu_i)$ 进行判别。



3.5 正态分布时的统计决策

2、多元正态分布下的最小错误率贝叶斯决策

➤ 条件二情况下的决策面

对于未知样本 x ，只要计算出它与每一类均值向量 μ_i 之间的马氏距离的平方 $(x - \mu_i)^T \Sigma^{-1}(x - \mu_i)$ ，然后把 x 判别为马氏距离最小的那个类中。

按马氏距离判别仍然是线性的，其判别函数就可以表示成如下形式：

$$g_i(x) = w_i^T x + w_{i0}$$

其中， $w_i = \Sigma^{-1}\mu_i$, $w_{i0} = -\frac{1}{2}\mu_i^T \Sigma^{-1}\mu_i + \ln P(\omega_i)$



3.5 正态分布时的统计决策

2、多元正态分布下的最小错误率贝叶斯决策

➤ 条件二情况下的决策面

显然决策面仍是一个超平面。如果决策域 R_i 和 R_j 相邻，则决策面方程应满足：

$$\mathbf{w}^T (\mathbf{x} - \mathbf{x}_0) = 0$$

其中 $\mathbf{w} = \Sigma^{-1}(\mu_i - \mu_j)$, $\mathbf{x}_0 = \frac{1}{2}(\mu_i + \mu_j) - \frac{1}{(\mu_i - \mu_j)^T \Sigma^{-1} (\mu_i - \mu_j)} \ln \frac{P(\omega_i)}{P(\omega_j)} (\mu_i - \mu_j)$ 。




3.5 正态分布时的统计决策

2、多元正态分布下的最小错误率贝叶斯决策

➤ 条件二情况下的决策面

如果各类的先验概率相等，则决策面过均值向量连线的中点，如图所示。若各类的先验概率不相等，则决策面就朝先验概率较小的那个类平移。





3.6 分类器的错误率

3.6.1 错误率的理论计算

3.6.2 错误率上界



3.6 分类器的错误率

1、分类器的错误率概述

- 对分类器设计而言，分类器的错误率是一个非常重要的参数，是用来衡量分类器性能优劣的一个指标。显然，最小错误率贝叶斯决策的错误率是所有分类器中最小的，或者是最优的。
- Bayes分类器错误率的计算或估计方法
 - ① 按照理论公式计算
 - ② 计算错误率上界
 - ③ 实验估计



3.6 分类器的错误率

1、错误率的理论计算

➤ 正态分布且协方差矩阵相等的情况

- **最小错误率贝叶斯决策规则的等价规则，以负对数似然比形式表示为：**

① 若 $h(x) = -\ln\left[\frac{p(x|\omega_1)}{p(x|\omega_2)}\right] = -\ln p(x|\omega_1) + \ln p(x|\omega_2) < \ln \frac{P(\omega_1)}{P(\omega_2)}$ ，则决策 $x \in \omega_1$ 。

② 若 $h(x) = -\ln\left[\frac{p(x|\omega_1)}{p(x|\omega_2)}\right] = -\ln p(x|\omega_1) + \ln p(x|\omega_2) > \ln \frac{P(\omega_1)}{P(\omega_2)}$ ，则决策 $x \in \omega_2$ 。

- $h(x)$ 是 x 的函数， x 是随机向量，所以 $h(x)$ 也是随机变量。其概率分布密度函数为 $p(h|\omega_i)$ 。由于该函数是一维概率密度函数，易于积分，所以用它计算错误率较为方便。



3.6 分类器的错误率

1、错误率的理论计算

➤ 正态分布且协方差矩阵相等的情况

- 错误率公式可表示为

$$P_1(e) = \int_{\mathcal{R}_2} p(\mathbf{x}|\omega_1) d\mathbf{x} = \int_t^{\infty} p(h|\omega_1) dh$$

$$P_2(e) = \int_{\mathcal{R}_1} p(\mathbf{x}|\omega_2) d\mathbf{x} = \int_{-\infty}^t p(h|\omega_2) dh$$

式中, $t = \ln[P(\omega_1)|P(\omega_2)]$

- 只要 $h(x)$ 密度函数的解析形式已知, 就可以计算出错误率 $P_1(e)$ 和 $P_2(e)$ 。



3.6 分类器的错误率

1、错误率的理论计算

➤ 正态分布且协方差矩阵相等的情况

已知两类别总体服从正态分布，则负对数似然比的决策规则可以写为

$$\begin{aligned}h(x) &= -\ln p(x|\omega_1) + \ln p(x|\omega_2) \\&= -\left[-\frac{1}{2}(x - \mu_1)^T \Sigma_1^{-1}(x - \mu_1) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_1| \right] \\&\quad + \left[-\frac{1}{2}(x - \mu_2)^T \Sigma_2^{-1}(x - \mu_2) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_2| \right] \\&= \frac{1}{2}(x - \mu_1)^T \Sigma_1^{-1}(x - \mu_1) - \frac{1}{2}(x - \mu_2)^T \Sigma_2^{-1}(x - \mu_2) + \frac{1}{2} \frac{\ln |\Sigma_1|}{\ln |\Sigma_2|}\end{aligned}$$

其中，当 $h(x) < \ln \frac{P(\omega_1)}{P(\omega_2)}$ 时，则决策 $x \in \omega_1$ ；当 $h(x) > \ln \frac{P(\omega_1)}{P(\omega_2)}$ 时，则决策 $x \in \omega_2$ 。



3.6 分类器的错误率

1、错误率的理论计算

➤ 正态分布且协方差矩阵相等的情况

又已知协方差矩阵相等 ($\Sigma_1 = \Sigma_2 = \Sigma$)，决策面为 x 的线性函数，其决策规则可简化为：

① 若 $h(x) = (\mu_1 - \mu_2)^T \Sigma^{-1} x + \frac{1}{2} (\mu_1^T \Sigma^{-1} \mu_1 - \mu_2^T \Sigma^{-1} \mu_2) < \ln \frac{P(\omega_1)}{P(\omega_2)}$ ，则决策 $x \in \omega_1$ ；

② 若 $h(x) = (\mu_1 - \mu_2)^T \Sigma^{-1} x + \frac{1}{2} (\mu_1^T \Sigma^{-1} \mu_1 - \mu_2^T \Sigma^{-1} \mu_2) > \ln \frac{P(\omega_1)}{P(\omega_2)}$ ，则决策 $x \in \omega_2$ 。



3.6 分类器的错误率

1、错误率的理论计算

➤ 正态分布且协方差矩阵相等的情况

根据正态分布的性质， $h(x)$ 是一维的随机变量，是 x 的线性函数，服从一维正态分布。

对于 $p(h|\omega_1)$ 可以算出一维正态分布的参数，即均值 η_1 及方差 σ_1^2 ：

$$\begin{aligned}\eta_1 &= E[h(x)|\omega_1] = (\mu_2 - \mu_1)^T \Sigma^{-1} \mu_1 + \frac{1}{2} (\mu_1^T \Sigma^{-1} \mu_1 - \mu_2^T \Sigma^{-1} \mu_2) \\ &= -\frac{1}{2} (\mu_1 - \mu_2)^T \Sigma^{-1} (\mu_1 - \mu_2)\end{aligned}$$

令 $\eta = \frac{1}{2} [(\mu_1 - \mu_2)^T \Sigma^{-1} (\mu_1 - \mu_2)]$ ，则有

$$\eta_1 = -\eta$$

$$\sigma_1^2 = E\{[h(x) - \eta]^2|\omega_1\} = (\mu_1 - \mu_2)^T \Sigma^{-1} (\mu_1 - \mu_2) = 2\eta$$



3.6 分类器的错误率

1、错误率的理论计算

➤ 正态分布且协方差矩阵相等的情况

- 同理，可以得到 $p(h|\omega_2)$ 的参数——均值 η_2 及方差 σ_2^2

$$\eta_2 = \frac{1}{2}(\mu_1 - \mu_2)^T \Sigma^{-1}(\mu_1 - \mu_2) = \eta$$

$$\sigma_2^2 = (\mu_1 - \mu_2)^T \Sigma^{-1}(\mu_1 - \mu_2) = 2\eta$$

- 最后利用 $p(h|\omega_1)$ 和 $p(h|\omega_2)$ 计算出 $P_1(e)$ 和 $P_2(e)$:

$$P_1(e) = \int_t^{\infty} p(h|\omega_1) dh = \int_{(\frac{t+\eta}{\sigma})}^{\infty} (2\pi)^{-\frac{1}{2}} \exp(-\frac{1}{2}\varepsilon^2) d\varepsilon$$

$$P_2(e) = \int_{-\infty}^t p(h|\omega_2) dh = \int_{-\infty}^{\frac{t-\eta}{\sigma}} (2\pi)^{-\frac{1}{2}} \exp(-\frac{1}{2}\varepsilon^2) d\varepsilon$$

$$\text{其中, } t = \ln\left[\frac{P(\omega_1)}{P(\omega_2)}\right], \sigma = \sqrt{2\eta}$$



3.6 分类器的错误率

1、错误率的理论计算

➤ 独立随机变量情况

当模式样本 x 的各维特征向量相互独立时， x 的密度函数可表示为：

$$p(x|\omega_i) = \prod P(x_l|\omega_i), \quad i = 1, 2; \quad l = 1, \dots, d$$

因此负对数似然比 $h(x)$ 为：

$$h(x) = \sum_{l=1}^d h(x_l)$$

其中 $h(x_l) = -\ln \frac{p(x_l|\omega_1)}{p(x_l|\omega_2)}$ ，即随机变量 $h(x)$ 为 d 个随机变量 $h(x_1)$ 之和。由中心极限定

理，无论各 $h(x_1)$ 的密度函数如何，只要当 d 足够大， $h(x)$ 的密度函数总趋于正态分布。



3.6 分类器的错误率

1、错误率的理论计算

➤ 独立随机变量情况

可以计算出 $h(x)$ 的均值 η_i 及方差 σ_i^2

$$\eta_i = E[h(x)|\omega_i] = E\left[\sum_{l=1}^d h(x_l) | \omega_i\right] = \sum_{l=1}^d \eta_{il}$$

$$\sigma_i^2 = E\{[h(x) - \eta_i]^2 | \omega_i\} = \sum_{l=1}^d E\{[h(x_l) - \eta_{il}]^2 | \omega_i\} + \sum_{\substack{l,j=1 \\ l \neq j}}^d E\{[h(x_l) - \eta_{il}][h(x_j) - \eta_{jl}] | \omega_i\}$$

根据独立性条件，上式中第二项为零，其方差可写为：

$$\sigma_i^2 = \sum_{l=1}^d \sigma_{il}^2$$

由于 η_{il} 和 σ_{il}^2 都是一维随机变量 $\bar{x}_l$ 的函数，多数情况下计算相对容易。所以可以把 $h(x|\omega_i)$ 近似看成是服从 $N(\eta_i, \sigma_i^2)$ 的一维正态分布的随机变量，利用公式近似计算错误率。



3.6 分类器的错误率

2、错误率上界

➤ Chernoff 错误率上界

对于 $x \in \omega_1$ ，根据特征函数的定义， ω_1 类负对数似然比 $h(x)$ 的特征函数为：

$$\phi_1(\omega) = \int_{-\infty}^{+\infty} \exp(j\omega h) p(h|\omega_1) dh$$

式中 ω 表示角频率，如果用实数 S 代替上式中的 $j\omega$ 则得到 $h(x)$ 的矩生成函数，它是 S 的函数，用 $\phi_1(S)$ 表示为：

$$\phi_1(S) = \int_{-\infty}^{+\infty} \exp(Sh) p(h|\omega_1) dh$$

取 $\phi_1(S)$ 得负对数，记为 $\mu(S)$ ，则：

$$\mu(S) = -\ln \phi_1(S) = -\ln \int_{-\infty}^{+\infty} \exp(Sh) p(h|\omega_1) dh$$



3.6 分类器的错误率

2、错误率上界

➤ Chernoff错误率上界

可以证明：

$$\int_{-\infty}^{+\infty} [\exp(Sh)/\phi_1(S)] p(h|\omega_1) dh = 1$$

显然上式符合密度函数的性质。于是引入了一个新的随机变量 g ，使它的概率密度为上式中的被积函数，即：

$$p_g(g = h|\omega_1) = [\exp(Sh)/\phi_1(S)] p(h|\omega_1)$$

有了 g 的密度函数，就可以写出 g 的均值为

$$E[g|\omega_1] = \int_{-\infty}^{+\infty} h p_g(g = h|\omega_1) dh = \int_{-\infty}^{+\infty} h [\exp(Sh)/\phi_1(S)] p(h|\omega_1) dh = -\frac{d\mu(S)}{dS}$$



3.6 分类器的错误率

2、错误率上界

➤ Chernoff错误率上界

用类似的推导得出 g 的方差为

$$\sigma_g^2 = -\frac{d^2\mu(S)}{dS^2}$$

这样，错误率 $P_1(e)$ 就可以写为：

$$\begin{aligned} P_1(e) &= \int_t^\infty p(h|\omega_1) dh = \int_t^\infty \frac{\phi_1(S)}{e^{Sh}} \cdot \frac{e^{Sh}}{\phi_1(S)} p(h|\omega_1) dh \\ &= \int_t^\infty \frac{\phi_1(S)}{e^{Sh}} p_g(g = h|\omega_1) dh \\ &= \int_t^\infty \exp[-\mu(S) - Sh] p_g(g = h|\omega_1) dh \\ &= \exp[-\mu(S)] \int_t^\infty (-Sh) p_g(g = h|\omega_1) dh \end{aligned}$$



3.6 分类器的错误率

2、错误率上界

➤ Chernoff错误率上界

对于 $S \geq 0$ ，若 $h \geq t$ ，则

$$\exp(-Sh) \leq \exp(-St)$$

利用上面的不等式关系，可以写出错误率 $P_1(e)$ 的上界为：

$$P_1(e) \leq \exp[-\mu(S) - St] \int_t^{\infty} p_g(g = h | \omega_1) dh$$

式中积分项为密度函数在 (t, ∞) 域上的积分，其值小于1，所以可以把错误率

$P_1(e)$ 的上界进一步写成较简单的形式

$$P_1(e) \leq \exp[-\mu(S) - St]$$



3.6 分类器的错误率

2、错误率上界

➤ Chernoff错误率上界

对于错误率 $P_2(e)$ 的上界，也可以用类似的方法，此时 ω_2 类的负对数似然比的特

征函数 $\omega_2(\omega)$ 为：

$$\phi_2(\omega) = \int_{-\infty}^{+\infty} \exp(j\omega h) p(h|\omega_2) dh$$

相应的矩生成函数为

$$\phi_2(S) = \int_{-\infty}^{+\infty} \exp(S h) p(h|\omega_2) dh$$



3.6 分类器的错误率

2、错误率上界

➤ Chernoff错误率上界

$\varphi_2(S)$ 可以改写为:

$$\begin{aligned}\varphi_2(S) &= \int_{E^d} \exp - \left[S \ln \frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} \right] p(\mathbf{x}|\omega_2) d\mathbf{x} \\ &= \int_{E^d} \left[\frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} \right]^{-S} p(\mathbf{x}|\omega_2) d\mathbf{x} \\ &= \int_{E^d} [p(\mathbf{x}|\omega_1)]^{-S} [p(\mathbf{x}|\omega_2)]^{1+S} d\mathbf{x}\end{aligned}$$

同样，把 $\varphi_1(S)$ 改写为:

$$\varphi_1(S) = \int_{E^d} [p(\mathbf{x}|\omega_1)]^{1-S} [p(\mathbf{x}|\omega_2)]^S d\mathbf{x}$$

从上面两个式子可知，两个被积函数存在如下关系:

$$[p(\mathbf{x}|\omega_1)]^{1-S} [p(\mathbf{x}|\omega_2)]^S \cdot \left[\frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} \right]^{-1} = [p(\mathbf{x}|\omega_1)]^{-S} \cdot [p(\mathbf{x}|\omega_2)]^{1+S}$$



3.6 分类器的错误率

2、错误率上界

➤ Chernoff错误率上界

或者，将 $p(h|\omega_1)$ 和 $p(h|\omega_2)$ 表示为：

$$p(h|\omega_2) = e^k \cdot p(h|\omega_1)$$

可以计算出 $P_2(e)$ ：

$$\begin{aligned} P_2(e) &= \int_{-\infty}^t p(h|\omega_2) dh = \int_{-\infty}^t e^h p(h|\omega_1) dh \\ &= \int_{-\infty}^t e^h \cdot \exp[-\mu(S) - Sh] p_g(g = h|\omega_1) dh \\ &= \int_{-\infty}^t \exp[-\mu(S) + (1 - S)h] p_g(g = h|\omega_1) dh \end{aligned}$$



3.6 分类器的错误率

2、错误率上界

➤ Chernoff错误率上界

对于 $S \leq 1$ ，若 $h \leq t$ 情况，有如下关系：

$$\exp[(1 - S)h] \leq \exp[(1 - S)t]$$

所以错误率 $P_2(e)$ 的上界可以写为：

$$P_2(e) \leq \exp[-\mu(S) + (1 - S)t]$$

为了得到最小上界，对上式两端分别求偏导，并且令偏导数为0，可得到最小上界的最佳 S 值记为 S^* ，则 S^* 应是如下微分方程的解：

$$\frac{-d\mu}{dS} = t$$



3.6 分类器的错误率

2、错误率上界

➤ Chernoff错误率上界

所以根据同一个 S^* 同时给出了 $P_1(e)$ 和 $P_2(e)$ 的最小上界。把由 S^* 确定的错误率上界称为**Chernoff上界**。

若要求总错误率 $P(e)$ 的上界，可利用 $P_1(e)$ 和 $t = \ln \frac{P(\omega_1)}{P(\omega_2)}$ 就能得出较好的上界。

这时 $P_1(e)$ 和 $P_2(e)$ 就可以改写为：

$$P_1(e) \leq \{P(\omega_2)/P(\omega_1)\}^s \exp[-\mu(S)] \int_t^\infty p_g(g = h|\omega_1) dh$$

$$P_2(e) \leq \{P(\omega_1)/P(\omega_2)\}^{1-s} \exp[-\mu(S)] \int_{-\infty}^t p_g(g = h|\omega_1) dh$$



3.6 分类器的错误率

2、错误率上界

➤ Chernoff 错误率上界

又因为

$$P(e) = P(\omega_1)P_1(e) + P(\omega_2)P_2(e)$$

所以

$$\begin{aligned} P(e) &\leq [P(\omega_1)]^{1-S} \cdot [P(\omega_2)]^S \exp[-\mu(S)] \cdot \left[\int_t^\infty p_g(g = h|\omega_1) + \int_{-\infty}^t p_g(g = h|\omega_1) \right] \\ &= [P(\omega_1)]^{1-S} [P(\omega_2)]^S \exp[-\mu(S)] \end{aligned}$$

通过 S 使上式最小化。就可以求出最佳值 S^* ，即满足 $-\frac{d\mu(S)}{dS} = \ln \frac{P(\omega_1)}{P(\omega_2)} = t$ 的解。



3.6 分类器的错误率

2、错误率上界

➤ 用Bhattacharyya系数确定的错误率上界

条件错误概率为：

$$P(x|e) = 1 - \max P(\omega_i|x), \quad i = 1, 2, \dots, c$$

两类情况下样本 x 的条件错误率为：

$$P(e|x) = \min[P(\omega_1|x), P(\omega_2|x)]$$

为了得到错误率上界，利用几何不等式：如果 $a > b > 0$ 时，则 $\sqrt{ab} > b$ 。因为

$P(\omega_1|x) > 0$ 和 $P(\omega_2|x) > 0$ ，故

$$P(e|x) \leq \sqrt{P(\omega_1|x)P(\omega_2|x)}$$



3.6 分类器的错误率

2、错误率上界

➤ 用Bhattacharyya系数确定的错误率上界

对条件错误率求期望就得出错误率为：

$$\begin{aligned} P(e) &= \int P(e|\mathbf{x}) p(\mathbf{x}) d\mathbf{x} \\ &\leq \int \sqrt{P(\omega_1|\mathbf{x})P(\omega_2|\mathbf{x})} p(\mathbf{x}) d\mathbf{x} \\ &= \sqrt{P(\omega_1) \cdot P(\omega_2)} \int \sqrt{P(\omega_1|\mathbf{x})P(\omega_2|\mathbf{x})} d\mathbf{x} \\ &= \sqrt{P(\omega_1) \cdot P(\omega_2)} \exp \left\{ - \left[- \ln \int \sqrt{P(\omega_1|\mathbf{x})P(\omega_2|\mathbf{x})} d\mathbf{x} \right] \right\} \end{aligned}$$



3.6 分类器的错误率

2、错误率上界

➤ 用Bhattacharyya系数确定的错误率上界

定义Bhattacharyya系数，并用 J_B 表示：

$$J_B = -\ln \int \sqrt{P(x|\omega_1)P(x|\omega_2)} dx$$

可将错误率的公式表示为

$$P(e) \leq \sqrt{P(\omega_1)P(\omega_2)} \exp(-J_B)$$

上式不等号右边就是利用Bhattacharyya系数所确定的错误率上界，它在计算上比Chernoff上界简单。



3.6 分类器的错误率

2、错误率上界

➤ 用Bhattacharyya系数确定的错误率上界

- **求Chernoff上界时**，在已知各类的先验概率和类条件概率密度，并在使用一定决策规则的条件下，要求出负对数似然比密度函数 $P(h|\omega_q)$ ，再写出矩阵生成函数 $\varphi_i(S)$ 的负对数 $\mu(S)$ ，然后才能通过解微分方程 $-\frac{d\mu(S)}{dS} = t$ 而得到最佳值 S^* ，最后求出相应的 $P_1(e)$ 和 $P_2(e)$ 及 $P(e)$ 的上界。
- **用Bhattacharyya系数确定的上界**，只要在已知 $P(\omega_1)$ 、 $P(\omega_2)$ 、 $P(x|\omega_1)$ 及 $P(x|\omega_2)$ 条件下利用 J_B 的公式就可以直接计算出错误率的上界。
- **应当指出**，Bhattacharyya系数所确定的错误率上界实际上就是 $S = 0.5$ 条件下Chernoff上界和 $P(e)$ 的上界。



3.7 朴素贝叶斯分类器与贝叶斯网络

- 3.7.1 朴素贝叶斯分类器
- 3.7.2 半朴素贝叶斯分类器
- 3.7.3 贝叶斯网络



3.7 朴素贝叶斯分类器与贝叶斯网络

1、朴素贝叶斯分类器

➤ 朴素贝叶斯分类器概述

基于贝叶斯公式估计后验概率 $P(\omega_i|x)$ 的主要困难在于，类条件概率 $P(x|\omega_i)$ 难以从有限的训练样本直接估计得到。

朴素贝叶斯分类器(naïve Bayes classifier)采用了“**属性条件独立性假设**(attribute conditional independence assumption)”：对已知类别，**假设所有属性相互独立**。即假设每个属性独立地对分类结果发生影响。



3.7 朴素贝叶斯分类器与贝叶斯网络

1、朴素贝叶斯分类器

➤ 朴素贝叶斯分类器特点

基于以上假设，有：

$$P(\omega_i|\mathbf{x}) = \frac{P(\omega_i)P(\mathbf{x}|\omega_i)}{P(\mathbf{x})} = \frac{P(\omega_i)}{P(\mathbf{x})} \prod_{i=0}^d P(x_i|\omega_i)$$

其中 d 为属性个数，对所有类别来说 $P(\mathbf{x})$ 相同，因此由最小错误率贝叶斯决策规则有：

$$h_{nb}(\mathbf{x}) = \operatorname{argmax}_{\omega_i \in \omega} P(\omega_i) \prod_{i=0}^d P(x_i|\omega_i)$$

即为朴素贝叶斯分类器的表达式，其中 ω 表示所有类别的集合。

朴素贝叶斯分类器的训练过程就是根据训练集来估计类先验概率 $P(\mathbf{x})$ ，并且为每个属性估计条件概率 $P(x|\omega_i)$ 。



3.7 朴素贝叶斯分类器与贝叶斯网络

2、半朴素贝叶斯分类器

➤ 半朴素贝叶斯分类器概述

- 朴素贝叶斯分类器采用的属性条件独立性假设在现实任务中往往很难成立
- 半朴素贝叶斯分类器的特点
 - ① 将朴素贝叶斯分类中属性条件独立性假设进行一定程度的放松
 - ② 基本思想：适当考虑部分属性间的相互依赖信息，
 - ③ “独依赖估计” (One-Dependent Estimator, ODE)：最常用的一种策略，其中“独依赖”是指假设每个属性在类别之外最多仅依赖于一个其他属性，即

$$P(\omega_i | \mathbf{x}) \propto P(\omega_i) \prod_{i=0}^d P(x_i | \omega_i, pa_i)$$

其中 pa_i 为 x_i 依赖的属性，称为 x_i 的父属性




3.7 朴素贝叶斯分类器与贝叶斯网络

2、半朴素贝叶斯分类器

➤ ODE与SPODE

$$P(\omega_i | \mathbf{x}) \propto P(\omega_i) \prod_{i=0}^d P(x_i | \omega_i, pa_i)$$

- 若每个属性的父属性已知，则可通过和朴素贝叶斯分类器相似的特性估计 $P(x_i | \omega_i, pa_i)$ 。问题的关键转化为如何确定每个属性的父属性，不同的做法产生不同的独依赖分类器。
- 最直接的解决方法是假设所有属性都依赖于同一个属性，称该属性为“超父” (super-parent)，然后通过交叉验证等模型选择方法来确定超父属性，由此形成了SPODE (Super-ParentODE)方法，如图所示，属性 x_1 即为超父属性。





3.7 朴素贝叶斯分类器与贝叶斯网络

3、贝叶斯网络 (Bayesian network)

➤ 贝叶斯网络概述

利用**有向无环图** (Directed Acyclic Graph, DAG) 来描述属性与属性之间的依赖关系

进一步使用条件概率表 (Conditional Probability Table, CPT) 来描述属性的联合概率分布, 也可称为**“信念网”** (belief network)



3.7 朴素贝叶斯分类器与贝叶斯网络

3、贝叶斯网络 (Bayesian network)

➤ 贝叶斯网络的构成

- 一个贝叶斯网 B 主要由结构 G 和参数 θ 两部分构成，公式描述为 $B = \langle G, \theta \rangle$ ，其中网络结构 G 是一个有向无环图。
- G 中每个结点对应于一个属性，如果两个结点之间有直接依赖关系，则它们可由一条边连接起来，参数 θ 可以对这种依赖关系进行定量化的描述。
- 假设属性 x_i 在 G 中的父结点集为 π_i ，则参数 θ 中包含了每个属性的条件概率表 $\theta_{(x_i|\pi_i)} = P_B(x_i|\pi_i)$ 。
- 贝叶斯网结构能够对属性间的条件独立性进行有效表达。例如，给定贝叶斯网络中的父结点集合，其假设每个属性与它的非后裔属性独立，所以有

$$P_B(x_1, x_2, \dots, x_d) = \prod_{i=1}^d P_B(x_i|\pi_i) = \prod_{i=1}^d \theta_{(x_i|\pi_i)}$$




3.7 朴素贝叶斯分类器与贝叶斯网络


3、贝叶斯网络 (Bayesian network)

➤ 贝叶斯网络中变量的依赖关系


贝叶斯网络中三种典型的变量之间依赖关系，分别为同父结构，V型结构、顺序结构：



(a) 同父结构



(b) V型结构



(c) 顺序结构



3.7 朴素贝叶斯分类器与贝叶斯网络

3、贝叶斯网络 (Bayesian network)

➤ 三种依赖关系

- 同父结构中若给定父节点 x_1 的值，则其后裔属性 x_3 、 x_4 条件独立，而在顺序结构中给定 x 的值，则 y 、 z 条件独立。对于V型结构，其中一个变量的取值确定与否，能对其他两个变量的独立性产生影响，即给定 x_4 的取值， x_1 和 x_3 之间必定不独立。
- 对应的联合概率分布分别为：
 - ① 同父结构： $p(x_1, x_3, x_4) = p(x_1)p(x_3|x_1)p(x_4|x_1)$
 - ② V型结构： $p(x_1, x_2, x_4) = p(x_1)p(x_2)p(x_4|x_1, x_2)$
 - ③ 顺序结构： $p(x, y, z) = p(z)p(x|z)p(y|x)$



3.7 朴素贝叶斯分类器与贝叶斯网络

3、贝叶斯网络 (Bayesian network)

➤ 贝叶斯网络的应用

- 在贝叶斯网络中，如果网络结构已知，只需对训练样本进行统计计数，估计出每个结点的条件概率表即可。
- 但实际的网络结构难以获得，贝叶斯网学习的核心任务是根据训练数据集确定出结构最“恰当”的贝叶斯网。
- **“评分搜索”**是确定该结构的一个常用办法，“评分搜索”需要先定义一个评分函数 (score function)，利用该评分函数来量化和评估贝叶斯网与训练数据之间的匹配程度，然后基于该函数来确定结构最优的贝叶斯网。评分函数的选择确定了希望获得什么样的贝叶斯网。



3.7 朴素贝叶斯分类器与贝叶斯网络

3、贝叶斯网络 (Bayesian network)

➤ 贝叶斯网络小结

- **理想情况：**根据贝叶斯网络定义的联合概率分布来精确计算后验概率。
- **实际情况：**
 - ① **“精确推断”已被证明是NP难点**（即非确定性多项式时间可归约问题），即当贝叶斯网中的结点较多、连接稠密时，难以进行精确推断。
 - ② 需要通过降低精度要求，在有限时间内求得近似解，常使用吉布斯采样完成近似推断。



作业

1、已知一未知样本可能属于飞机、舰船和车辆三类 ($C = 3$)，对应的先验概率分别为： $P(\omega_1)=0.5$ ， $P(\omega_2)=0.3$ ， $P(\omega_3)=0.2$ ，类条件概率密度分别为： $P(x|\omega_1) = 0.3$ ， $P(x|\omega_2) = 0.4$ ， $P(x|\omega_3) = 0.3$ ，试对未知样本 x 进行最小错误率贝叶斯决策。

2、一架客机经检修可能是健康和非健康状态，设第一类为健康，第二类为非健康，已知： $P(\omega_1) = 0.6$ ， $P(\omega_2) = 0.4$ ， $P(x|\omega_1) = 0.3$ ， $P(x|\omega_2) = 0.4$ ，且风险值分别为： $\lambda_{11} = \lambda_{22} = 5$ ， $\lambda_{12} = 4$ ， $\lambda_{21} = 3$ ，试对客机状态进行最小风险贝叶斯决策。



北京航空航天大学
BEIHANG UNIVERSITY

德才兼备 知行合一

The end