



北京航空航天大学
BEIHANG UNIVERSITY

模式识别

第五章 特征选择与特征提取

北京航空航天大学宇航学院



主要内容

5.1 基本概念

5.2 图像特征

5.3 特征选择

5.4 特征提取



5.1 基本概念

5.1.1 特征概念回顾

5.1.2 识别系统回顾

5.1.3 研究特征原因



5.1 基本概念

1、特征概念回顾

➤ 特征和特征值

- 特征是可以用来体现类别之间相互区别的某些数学测度，也称作属性，测度的值称为特征值。

➤ 特征向量和特征空间

- 由被识别的对象（样本）确定一组基本特征，组成该样本的特征向量。
- 样本的特征构成了样本的特征空间，空间的维数就是特征的个数，每一个样本就是特征空间中的一个点。

➤ 特征形成与计算

- 由被识别的对象（即样本）确定一组基本特征，组成该样本的特征向量。
 - 当识别对象是波形或图像时，这些特征可以计算得到的。
 - 当识别对象是实物或某种过程时，这些特征可由传感器测量。



5.1 基本概念

1、特征概念回顾

➤ 原始特征

- 模式识别中把每个对象都量化为一组特征来描述
- **原始特征的定义**：通过直接测量得到的特征称为原始特征，如人体的各种生理指标（以描述健康状况）、数字图像中每个像素点的灰度值（以描述图像内容）。
- **原始特征的类别**：物理、结构和数学特征。
 - **物理和结构特征**：一般是由仪器直接测量出来的数值，这类特征易于为人的直觉感知，但是有时难以定量描述，因此不利于机器判别。
 - **数学特征**：则是对仪器所测量数据的进一步计算，比如根据图像中细胞的总光密度、大小、形状、核内纹理等统计特征来区分正常细胞和异常细胞，这类特征易于用机器判别和分析



5.1 基本概念

1、特征概念回顾



➤ 原始特征

- 原始特征是直接测量获得的，但是往往不直接用于模式识别中，这是因为：

- ① 原始特征不能反映对象的本质特征；
- ② 原始特征的维数可能很大，不利于分类器的设计。

➤ 例：卫星原始特征

- 实验用的卫星图像大小 160×120 ，如果采用全部灰度值的话，原始特征即为 19200 维。
- 如果改为计算卫星的面积、周长、形状、纹理等有效特征，原始特征可能不超过 100 维。





5.1 基本概念

1、特征概念回顾

➤ 特征选择与提取

- 从原始特征中尽量挑选出一些最有效的特征，以达到降低特征空间维数的目的。
- 直接搜索挑选出最优组合——特征选择。
- 数学变换优化成另一组特征——特征提取。





5.1 基本概念

1、特征概念回顾

➤ 特征选择

- 从原始特征中挑选出一组最有代表性、分类性能好的特征。

➤ 特征提取

- 通过映射的方法将高维特征映射到低维空间，在低维空间表示样本。

➤ 相似与差异


- **相似点：**达到的效果一样，即试图去减少特征数据集中的属性的数目。
- **差异点：**
 - ❑ 特征提取是通过属性组合生成新属性，改变特征空间；
 - ❑ 特征选择是从原始特征集中选取子集，不更改原特征空间。

特征选择是“挑出有用的”，特征提取是“创造新东西”。



5.1 基本概念

2、模式识别系统回顾



特征提取、特征选择、特征计算是模式识别系统的关键过程



5.1 基本概念

3、研究特征的原因

➤ 特征集的重要性


- 模式识别系统的成功与否，取决于所选用的特征集是否能够准确反映待研究的分类问题。

➤ 特征设计的关键性

- 设计和选用特征是模式识别系统设计中最关键的步骤之一。

➤ 特征选择与提取的作用

- 特征选择和特征提取是降低特征空间维度、简化系统设计与使用难度的关键环节。





5.2 图像特征

5.2.1 颜色特征

5.2.2 形象特征

5.2.3 纹理特征

5.2.4 空间关系特征



5.2 图像特征

1、颜色特征

➤ 颜色特征

- 颜色特征是一种**全局特征**，通常对图像或图像区域的方向、大小等变化不敏感，也就是说，颜色特征通常不能很好的描述图像中对象的局部特征。

➤ 颜色直方图


- 描述一幅图像中颜色的全局分布，无法描述图像中颜色的局部分布及每种色彩所处的空间位置，即无法描述图像中的某一具体的对象或物体，只是**颜色全局分布的统计结果**。

统计一幅图像各级灰度值的像素数

1	2	3	4	5	6
6	4	3	2	2	1
1	6	6	4	6	6
3	4	5	6	6	6
1	4	6	6	2	3
1	3	6	4	6	6



1	2	3	4	5	6
5	4	5	6	2	14




只知道该范围内像素值的点有多少个，但无法确定点的具体位置。




5.2 图像特征

1、颜色特征

➤ 灰度直方图



➤ RGB直方图





5.2 图像特征


1、颜色特征

➤ 颜色矩

- 用来**描述图像颜色分布的统计特征**，主要通过计算图像的颜色一阶矩、二阶矩和三阶矩来反映图像的颜色特征。这些矩分别对应于颜色的平均值、方差和偏斜度，能够有效地表示图像中的颜色分布。
- 由于**颜色信息主要分布在低阶矩中**，所以用一阶矩、二阶矩和三阶矩足以表达图像的颜色分布。

➤ 图像分析与力学中的矩对应关系

- 一阶矩（均值）、二阶矩（方差）、三阶矩（偏度）、四阶矩（峰度）





5.2 图像特征

1、颜色特征

➤ 一阶矩（均值）

- 一阶颜色矩采用一阶原点矩，即均值，反映图像的整体明暗程度，值越大越亮。

$$E_i = \sum_N \frac{1}{N} P_{ij}$$

i 是图像的颜色通道数，若为灰度图像， $i = 1$ ，若为彩色图像， $i = 3$ ；

P_{ij} 为第 j 个像素在第 i 个颜色通道上的颜色值。



5.2 图像特征

1、颜色特征

➤ 一阶矩 (均值)

- 一阶颜色矩采用一阶原点矩，即均值 $E_i = \sum_N^{j=1} \frac{1}{N} P_{ij}$ ，反映图像的整体明暗程度，值越大越亮。

➤ 二阶矩 (方差)

- 二阶颜色矩是标准差，反映颜色分布范围，值越大，分布越广。

$$\sigma_i = \sqrt{\left(\frac{1}{N} \sum_N^{j=1} (P_{ij} - \underbrace{E_i}_{\text{均值}})^2 \right)}$$



5.2 图像特征

1、颜色特征

➤ 一阶矩（均值）

- 一阶颜色矩采用一阶原点矩，即均值 $E_i = \sum_{j=1}^J \frac{1}{N} P_{ij}$ ，反映图像的整体明暗程度，值越大越亮。

➤ 二阶矩（方差）

- 二阶颜色矩是标准差 $\sigma_i = \sqrt{(\frac{1}{N} \sum_{j=1}^J (P_{ij} - E_i)^2)}$ ，反映颜色分布范围，值越大，分布越广。

➤ 三阶矩（偏度）

- 三阶颜色矩采用三阶中心矩的立方根，即偏差 $S_i = \sqrt[3]{(\frac{1}{N} \sum_{j=1}^J (P_{ij} - E_i)^3)}$ ，反映图像颜色分布的对称性。

当 $S_i = 0$ 时，图像的颜色分布是对称的；

当 $S_i < 0$ 时，颜色分布左偏或负偏；

当 $S_i > 0$ 时，颜色分布右偏或正偏；



5.2 图像特征

1、颜色特征

➤ 一阶矩（均值）

- 一阶颜色矩采用一阶原点矩，即均值 $E_i = \sum_{j=1}^J \frac{1}{N} P_{ij}$ ，反映图像的整体明暗程度，值越大越亮。

➤ 二阶矩（方差）

- 二阶颜色矩是标准差 $\sigma_i = \sqrt{\left(\frac{1}{N} \sum_{j=1}^J (P_{ij} - E_i)^2\right)}$ ，反映颜色分布范围，值越大，分布越广。

➤ 三阶矩（偏度）

- 三阶颜色矩采用三阶中心距的立方根，即偏差 $S_i = \sqrt[3]{\left(\frac{1}{N} \sum_{j=1}^J (P_{ij} - E_i)^3\right)}$ ，反映图像颜色分布的对称性。

➤ 四阶矩（峰度） $K_i = \left[\left(\frac{1}{N} \sum_{j=1}^J (P_{ij} - E_i)^4 \right) - 3 \right] / \sigma_i^4$

- 正峰度：分布比正态分布更尖，尾部更重。
- 负峰度：分布比正态分布更平，尾部更轻。
- 零峰度：分布与正态分布相似。



5.2 图像特征

2、形状特征

➤ 形状特征的意义



- 形状特征用来表示图像中感兴趣的区域。

➤ 形状特征的主要形式

- 轮廓特征：图像形状的外边界。
- 区域特征：面积、周长、半径、长度、宽度、高度。

➤ 图像分割对区域几何参数提取的影响

- 区域几何参数提取依赖于图像处理和分割效果，分割质量差可能导致参数无法提取。





5.2 图像特征



2、形状特征的提取

➤ Hough变换——直线、圆轮廓特征

- 利用图像全局特性而将边缘像素连接起来，组成区域封闭边界的一种方法。
- 直角坐标系中表示直线
- 极坐标中表示一条直线

$$y = kx + b$$

$$\rho = x \cos \theta + y \sin \theta$$



直线在直角坐标系中可以用 $y = kx + b$ 来表示，如果将其转到另一组参数空间中，用 ρ 和 θ 来表示该直线。按照这种表示，过一个点的所有直线可以在参数空间中绘制出一条正弦线。




5.2 图像特征


2、形状特征的提取

➤ Hough变换——直线、圆


- 将彩色图像转换为灰度图像
- 使用边缘检测算法检测边缘
- 对于每个边缘点用Hough变换来查找可能的直线
- 查找具有最高值的条目即为直线



原始图像



灰度二值化



Hough变换检测直线






5.2 图像特征

2、形状特征的提取

➤ HOG描述子 Histogram of Oriented Gradients

- 方向梯度直方图。



➤ 傅立叶描述子 Fourier Descriptor

- 基本思想是**用物体边界的傅里叶变换作为形状描述**，利用区域边界的封闭性和周期性，将二维问题转换为一维问题。由边界点导出三种形状表达：曲率函数、质心距离、复坐标函数。



5.2 图像特征

3、纹理特征

➤ 纹理特征的含义

- 纹理特征也是一种全局特征，体现表面缓慢变换或周期性变化的表面组织结构排列属性。

➤ 纹理特征的局限性


- 纹理特征不能完全反映出物体的本质属性，仅仅利用纹理特征是无法获得高层次图像内容的。

➤ 纹理特征的特点

- 对包含多个像素点的区域进行统计计算。
- 应具有旋转不变性。
- 容易受分辨率变化影响。



(a) 多尺度多方向 Gabor 纹理特征



(b) LBP 纹理特征



(c) 局部空间自相关



5.2 图像特征

3、纹理特征的提取


➤ 灰度共生矩阵 (Gray-level Co-occurrence Matrix, GLCM)

- 取图像 ($N \times N$) 中任意一点 (x, y) 及偏离它的另一点 $(x+a, y+b)$ ，设该点对的灰度值为 (g_1, g_2) 。令点 (x, y) 在整个画面上移动，则会得到各种 (g_1, g_2) 值，设灰度值的级数为 k ，则 (g_1, g_2) 的组合共有 k^2 种。

假设 $a = 1, b = 1$

图中点对的灰度值为 $(87, 184)$

还可得到其他点对的灰度值





5.2 图像特征

3、纹理特征的提取

➤ 灰度共生矩阵 (Gray-level Co-occurrence Matrix, GLCM)


- 对于整个图像，统计每一种 (g_1, g_2) 值出现的次数，排列成一个方阵，再用 (g_1, g_2) 出现的总次数将它们归一化为出现的概率 $P(g_1, g_2)$ ，得到的方阵称为灰度共生矩阵（GLCM）。
- 距离差分值 (a, b) 取不同的数值组合，可得到不同的联合概率矩阵。 (a, b) 取值要根据纹理周期分布的特性来选择，对于较细的纹理，选取(1,0)、(1,1)、(2,0)等。
 - 当 $a = 1, b = 0$ 时，像素对是水平的，即0度扫描；
 - 当 $a = 0, b = 1$ 时，像素对是垂直的，即90度扫描；
 - 当 $a = 1, b = 1$ 时，像素对是右对角线的，即45度扫描；
 - 当 $a = -1, b = -1$ 时，像素对是左对角线，即135度（-45度）扫描。



5.2 图像特征

3、纹理特征的提取

➤ 灰度共生矩阵 (Gray-level Co-occurrence Matrix, GLCM)



当 $a = 1, b = 0$ 时 (水平扫描), 有:

- $GLCM(1,1)=1$: 有1对灰度为1的像素水平相邻
- $GLCM(1,2)=2$: 有2对灰度为1和2的像素水平相邻

一幅图像的灰度共生矩阵能反映出图像灰度关于方向、相邻间隔、变化幅度的综合信息，是分析图像的局部模式和它们排列规则的基础。



5.2 图像特征

3、纹理特征的提取

➤ 灰度共生矩阵 (Gray-level Co-occurrence Matrix, GLCM)

$$f(x, y) = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$$

假设图像的灰度级数为 1 到 9

假设计算距离为 1 的像素对

假设计算水平方向



对于水平方向 ($\theta=0^\circ$, 距离 $d=1$)

GLCM =

$$\begin{bmatrix} 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$



5.2 图像特征

3、纹理特征的提取

➤ 自相关函数（图像的能量谱函数）

- 局部自相关函数：一种通过研究灰度的空间相关特性来描述纹理的常用方法


$$C(\varepsilon, \eta, j, k) = \frac{\sum_{x=j-w}^{j+w} \sum_{y=k-w}^{k+w} f(x, y) f(x - \varepsilon, y - \eta)}{\sum_{x=j-w}^{j+w} \sum_{y=k-w}^{k+w} [f(x, y)]^2}$$

窗口中心：(j, k)

窗口大小：2w + 1

位移参数：ε 和 η（取值通常在一个范围，如[-1, 1]）

像素坐标：f(x, y) 和 f(x - ε, y - η)





5.2 图像特征

3、纹理特征的提取

➤ 自相关函数（图像的能量谱函数）

$$f(x, y) = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$$

假设 $w=1$ （窗口大小为 3×3 ）

假设 ε 和 η 取值范围 $[-1, 1]$



$$C(-1, -1) = \frac{94}{285} \approx 0.3298$$

$$C(0, -1) = \frac{186}{285} \approx 0.6526$$

$$C(1, -1) = \frac{106}{285} \approx 0.3719$$

.....

$$C(\varepsilon, \eta) = \begin{bmatrix} 0.3298 & 0.6526 & 0.3719 \\ 0.5396 & 1 & 0.5396 \\ 0.2912 & 0.6526 & 0.3298 \end{bmatrix}$$

自相关矩阵




5.2 图像特征

3、纹理特征的提取

➤ LBP局部二值模式的原理 (Local Binary Pattern)

- 利用相邻像素间的关系，将0-255灰度级的像素值映射到重新定义的灰度级，然后通过统计直方图来反映图像的全局纹理信息。



- 原始的LBP算子定义为在 3×3 的窗口内，以窗口中心像素为阈值，将相邻的 8 个像素的灰度值与其进行比较，若周围像素值大于中心像素值，则该像素点的位置被标记为 1，否则为 0。 3×3 邻域内的 8 个点经比较可产生 8 位二进制数（通常转换为十进制数即LBP码，共 $2^8=256$ 种），即得到该窗口中心像素点的LBP值，并用这个值来反映该区域的纹理信息。



5.2 图像特征

3、纹理特征的提取

➤ LBP的特性

- 具有灰度不变性（思考：是否具有旋转不变性）。
- 统计与结构相结合的纹理分析方法。

44	118	192
32	82	204
61	174	250



0	1	1
0		1
0	1	1

$$(01111100)_{10}=124$$



61	32	44
174	82	118
250	204	192



0	0	0
1		1
1	1	1

$$(00011111)_{10}=31$$



5.2 图像特征

3、纹理特征的提取

- 上述提取的LBP算子在每个像素点都可以得到一个LBP编码，那么，对一幅图像（记录的是每个像素点的灰度值）提取其原始的LBP算子之后，得到的**原始LBP特征依然是一幅图片**（记录的是每个像素点的LBP值）。



➤ LBP的应用

- 应用中，如纹理分类、人脸分析等，一般都不将LBP图谱作为特征向量用于分类识别，而是采用LBP特征谱的统计直方图作为特征向量用于分类识别。



5.2 图像特征

4、空间关系特征

➤ 空间关系特征的含义


- 所谓空间关系，是指**图像中分割出来的多个目标之间的相互空间位置，或者相对方向关系。**

➤ 空间位置信息

- 相对空间位置信息：目标之间的相对情况，如上下左右关系等。
- 绝对空间位置信息：目标之间的距离大小以及方位。

➤ 常见的空间关系

- 连接/邻接关系。
- 交叠/重叠关系。
- 包含/包容关系。





5.3 特征选择

5.3.1 问题与思路

5.3.2 类别可分性准则

5.3.3 最优搜索

5.3.4 次优搜索

5.3.5 启发搜索



5.3 特征选择

1、问题和思路

➤ 无关特征对分类器性能的负面影响

- 有很多特征可能与要解决分类问题关系不大，但却在后续分类器设计中影响分类器性能。

➤ 特征冗余导致的计算与推广问题

- 特征过多会导致计算量大、推广能力差，且在样本有限时易出现病态矩阵等问题。

➤ 特征选择对模式识别系统成败的关键作用

- 模式识别系统的成败，首先取决于特征是否较好的反映模式的特性以及模式的分类问题。

➤ 在保证分类效果的基础上实现特征精简

- 希望在保证分类效果前提下，采用尽可能少的特征完成分类。

提高分类效果，减少计算量，让系统更高效。



5.3 特征选择

1、问题和思路

➤ 特征选择

- 已知给定的 M 个原始特征。
- 从中优选出 m 个特征 ($m < M$) 。
- 即：从给定的 M 个原始特征中搜索到最优的特征组合。

➤ 两方面解决：

- **特征选择的标准：**定义不同的类别可分离性准则（判据） J_{ij} ，用来衡量在一组特征下第 i 类和第 j 类之间的可分程度。
- **特征搜索算法：**在允许的时间内找出最优的那组特征。



5.3 特征选择

2、类别可分性准则

➤ 基本要求 (定性)

- 判据应该与错误率（或错误率的上界）有单调关系，这样才能较好地反映分类目标。
- 当特征独立时，判据对特征应该具有可加性，即：

$$J_{ij}(x_1, x_2, \dots, x_d) = \sum_{k=1}^d J_{ij}(x_k)$$

J_{ij} 越大，两类的分离程度就越大， $x_1, x_2, \dots, x_d$ 是一系列特征变量。

- 判据应该具有以下度量特性：

$$J_{ij} \geq 0, i \neq j; \quad J_{ij} = 0, i = j; \quad J_{ij} = J_{ji}$$

- 理想的判据应该对特征具有单调性，即加入新的特征不会使判据减小：

$$J_{ij}(x_1, x_2, \dots, x_d) \leq J_{ij}(x_1, x_2, \dots, x_d, x_{d+1})$$



5.3 特征选择

2、类别可分性准则

➤ (1) 基于类内类间距离的可分性判据

- 各类样本可以分开是因为它们位于特征空间中的不同区域，显然这些区域之间距离越大，类别可分性就越大。
- 距离度量有多种，如欧氏距离、各种平均平方距离。
- 各类特征向量间的平均距离为： $\delta(x_k, x_l)$ 是向量间的距离。

$$J_d(x) = \frac{1}{2} \sum_{i=1}^c P_i \sum_{j=1}^c P_j \frac{1}{n_i n_j} \sum_{k=1}^{n_i} \sum_{l=1}^{n_j} \delta(x_k^{(i)}, x_l^{(j)})$$

c 为类别数； n_i 为 w_i 类中样本数； n_j 为 w_j 类中的样本数； P_i 、 P_j 是相应类别的先验概率。



5.3 特征选择

2、类别可分性准则

➤ (1) 基于类内类间距离的可分性判据

- 其他距离度量:

$$J_1 = \text{tr}(\mathbf{S}_w + \mathbf{S}_b)$$

$$J_2 = \text{tr}(\mathbf{S}_w^{-1} \mathbf{S}_b)$$

$$J_3 = \ln \frac{|\mathbf{S}_b|}{|\mathbf{S}_w|}$$

$$J_4 = \frac{\text{tr}(\mathbf{S}_b)}{\text{tr}(\mathbf{S}_w)}$$

$$J_5 = \frac{|\mathbf{S}_b - \mathbf{S}_w|}{|\mathbf{S}_w|}$$

✓ 总类内离散度: $\mathbf{S}_w$

✓ 总类间离散度: $\mathbf{S}_b$



5.3 特征选择

2、类别可分性准则

➤ (2) 基于信息熵的可分性判据

- 把类别 $\omega_i, i = 1, \dots, c$ 看作一系列随机事件，它的发生依赖于随机向量 x ，给定 x 的后验概率 $P(\omega_i|x)$ 。
- 如果根据 x 能完全确定 ω ，则 ω 就没有不确定性，对 ω 本身的观察就不会再提供信息量，此时熵为0，特征 x 最有利于分类；
- 如果 x 完全不能确定 ω ，则 ω 不确定性最大，对本身的观察所提供信息量最大，此时熵为最大，特征 x 最不利于分类。

Shannon熵和平方熵

$$H = - \sum_{i=1}^c P(w_i|x) \log_2 P(w_i|x) \quad H = 2 \left[1 - \sum_{i=1}^c P^2(w_i|x) \right]$$



5.3 特征选择

2、类别可分性准则

➤ (2) 基于信息熵的可分性判据

Shannon熵和平方熵

$$H = - \sum_{i=1}^c P(w_i|\mathbf{x}) \log_2 P(w_i|\mathbf{x}) \quad H = 2 \left[1 - \sum_{i=1}^c P^2(w_i|\mathbf{x}) \right]$$

- 在熵的基础上，对特征 $\mathbf{x}$ 的所有取值积分，就得到**基于信息熵的可分性判据**：

$$J_E = \int H(\mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

- J_E 越小，可分性越好。



5.3 特征选择

2、类别可分性准则


➤ (3) 基于统计检验的可分性判据

- 统计检验的基本思想是从样本**计算某一能反映待检验假设的统计量**，在比较两组样本(两类样本)时就是用这个统计量来衡量两组样本之间的差别，例如t-检验、秩和检验等。

➤ (4) 基于概率分布的可分性判据

Bhattacharyya距离
Chernoff界限

(定量计算两个分布密度函数之间的距离)



完全可分与完全不可分情况



5.3 特征选择

3、最优搜索

➤ 特征选择

- 已知给定的 M 个原始特征。
- 从中优选出 m 个特征 ($m < M$) 。
- 即：从给定的 M 个原始特征中搜索到最优的特征组合。

➤ 全局搜索次数：

$$C_M^m = \frac{M!}{(M - m)! m!}$$

- 运算量巨大！



5.3 特征选择

3、最优搜索

➤ 分支定界算法 (Branch and Bound, 简称B&B算法)

- 将有可能特征组合构建一个树状结构, 按照特定的规则对树进行搜索和回溯, 尽早达到最优解, 而不必遍历树的所有分支。
- 最优搜索算法, 所有可能的组合都被考虑到。
- 建立搜索树的过程就是特征选择的过程。

➤ 单调假设

$$J(x_{i1}) < J(x_{i1}, x_{i2}) < J(x_{i1}, x_{i2}, x_{i3}) < \cdots < J(x_{i1}, x_{i2}, \dots, x_{iN})$$



5.3 特征选择

3、最优搜索

➤ B&B算法步骤

- ① 从包含所有特征（根节点）开始。
- ② 每一级去掉一个特征，逐步去掉不被选中的特征，**同一层中按对准则函数的影响大小，从左到右排列。**
- ③ 底层的每个叶节点代表特征选择的一个组合。
- ④ 到达叶节点后算法向上回溯，每回溯一级，应将相应节点上去掉的特征再收回来。
- ⑤ 定义准则函数阈值，用来结束搜索过程。




5.3 特征选择

3、最优搜索

➤ B&B算法举例：六个特征中选两个

- **Step1:** 首先确定树的深度： $D - d = 6 - 2 = 4$ 。树的根节点包含全部特征。
- **Step2:** 每一级的节点在其父节点基础上去掉一个特征（去掉的特征序号写在节点旁），因此共需要 $D - d$ 级，达到所需要的特征数目。


- 最底层的每个节点（叶节点），代表最终特征选择的一种组合。
- 为了简化树的规模，避免出现重复组合，约定特征只能以增序（按照6个特征对可分性判据影响大小）枚举：1 - 2 - ... - 6。
- 注意到第一级只能移除 1, 2, 3 特征，因为如果移除 4 特征，其后续分支深度 < 4 ，也就是后续枚举无法满足前述增序排列约定 (5, 6, 7, ?)。





➤ B&B算法举例：六个特征中选两个

- ① 根节点按照 Step1 和 2 长出第一层;
- ② 从根节点长到第一层后, 对最右节点 (去 3) 进行下一层的搜索, (去 3) 节点生长要满足不去掉特征 1 和 2, 那么 (去3) 无论怎么生长最后剩两个特征只会剩 1和2, 所以 (去 3) 后面先去 4 还是先去 5 还是先去 6 不影响, 只有一种非重复组合, 走到叶子节点, 计算此时准则函数, 记录下来作为界限B。






3、最优搜索

➤ B&B算法举例：六个特征中选两个

- **Step4:**

- ① 最右边（去 3）节点走完，**沿着叶节点回溯到最近的一个左侧分支**，也就是（去 2）节点，（去 2）节点根据 Step2 中规定能长出 2 个子节点（满足深度为 3），排序后，从最右侧节点往下生长，直到最终走到一个叶节点，计算准则函数，**如果比之前记录的准则函数大，就替换界限B。**
- ② 走到叶节点后就回溯到左边最近的通路，**如果某个中间节点的准则函数已经小于界限B，说明最优解已不可能在本节点之下的叶节点上，因此停止沿本树枝的搜索，从此节点重新向上回溯。**如果回溯过程一直到根节点，而且根据界限B不能再向下搜索其他树枝，则算法停止，**最后一次更新B时取得的特征组合就是特征选择的结果。**





5.3 特征选择

3、最优搜索

➤ B&B算法特点

- 要求准则函数（即可分性判据）对特征具有单调性。
- 树的构建生长过程就是特征选择的过程。
- 回溯过程保证算法可以遍历所有可能组合。
- 算法有可能提前达到准则函数阈值，因此运算量有可能有效减少。

B&B通过构建和遍历树结构，利用准则函数的单调性来减少运算量。



5.3 特征选择

4、次优搜索

➤ 目标

- 相对最优搜索，继续减小计算量。

➤ 常用次优搜索策略

- 单独最优特征组合。
- 顺序前向搜索。
- 顺序后向搜索。
- 浮动搜索（L-R方法）。



5.3 特征选择

4、次优搜索

➤ (1) 单独最优特征的组合

- 对每个特征单独计算类别可分性判据。
- 对单个特征的判据值进行排序。
- 选择前 m 个特征。

➤ 为什么是次优

- 单独最优特征的组合不一定是最优的。



5.3 特征选择

4、次优搜索

➤ (2) SFS (Sequential Forward Selection, 顺序前向搜索)

- 第一个特征选单独最优的特征。
- 第二个特征与第一个特征组合选准则最优的。
- 以此类推，直到 m 个特征。

➤ 特点

- 向前的或自底向上的特征优选算法；第一个特征影响大。

➤ 为什么是次优

- n 维特征组合最优，加上一维特征后，不一定是 $n + 1$ 维的全局最优特征组合。



5.3 特征选择

4、次优搜索

➤ (3) SBS (Sequential Backward Selection, 顺序后向搜索)

- 从所有特征开始逐一剔除不被选中的特征;
- 每次剔除的特征都是使得剩余的特征的准则函数值最优的特征;
- 直到 m 个特征为止。

➤ 特点

- 向后的或自顶向下的特征优选算法; 高维空间的运算。

➤ 为什么是次优

- 最优的 m 维特征组合不一定来自于最优的 $m + 1$ 维特征组合。



5.3 特征选择

4、次优搜索

➤ (4) L-R方法

- 结合SFS和SBS，局部最优搜索
- 引入回溯——**增L减R ($L > R$)**：每次首先按照SFS方式逐步增选L个特征，然后再按照SBS方式逐步剔除R个特征，以此类推，直到选择到所需要数目的特征；
- 引入回溯——**减R增L ($L < R$)**：每次首先按照SBS逐步剔除R个特征，然后再从已经被剔除的特征中按照SFS方式逐步选择L个特征，直到剩余的特征数目达到所需数目；

➤ 特点

- 运算量大；回溯使得已选的特征可以剔除，剔除的特征可以再选。

➤ 为什么是次优

- SFS和SBS都是次优，**回溯并不能保证不漏掉全局最优组合。**



5.3 特征选择

5、启发式搜索

➤ 最优搜索和次优搜索的局限性

- 特征维数较大时，最优搜索和次优搜索这类直接搜索方法计算量仍然太大，需要更好的搜索方法。

➤ 启发式搜索的含义

- 利用问题拥有的启发信息来引导搜索，达到减少搜索范围、降低问题复杂度的目的。
- 遗传算法。
- 模拟退火算法。





5.3 特征选择

5、启发式搜索

➤ (1) 遗传算法

- 一种通过模拟生物选择和进化过程的搜索寻优方法。
- 不能保证全局最优。








5.3 特征选择

5、启发式搜索

➤ (2) 模拟退火算法

- 基于Monte-Carlo迭代求解策略的一种随机寻优算法。
- 采样次数足够多时，理论上算法具有概率的全局优化性能。
- 高温时，优先接受目标函数下降的解，但也允许一定概率接受上升的解。
- 降温过程中，接受目标函数上升的解的概率逐渐减小。
- 温度趋近于零时，仅接受目标函数下降的解。





5.4 特征提取

5.4.1 问题与思路

5.4.1 LDA

5.4.2 PCA

5.4.3 K-L变换

5.4.4 流形学习



5.4 特征提取

1、问题与思路

➤ 重温原始特征的问题

- 有很多特征可能与要解决分类问题关系不大，但却在后续分类器设计中影响分类器性能。
- 即使很多特征与分类问题关系密切，但特征过多导致计算量大、推广能力差。当样本数有限时容易出现病态矩阵等问题。
- 特征提取的原因：与特征选择一样。



5.4 特征提取

1、问题与思路

➤ 特征提取

- 已知给定的 d 个原始特征。
- 经过数学变换得到 d' 个特征 ($d' < d$) 。

➤ 特征提取目的

- ① **降低特征空间维数**，使后续分类器设计在计算上更容易实现；
- ② **消除特征之间可能存在的相关性**，减少特征中与分类无关的信息，使新的特征更有利于分类。



5.4 特征提取

1、问题与思路

➤ 数学变换形式可以多样

- ① 最常采用的特征变换是**线性变换（本节重点介绍）**，若 $x \in R^d$ 是 d 维原始特征，变换后的 d' 维新特征 $z \in R^{d'}$ ：

$$z = W^T x$$

其中， W 是 $d \times d'$ 矩阵，称为变换矩阵。

- ② 有些情况下也可以采用非线性变换 $z = W(x)$ ，此时 $W(\cdot)$ 为非线性变换。

➤ 特征提取就是根据训练样本求适当的 W ，使得基于某种变换后的特征所计算得到的准则（类别可分性判据）最优。




5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ 基本概念

- 一种经典的线性学习方法：给定训练样例，经过投影，使得同类样例的投影点尽可能接近、异类样例的投影点尽可能远离。在对新样本进行分类时，根据投影点的位置来确定新样本的类别。
- 右图展示了典型的二分类 LDA 问题。假设有两类特征样本，分别为“O”和“+”。这些样本数据是二维的，希望将这些数据投影到一条直线，让每一种类别样本在直线上的投影尽可能地接近，而“O”和“+”样本数据中心之间的距离尽可能地大。



投影后类内方差最小、类间方差最大



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (1) Fisher投影准则

- 二分类 LDA 问题中, 投影前第 i 类样本 (d 维) 的均值为

$$\mathbf{m}_i = \frac{1}{N_i} \sum_{\mathbf{x}_j \in \mathcal{X}_i} \mathbf{x}_j, \quad i = 1, 2$$


- 为了度量两类的间隔和每一类内部的聚集程度, 可以定义各类的类内离散度矩阵

$$\mathbf{S}_i = \sum_{\mathbf{x}_j \in \mathcal{X}_i} (\mathbf{x}_j - \mathbf{m}_i)(\mathbf{x}_j - \mathbf{m}_i)^T \in \mathbb{R}^{d \times d}, \quad i = 1, 2$$

- 那么总类内离散度矩阵为 $\mathbf{S}_w = \mathbf{S}_1 + \mathbf{S}_2$

- 类间离散度矩阵

$$\mathbf{S}_b = (\mathbf{m}_1 - \mathbf{m}_2)(\mathbf{m}_1 - \mathbf{m}_2)^T \in \mathbb{R}^{d \times d}$$



投影后类内方差最小、类间方差最大



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (1) Fisher投影准则

- 将所有样本**投影到一维空间**，投影后的特征向量为


$$y = w^T x$$

- 投影后两类的均值 (标量) 分别为

$$\tilde{m}_i = \frac{1}{N_i} \sum_{y_j \in \mathcal{Y}_i} y_j = \frac{1}{N_i} \sum_{x_j \in \mathcal{X}_i} w^T x_j = w^T m_i, \quad i = 1, 2$$

- 投影后的类内离散度和总类内离散度分别为

$$\begin{aligned} \tilde{S}_i &= \sum_{y_j \in \mathcal{Y}_i} (y_j - \tilde{m}_i)^2 \\ \tilde{S}_w &= \tilde{S}_1 + \tilde{S}_2 \end{aligned}$$



投影后类内方差最小、类间方差最大



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (1) Fisher投影准则


- 投影后的类间离散度为

$$\tilde{S}_b = (\tilde{m}_1 - \tilde{m}_2)^2$$

- 根据 Fisher 投影准则的优化目标 (选择合适的投影方向, 使得投影后类间离散度尽可能大, 同时总类内离散度尽可能小), 可以写出如下**优化目标函数**

$$J(w) = \frac{\tilde{S}_b}{\tilde{S}_w} = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1 + \tilde{S}_2}$$

- 注意到, 上式没有包含需要找寻的投影方向。为了寻找最优投影方向 w , 需要将优化目标函数进行改写。



投影后类内方差最小、类间方差最大



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (1) Fisher投影准则

- 为了寻找最优投影方向 w , 需要将优化目标函数进行改写。

$$J(w) = \frac{\tilde{S}_b}{\tilde{S}_w} = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1 + \tilde{S}_2}$$

- 对于分子

$$\begin{aligned}\tilde{S}_b &= (\tilde{m}_1 - \tilde{m}_2)^2 \\ &= (w^T m_1 - w^T m_2)(w^T m_1 - w^T m_2)^T \\ &= w^T (m_1 - m_2)(m_1 - m_2)^T w \\ &= w^T S_b w\end{aligned}$$

$$S_b = (m_1 - m_2)(m_1 - m_2)^T \in \mathbb{R}^{d \times d}$$



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (1) Fisher投影准则

- 为了寻找最优投影方向 w , 需要将优化目标函数进行改写。

$$J(w) = \frac{\tilde{S}_b}{\tilde{S}_w} = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1 + \tilde{S}_2}$$

- 对于分母

$$\begin{aligned}\tilde{S}_w &= \tilde{S}_1 + \tilde{S}_2 \\&= \sum_{y_1 \in \mathcal{Y}_1} (y_1 - \tilde{m}_1)^2 + \sum_{y_2 \in \mathcal{Y}_2} (y_2 - \tilde{m}_2)^2 \\&= \sum_{x_1 \in \mathcal{X}_1} (w^T x_1 - w^T m_1)^2 + \sum_{x_2 \in \mathcal{X}_2} (w^T x_2 - w^T m_2)^2 \\&= w^T \left[\sum_{x_1 \in \mathcal{X}_1} (x_1 - m_1)(x_1 - m_1)^T + \sum_{x_2 \in \mathcal{X}_2} (x_2 - m_2)(x_2 - m_2)^T \right] w \\&= w^T (S_1 + S_2) w \\&= w^T S_w w\end{aligned}$$

$$S_w = S_1 + S_2$$

$$S_i = \sum_{x_j \in \mathcal{X}_i} (x_j - m_i)(x_j - m_i)^T$$



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (1) Fisher投影准则

- 最终得到**二分类LDA的优化目标**：最大化 $J(w) = \frac{w^T S_b w}{w^T S_w w}$
- 从优化目标来看，如果直接对上式（分子分母都是二次型）进行优化，有无穷个满足要求的解。为了解决多解问题，需要**额外增加一个约束条件，限制解的个数**。
- 由于只关心投影的方向，对投影方向向量的模长不关心，并且上式分子分母的向量 w 数乘缩放不影响比值。因此将**优化问题更改如下**

$$\begin{aligned} \max \quad & w^T S_b w \\ \text{s.t.} \quad & w^T S_w w = c \neq 0 \end{aligned}$$



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (1) Fisher投影准则

$$\begin{aligned} \max w^T S_b w \\ s.t. w^T S_w w = c \neq 0 \end{aligned}$$

- 思考采用什么方法求解上述优化问题? (拉格朗日乘子法)

$$\begin{aligned} L(w, \lambda) &= w^T S_b w - \lambda(w^T S_w w - c) \\ \Rightarrow \frac{\partial L(w, \lambda)}{\partial w} &= 2S_b w - 2\lambda S_w w \end{aligned}$$

- 令上式等于零, 取到极大值

$$S_b w^* = \lambda S_w w^*$$

$$\lambda w^* = S_w^{-1} S_b w^* \quad S_w \text{ 可逆}$$

$$\lambda w^* = S_w^{-1} (m_1 - m_2)(m_1 - m_2)^T w^* \quad S_b \text{ 定义带入}$$



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (1) Fisher投影准则

$$S_b w^* = \lambda S_w w^*$$

$$\lambda w^* = S_w^{-1} S_b w^* \quad S_w \text{ 可逆}$$

$$\lambda w^* = S_w^{-1} (m_1 - m_2)(m_1 - m_2)^T w^* \quad S_b \text{ 定义带入}$$

标量, 不影响方向

- 因此最佳投影方向仅与前两项有关

$$w^* = S_w^{-1} (m_1 - m_2)$$

- 需要注意的是, Fisher 投影的最优解本身只给出了一个投影方向, 并没有给出需要的分类面。要得到分类面, 需要在投影后的方向 (一维空间) 上确定一个分类阈值。



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (1) Fisher投影准则小结

- 求解广义Rayleigh商

$$J(w) = \frac{w^T S_b w}{w^T S_w w}$$

- 得到最佳投影

$$w^* = S_w^{-1}(m_1 - m_2)$$

- 得到分类面 (决策规则)

$$g(x) = w^T x + w_0 > 0 \Rightarrow x \in y_1$$

$$g(x) = w^T x + w_0 < 0 \Rightarrow x \in y_2$$



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (2) 多类LDA

- 已知给定的 d 个原始特征。个特征
- 经过 W 投影得到 d' 个特征 ($d' \leq C - 1$, 其中 C 为类别数, 一般 $C - 1 < d$) 。
- 优化目标:

$$J(W) = \frac{W^T S_b W}{W^T S_w W}$$



$W^T S_b W$ 和 $W^T S_w W$ 均为矩阵, 不再是标量, 无法作为一个标量函数来优化

替换优化目标为



基于类内类间距离的可分性判据

$$J_1(W) = \max_W \frac{\text{tr}(W^T S_b W)}{\text{tr}(W^T S_w W)}$$

$$J_2(W) = \max_W \text{tr}[W^T (S_b + S_w) W]$$

$$J_3(W) = \max_W \ln \frac{|W^T S_b W|}{|W^T S_w W|}$$

$$J_4(W) = \max_W \text{tr} \left(\frac{W^T S_b W}{W^T S_w W} \right)$$

$$J_5(W) = \max_W \frac{|W^T (S_b + S_w) W|}{|W^T S_w W|}$$



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (2) 多类LDA

$$J_1(W) = \max_W \frac{\text{tr}(W^T S_b W)}{\text{tr}(W^T S_b W)}$$

$$J_2(W) = \max_W \text{tr}[W^T (S_b + S_w) W]$$

$$J_3(W) = \max_W \ln \frac{|W^T S_b W|}{|W^T S_w W|}$$

$$J_4(W) = \max_W \text{tr} \left(\frac{W^T S_b W}{W^T S_w W} \right)$$

$$J_5(W) = \max_W \frac{|W^T (S_b + S_w) W|}{|W^T S_w W|}$$



- 设矩阵 $S_w^{-1} S_b$ 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_d$ ，按照大小顺序排列为：

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$$

- 选择前 d' 个特征值对应的特征向量作为 W ，即：

$$W = [u_1, u_2, \dots, u_{d'}]$$

- 以上 W 就是在这些准则下的最优变换阵。

形式虽然不一样，但是得到的最优变换矩阵是相同的



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (2) 多类LDA

➤ 以 J_2 准则为例给出推导过程:

$$J_2(W) = \max_W \text{tr}[W^T(S_b + S_w)W] \quad (\text{公式1})$$

- 要最大化 J_2 , 重点关注变换的方向。为了解决以上问题, 仿照Fisher投影求解思路, 引入同样的约束条件:

$$\text{tr}(W^T S_w W) = c \quad (\text{公式2})$$

- 设 $c=1$, 此时优化问题变为: $\max J_2(W) \quad \text{s.t.} \quad \text{tr}(W^T S_w W) = 1 \quad (\text{公式3})$
- 利用拉格朗日方法将以上有约束的优化问题转化为无约束问题, 拉格朗日函数是:



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (2) 多类LDA

➤ 以 J_2 准则为例给出推导过程:

(公式4) $g(W) = J_2(W) - \text{tr}[\Lambda(W^T S_W W - I)]$ ←

I 是单位矩阵, Λ 是对角阵 (对角线元素是拉格朗日乘子)。

- 在拉格朗日函数极值点上, 应该满足 $\frac{\partial g(W)}{\partial W} = 0$, 由此得到:

$$S_W^{-1}(S_W + S_b)W = W\Lambda \quad (\text{公式5})$$

- 整理, 得到:

$$S_W^{-1}S_b W = W(\Lambda - I) \quad (\text{公式6})$$

可见, W 由 $S_W^{-1}S_b$ 的特征向量组成,
 $\Lambda - I$ 等于 $S_W^{-1}S_b$ 对应的特征值 λ_i 组成的
的对角阵, 即:

$$\Lambda = I + \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_{d'} \end{bmatrix}$$



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (2) 多类LDA

➤ 以 J_2 准则为例给出推导过程:

- 此时 J_2 准则可以表示为:
$$J_2(W) = \text{tr}[W^T (S_w + S_b) W] \quad \xrightarrow{\boxed{S_w^{-1} (S_w + S_b) W = W \Lambda}} \quad \text{(公式5)}$$
$$= \text{tr}(W^T S_w W \Lambda) \quad \xrightarrow{\boxed{\text{tr}(W^T S_w W) = 1}} \quad \text{(公式2)}$$
$$= \text{tr}(\Lambda)$$

- 那么, 对于 $d \times d'$ 变换矩阵

$$\text{(公式7)} \quad J_2(W) = \sum_{i=1}^{d'} (1 + \lambda_i) \quad \xrightarrow{\boxed{\Lambda = I + \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_{d'} \end{bmatrix}}}$$

- 推导小结: 最优的变换阵 W 由 $S_w^{-1} S_b$ 的前 d' 个特征值所对应的特征向量组成, 而 J_2 准则值由公式(7)定义, 其中 $\lambda_i, i = 1, \dots, d'$ 为 $S_w^{-1} S_b$ 的从大到小排列的前 d' 个特征值。



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)

➤ (3) LDA算法流程小结

输入：原始样本集 $A = \{(x_i, y_i)\}$, 样本 $i=1, \dots, n$, $x_i \in R^d$ (d 维度向量), y_i 代表样本类别, 包含 C 类。需要将特征降维到 d' 维;

输出：降维后的样本集 A'

步骤1: 计算原始样本集类内离散度矩阵 S_w ;

步骤2: 计算原始样本集类间离散度矩阵 S_b ;

步骤3: 计算矩阵 $S_w^{-1} S_b$;

步骤4: 计算 $S_w^{-1} S_b$ 最大的 d' 个特征值和对应的 d' 个特征向量 $u_1, u_2, \dots, u_{d'}$, 得到投影矩阵 $W = [u_1, u_2, \dots, u_{d'}]$;

步骤5: 对原始样本集中的每个样本特征 x_i , 转换为新的样本特征 $z_i = W^T x_i$, 得到新的样本集 $A' = \{(z_i, y_i)\}$, 样本 $i=1, \dots, n$



5.4 特征提取

2、线性判别分析 (Linear Discriminant Analysis, LDA)



➤ (3) LDA特点

- 有监督，在降维过程中可以使用类别的先验知识（均值，协方差）。
- 可以得到有利于分类的投影方向。
- 在样本分类信息依赖均值时效果更好。
- 但不适合非高斯分布样本进行降维。
- 分类信息依赖方差而不是均值时效果不佳。
- 可能存在过拟合。

当两类数据的均值差异较大，但协方差矩阵十分接近时LDA 分类效果好于 PCA



特征1



分类信息依赖方差而不是均值时效果不佳（两类数据均值接近，方差差异大）



5.4 特征提取

3、主成分分析 (Principal Components Analysis, PCA)

- 一种典型的线性降维方法;

$$z = W^T x$$

- 通过正交变换将原始数据 (d 维) 投影到新的维度空间 (d' 维), 用较少的维度包含了原始数据中的绝大部分信息。即, PCA提取出空间原始数据中的主要特征, 减少数据冗余。
- 是一种无监督特征提取方法 (特征向量类别未知)。



5.4 特征提取

3、主成分分析 (Principal Components Analysis, PCA)

➤ PCA思想的出发点

- 对于正交属性空间中的样本点，如何用一个超平面对所有样本进行恰当的表达或表征？

➤ 理想超平面的性质

- **最近重构性**：样本点到这个超平面的距离都足够近。
- **最大可分性**：样本点在这个超平面上的投影能尽可能分开。
- 基于最近重构性和最大可分性，能分别得到PCA的两种等价推导。



5.4 特征提取

3、主成分分析 (Principal Components Analysis, PCA)

➤ 最近重构性

- 对样本进行中心化, 有 $\sum_i x_i = 0$
- 投影变换后得到的新坐标系为 $\{w_1, w_2, \dots, w_d\}$
- w_i 是标准正交基向量, 有 $\|w_i\|_2 = 1, w_i^T w_j = 0 (i \neq j)$
- 降维到 d' , 则样本点 x_i 在低维坐标系中的投影 $z_i = (z_{i1}; z_{i2}; \dots; z_{id'})$
- 其中, $z_{ij} = w_j^T x_i$ 是 x_i 在低维坐标下第 j 维的坐标。
- 基于在 d' 维的投影对 x_i 进行重构: $x_i' = \sum_{j=1}^{d'} z_{ij} w_j$

优化目标: 最小化 m 个样本点的重构误差 $\sum \|x_i' - x_i\|_2^2 \Rightarrow \sum_{i=1}^m \left\| \sum_{j=1}^{d'} z_{ij} w_j - x_i \right\|_2^2$



5.4 特征提取

3、主成分分析 (Principal Components Analysis, PCA)

➤ 最近重构性

- 重构误差可展开为

$$\sum_{i=1}^m \left\| \sum_{j=1}^{d'} z_{ij} \mathbf{w}_j - \mathbf{x}_i \right\|_2^2 \stackrel{\text{标量}}{=} \sum_{i=1}^m \mathbf{z}_i^T \mathbf{z}_i - 2 \sum_{i=1}^m \mathbf{z}_i^T \mathbf{W}^T \mathbf{x}_i + \text{const}$$
$$\propto -\text{tr} \left(\mathbf{W}^T \left(\sum_{i=1}^m \mathbf{x}_i \mathbf{x}_i^T \right) \mathbf{W} \right).$$

涉及到大量矩阵知识,
这里不做详细展开

- 希望最小化重构误差, 此时优化问题可描述为

协方差矩阵, 可表示为 $\mathbf{X}\mathbf{X}^T$

$$\begin{aligned} \min \quad & -\text{tr}(\mathbf{W}^T \mathbf{X}\mathbf{X}^T \mathbf{W}) \\ \text{s.t.} \quad & \mathbf{W}^T \mathbf{W} = \mathbf{I}. \end{aligned}$$



等价

$$\begin{aligned} \max \quad & \text{tr}(\mathbf{W}^T \mathbf{X}\mathbf{X}^T \mathbf{W}) \\ \text{s.t.} \quad & \mathbf{W}^T \mathbf{W} = \mathbf{I}. \end{aligned}$$



5.4 特征提取

3、主成分分析 (Principal Components Analysis, PCA)


➤ 最大可分性

- 所有样本点的投影能尽可能分开, 则投影后样本点方差最大。
- 样本点 x_i 的投影为 $W^T x_i$
- 投影前样本进行了**中心化操作**, 均值为 0
- 所以投影后样本点的方差为

$$\begin{aligned}\sum_i (W^T x_i)^2 &= \sum_i \text{tr}(W^T x_i (W^T x_i)^T) \\ &= \sum_i \text{tr}(W^T x_i x_i^T W) = \text{tr}(W^T X X^T W)\end{aligned}$$

- 使**训练集上方差最大**的优化目标, 即为

$$\begin{aligned}\max \quad & \text{tr}(W^T X X^T W) \\ \text{s. t.} \quad & W^T W = I.\end{aligned}$$





5.4 特征提取

3、主成分分析 (Principal Components Analysis, PCA)

➤ PCA求解

$$\begin{aligned} \max \quad & \text{tr}(W^T X X^T W) \\ \text{s.t.} \quad & W^T W = I. \end{aligned}$$

- 拉格朗日乘子法，并令关于W的偏导数为零，得到：

$$X X^T W = \lambda W$$

- 对协方差矩阵 $X X^T$ 进行特征值分解
- 求得特征值排序 $\lambda_1 \geq \lambda_2 \geq \dots \lambda_d$
- 取前 d' 个特征值对应的特征向量构成 PCA 的解 $W = (w_1, w_2, \dots, w_{d'})$

最近重构性

$$\min_W -\text{tr}(W^T X X^T W)$$

$$\text{s.t. } W^T W = I.$$

最大可分性

$$\max_W \text{tr}(W^T X X^T W)$$

$$\text{s.t. } W^T W = I.$$

等价



5.4 特征提取

3、主成分分析 (Principal Components Analysis, PCA)

➤ PCA求解的一般流程

输入：d维的样本集 A ，要降维到的维数 d'

输出：降维后的样本集 A' 。

步骤1：对原样本集 A 中所有的样本进行中心化；

步骤2：计算中心化后样本的协方差矩阵 XX^T ；

步骤3：对以上协方差矩阵 XX^T 进行特征值分解；

步骤4：取出最大的 d' 个特征值对应的特征向量，并将所有特征向量标准化后，组成特征向量矩阵 $W = (w_1, w_2, \dots, w_{d'})$ ；

步骤5：利用特征向量矩阵 W ，将原样本集 A 中的每个样本转化为新的样本 $z = W^T x$ ，输出新的样本集 A' 。



5.4 特征提取

3、主成分分析 (Principal Components Analysis, PCA)

➤ PCA特点

- 求解协方差矩阵 XX^T 的特征值对应的特征向量。
- 一个矩阵有多个特征值，**一个特征值对应一个主成分**。
- 特征值最大的主成分包含原始数据的信息最多，从而可对新特征排列——“重要性”。
- 各个主成分之间线性无关，即新特征之间不相关——正交变换。
- 不考虑样本的类别——非监督方法。




5.4 特征提取

3、主成分分析 (Principal Components Analysis, PCA)

➤ PCA应用举例

- 10个人的人脸图像数据集。



- PCA变换后得到的特征脸。







5.4 特征提取

3、主成分分析 (Principal Components Analysis, PCA)

➤ PCA应用举例



520波段高光谱图像中的6个波段



对520个数据进行PCA变换后, 第1、2、10个主成分



5.4 特征提取

4、K-L变换

➤ K-L变换来源

- K-L变换 (Karhunen-Loeve) 是由H.Karhunen和M.Loeve等人最早提出来的，用于处理随机过程中的连续信号的去相关问题。

➤ 离散K-L变换

- 1933年，霍特林 (Hotelling) 提出了一种离散信号的去相关线性变换，称为霍特林变换，它实际是K-L级数展开的离散等效方法。因此，霍特林变换也可以称为离散K-L变换。
- 习惯上，**不论对连续或离散信号，这种去相关变换，统称为Karhunen-Loeve(K-L)变换或Hotelling变换。**



5.4 特征提取

4、K-L变换

➤ K-L变换原理

- 模式识别中的一个样本可以看作是随机向量的一次实现。对一个 m 维随机向量 x ，可以用确定的完备归一化正交向量系 $\{u_i\}_{i=1}^{\infty}$ 来展开

$$x = \sum_{i=1}^{\infty} a_i u_i, a_i \in \mathbb{R} \quad \text{公式 (1)}$$

x 表示成 u_i 的线性组合，且有 $u_i^T u_j = \begin{cases} 1, i = j \\ 0, i \neq j \end{cases}$

a_i 是线性组合的系数，将以上公式两边同时左乘 u_i^T ，得到 $a_i = u_i^T x$

- 如果用有限的 d 项 ($d < m$) 来逼近 x ，即 $\hat{x} = \sum_{i=1}^d a_i u_i$



5.4 特征提取

4、K-L变换

➤ K-L变换原理

- 则与原向量 x 的均方误差为

$$\begin{aligned}\xi &= E\left[(x - \hat{x})^T (x - \hat{x})\right] = E\left[\left(\sum_{i=d+1}^{\infty} a_i u_i\right)^T \left(\sum_{i=d+1}^{\infty} a_i u_i\right)\right] \\ &= E\left(\sum_{i=d+1}^{\infty} u_i^T x x^T u_i\right) = \sum_{i=d+1}^{\infty} u_i^T E(x x^T) u_i = \sum_{i=d+1}^{\infty} u_i^T R u_i\end{aligned}$$

公式 (2)

- 其中, $R = E(x x^T)$ 为自相关矩阵。
- 选取不同的正交向量系 (d 维正交坐标系) 对应不同的均方误差, 其选择应该使得均方误差最小。希望在正交归一的向量系中最小化以上均方误差, 求解如下优化问题

$$\min \quad \xi = \sum_{i=d+1}^{\infty} u_i^T R u_i \quad s.t. \quad u_i^T u_i - 1 = 0, \forall i \quad \text{公式 (3)}$$



5.4 特征提取

4、K-L变换

$$\min \quad \xi = \sum_{i=d+1}^{\infty} \mathbf{u}_i^T \mathbf{R} \mathbf{u}_i \quad \text{s.t.} \quad \mathbf{u}_i^T \mathbf{u}_i - 1 = 0, \forall i \quad \text{公式 (3)}$$

► K-L变换原理

- 利用拉格朗日乘子法求解，构建如下拉格朗日函数：

$$J(\mathbf{u}_i) = \sum_{i=d+1}^{\infty} \mathbf{u}_i^T \mathbf{R} \mathbf{u}_i - \sum_{i=d+1}^{\infty} \lambda_i (\mathbf{u}_i^T \mathbf{u}_i - 1) \quad \text{公式 (4)}$$

- 对 $\mathbf{u}_i$ 求导，并令导数为零，得到

$$(\mathbf{R} - \lambda_i \mathbf{I}) \mathbf{u}_i = 0, i = d + 1, \dots, \infty \quad \text{公式 (5)}$$

即， $\mathbf{u}_i$ 是矩阵 $\mathbf{R}$ 的特征向量且满足

$$\mathbf{R} \mathbf{u}_i = \lambda_i \mathbf{u}_i \quad \lambda_i \text{是矩阵} \mathbf{R} \text{的特征值} \quad \text{公式 (6)}$$

- 与此同时，结合公式(2)、(3)和(6)，均方误差 ξ 可以表示为：

$$\xi = \sum_{d+1}^{\infty} \mathbf{u}_i^T \mathbf{R} \mathbf{u}_i = \sum_{d+1}^{\infty} \mathbf{u}_i^T \lambda_i \mathbf{u}_i = \sum_{d+1}^{\infty} \lambda_i \quad \text{公式 (7)}$$



5.4 特征提取

4、K-L变换

➤ K-L变换原理

$$\xi = \sum_{d+1}^{\infty} \mathbf{u}_i^T \mathbf{R} \mathbf{u}_i = \sum_{d+1}^{\infty} \mathbf{u}_i^T \lambda_i \mathbf{u}_i = \sum_{d+1}^{\infty} \lambda_i \quad \text{公式 (7)}$$

- 要用 d 个向量表示样本，使得均方误差 ξ 最小，则应该将样本自相关矩阵 R （ $R = E(\mathbf{x}\mathbf{x}^T)$ ）的特征值按从大到小的顺序排列，**选择前 d 个特征值对应的特征向量，此时截断误差是在所有用 d 维正交坐标系展开中最小的。**
- **$\mathbf{u}_i, i=1,2,\dots,d$ 组成了新的特征空间**，样本 $\mathbf{x}$ 在该特征空间上的展开系数 $c_i = \mathbf{u}_i^T \mathbf{x}$ ，此时就组成了样本的新的特征向量。
- 以上特征提取方法称为K-L变换，**自相关矩阵 R 被称为K-L变换的产生矩阵。**



5.4 特征提取

4、K-L变换

➤ 产生矩阵的多种形式

- 自相关矩阵 $R = E(xx^T) \approx \frac{1}{n} \sum_{i=1}^n x_i x_i^T$

- 协方差矩阵 $\Sigma = E[(x - \mu)(x - \mu)^T]$

无类别标
签样本集

此时K-L变换与PCA等价

- 总类内离散度矩阵 $S_w = \sum_{i=1}^c P_i \Sigma_i$
 $\Sigma_i = E[(x_i - \mu_i)(x_i - \mu_i)^T]$

有类别标
签样本集

K-L变换可以有监督的，也可以是无监督的




5.4 特征提取


5、流形学习

➤ 线性降维的问题:


$$z = W^T x$$



样本三维分布



理想二维分布



PCA结果

➤ 需要研究非线性降维方法





5.4 特征提取

5、流形学习

➤ 流形的数学概念

- **流形是局部具有欧几里得空间性质的拓扑空间**，也就是流形是在局部与欧氏空间同胚的空间。
- 流形在局部空间有欧式空间的性质，能用欧式空间来进行距离计算。
- **流形是欧几里得空间中的曲线、曲面等概念的推广。**









5.4 特征提取

5、流形学习

➤ 流形的直观理解



比如对于球面上的一个点（三维空间中的点），可以用一个三元组

$$(x, y, z)$$

来表示其坐标。

但事实上，这个三维的坐标只由两个变量

$$(\theta, \varphi)$$

表示的，也可以说成它的自由度是2，正好对应了一个二维的流形。

$$x = x_0 + r \sin \theta \cos \varphi$$

$$y = y_0 + r \sin \theta \sin \varphi \quad (0 \leq \varphi \leq 2\pi \text{ and } 0 \leq \theta \leq \pi)$$

$$z = z_0 + r \cos \theta$$



5.4 特征提取

5、流形学习

➤ 流形学习的定义

- 是一类借鉴了拓扑流形概念的降维方法，从高维数据中发现/恢复低维的非线性结构（流形结构）。

➤ 流形学习的原理

- 若低维流形嵌入到高维空间中，则数据样本在高维空间的分布虽然看上去非常复杂，但高维空间在局部上仍具有欧氏空间的性质，因此，可以容易地在局部建立降维映射关系，然后再设法将局部映射关系推广到全局，最终实现降维。

➤ 流形学习的应用

- 当维数被降至二维或三维时，能对数据进行可视化展示，因此流形学习也可被用于可视化。

流形学习在处理非线性数据结构时特别有效，它能够揭示数据背后的复杂关系，而不仅仅是通过线性变换来简化数据。





5.4 特征提取


5、流形学习

例：2000年在Science杂志上发表的研究成果指出：

人的视觉感知以流形方式存在



旋转图像序列的
低维流形结构
的可视化





5.4 特征提取

5、流形学习


➤ 流形学习的问题定义

流形学习

寻找低维
嵌入结构

发现映射
关系

设 $Y \subset \mathbb{R}^d$ 是一个低维流形, $f: Y \rightarrow \mathbb{R}^D$ 是一个光滑嵌入, 其中 $D > d$, Y 中的数据集为 $\{y_i\}$, 经过 f 映射为观察空间的数据 $\{x_i = f(y_i)\}$, 流形学习就是**给定 $\{x_i\}$ 的条件下重构 f 和 $\{y_i\}$** 。





5.4 特征提取

5、流形学习

➤ 多维尺度变换 (multi-dimensional scaling, MDS) :

- 是一种很**经典的数据映射方法**，将定义在多维空间中的样本间关系按比例缩放到二维或三维空间中展示出来。
- 该方法出发点：不是直接将样本从一个空间映射到另外一个空间，而是**根据样本之间的距离关系或不相似度关系在低维空间（二维或三维空间）里生成对样本的一种表示，实现原特征空间到低维表示空间的变换。**
- 分为**度量型 (metric)** 和**非度量型(non-metric)**两种类型




5.4 特征提取

5、流形学习

➤ 多维尺度变换 (multi-dimensional scaling, MDS) :


- a) **度量型MDS**把样本间的距离或不相似度看作一种定量的度量, 希望在低维空间里的表示能够尽可能保持这种度量关系。
- b) **非度量型MDS**把样本间的距离或不相似度关系仅仅看作是一种定性的关系, 在低维空间里的表示只需要保持这种关系的顺序。



低维空间中任意两点间的距离应该与它们在原高维空间中的距离相同




度量型MDS





5.4 特征提取

5、流形学习



➤ 多维尺度变换 (multi-dimensional scaling, MDS) :

- 度量型MDS

- ✓ 已知一组样本两两之间的不相似度量 δ_{ij} (可以是某种距离度量), 要用某个低维空间中一组点来表示这组样本, 这组点在低维空间中两两之间的距离是 d_{ij} , 希望所得到的低维空间表示能使 d_{ij} 尽可能地代表 δ_{ij} 。

- ✓ 可以采用 δ_{ij} (称作给定距离) 平方与 d_{ij} (称作表示距离) 平方之间的平均误差

$$\min \sum_{i,j} (\delta_{ij}^2 - d_{ij}^2) \text{ 作为目标函数。}$$

- 低维空间: 使用欧氏距离度量样本间关系 → (推广到高维) → 高维空间: 使用欧氏距离?
- 思考, 这样有什么弊端?




5.4 特征提取

5、流形学习

➤ 1) 等度量映射 (Isometric Mapping, Isomap)

低维流形嵌入到高维空间之后，直接在高维空间中计算直线距离具有误导性（因为高维空间中的直线距离在低维嵌入流形上不可达）。而低维嵌入流形上两点间的本真距离是“测地线” (geodesic) 距离。



如何计算两点之间的测地距离？ 利用流形在局部上与欧式空间同胚这个性质，对于每个点基于欧式距离找出其最近邻点，然后就能建立一个**近邻连接图**，于是计算两点之间的测地距离的问题，就转变成为计算**近邻连接图**上两点之间的最短路径问题（**Dijkstra算法**）




5.4 特征提取


5、流形学习

➤ 1) 等度量映射 (Isometric Mapping, Isomap)

Isomap 通过保持数据点之间的测地距离来保留流形结构。利用数据点之间的近邻关系建立近邻连接图，并计算出数据点在流形上的近似测地距离，然后将数据映射到一个更低维空间，在此低维空间中的欧式距离和高维空间近似测地距离保持近乎一致。



映射到更低维空间





5.4 特征提取

5、流形学习

➤ 1) 等度量映射 (Isometric Mapping, Isomap)

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;

近邻参数 k ;

低维空间维数 d' .

过程:

1: **for** $i = 1, 2, \dots, m$ **do**

2: 确定 $\mathbf{x}_i$ 的 k 近邻;

3: $\mathbf{x}_i$ 与 k 近邻点之间的距离设置为欧氏距离, 与其他点的距离设置为无穷大;

4: **end for**

建立近邻连接图

5: 调用最短路径算法计算任意两样本点之间的距离 $\text{dist}(\mathbf{x}_i, \mathbf{x}_j)$; **测地距离**

6: 将 $\text{dist}(\mathbf{x}_i, \mathbf{x}_j)$ 作为 MDS 算法的输入;

7: **return** MDS 算法的输出

输出: 样本集 D 在低维空间的投影 $Z = \{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_m\}$.



5.4 特征提取


5、流形学习

➤ 2) 局部线性嵌入 (Locally Linear Embedding, LLE)

- **Isomap**算法是全局的，它要找到所有样本的全局最优解，当数据量很大时或者样本维度很高时，计算量非常大。因此更常用的算法是局部线性嵌入，**LLE**放弃所有样本全局最优的降维，只是**通过保证局部最优（保持邻域内样本之间的关系）来降维**。

LLE的两个基本假设：

- 一个流形的局部可以近似于一个欧式空间
- 每个样本都可以利用其邻居进行线性重构





5.4 特征提取

5、流形学习

➤ 2) 局部线性嵌入 (Locally Linear Embedding, LLE)

- Isomap算法是全局的，它要找到所有样本的全局最优解，当数据量很大时或者样本维度很高时，计算量非常大。因此更常用的算法是局部线性嵌入，LLE放弃所有样本全局最优的降维，只是通过保证局部最优来降维。

LLE的两个基本假设：

- 一个流形的局部可以近似于一个欧式空间
- 每个样本都可以利用其邻居进行线性重构

LLE算法通过构造样本点和它的邻域点之间的权向量，并在低维空间保持每个邻域中的权值不变来实现降维



5.4 特征提取

5、流形学习

➤ 2) 局部线性嵌入 (Locally Linear Embedding, LLE)

• 算法步骤

- ① 求取每个特征样本 x_i 的 k 个邻域点, 从而构成邻域集 $X_i = [x_{i1}, x_{i2}, \dots, x_{ik}]$
- ② 计算 x_i 与它的某个邻域点 x_{ij} 之间的权重 w_{ij} , 使得把 x_i 用它的 k 个近邻点线性表示误差最小, 即**通过最小化重构误差来求出权重**, 重构优化问题如下

$$\min_w \sum_{i=1}^N \left\| x_i - \sum_{j=1}^k w_{ij} x_{ij} \right\|^2 \quad s. t. \quad \sum_{j=1}^k w_{ij} = 1 \quad N \text{ 表示总样本数}$$

$W_{k \times N} = (w_1, w_2, \dots, w_N)$ $w_i = (w_{i1}, w_{i2}, \dots, w_{ik})^T$ 表示样本 x_i 的 k 近邻权重的列向量



具有解析解



5.4 特征提取

5、流形学习

➤ 2) 局部线性嵌入 (Locally Linear Embedding, LLE)

• 算法步骤

- ③ 映射到低维空间 R^d 时, 保持权重 w_{ij} 不变, 即求 x_i 在低维空间的映射 y_i , 使得低维重构误差最小, 其中重构误差为

$$\min_Y \sum_{i=1}^N \left\| y_i - \sum_{j=1}^k w_{ij} y_{ij} \right\|^2 \quad s. t. \quad \sum_{i=1}^N y_i = 0 \quad \frac{1}{N} \sum_{i=1}^N y_i y_i^T = I_{d \times d}$$

对降维后的样本集进行标准化, 即降维后的样本特征均值为0, 标准差为1, 特征间的协方差为0

以上目标函数还可以写成矩阵的形式并展开

$$\sum_{i=1}^N \left\| y_i - \sum_{j=1}^k w_{ij} y_{ij} \right\|^2 = \|Y - WY\|^2 = \|Y(I - W)\|^2 = \text{tr}(Y^T(I - W)^T(I - W)Y)$$



5.4 特征提取

5、流形学习

➤ 局部线性嵌入 (Locally Linear Embedding, LLE)

$$\sum_{i=1}^N \left\| \mathbf{y}_i - \sum_{j=1}^k w_{ij} \mathbf{y}_{ij} \right\|^2 = \|Y - WY\|^2 = \|Y(I - W)\|^2 = \text{tr}(Y^T \underline{(I - W)^T(I - W)} Y)$$

④ 将优化问题转化为特征分解问题，定义矩阵 $M = (I - W)^T(I - W)$ ，优化问题写为

$$\min_Y \text{tr}(Y^T M Y)$$

⑤ 在 $Y^T Y = I$ 约束下，这个优化问题的解是矩阵 $M = (I - W)^T(I - W)$ 最小特征值的特征向量。对 M 进行特征分解，求出前 d 个最小非零特征值所对应的特征向量 $y_1, y_2, \dots, y_d$ ，从而组成低维嵌入矩阵 $Y = [y_1, y_2, \dots, y_d]$



5.4 特征提取

5、流形学习

➤ 局部线性嵌入 (Locally Linear Embedding, LLE)

- 优点

- 有解析的全局最优解，不需要迭代，低维嵌入的计算归结为稀疏矩阵特征值的计算，从而具有较小的计算复杂度。
- 能保证每个点的近邻权值在平移、旋转、伸缩变换下保持不变。
- 可以直接在训练样本中产生一个嵌入

- 缺点

- 无法产生一个显式的变换矩阵或函数
- 当有新的样本数据时，很难在嵌入空间找到该样本的图像，需要重新学习以产生新嵌入



作业

1、什么是特征提取，什么是特征选择，二者有什么异同？

2、试比较 LDA 和 PCA 降维的异同点

提示：

- ① 从是否利用特征向量标签的角度分析
- ② 从变换是否线性的角度分析
- ③ 从能够降低到的最低维数来分析
- ④ 从二者的优缺点方面来分析



北京航空航天大学
BEIHANG UNIVERSITY

德才兼备 知行合一

The end