



北京航空航天大学
BEIHANG UNIVERSITY

模式识别

第六章 无监督分类器

北京航空航天大学宇航学院



主要内容

6.1 引言

6.2 聚类原理

6.3 分级聚类

6.4 动态聚类

6.5 基于密度的聚类

6.6 模糊聚类



6.1 引言

【监督】

对于大多数统计模式识别问题，如果**训练样本集**中的每个**样本**的所属**类别**是**已知的**，称为**样本带标签**，对应的模式识别问题称为监督问题，对应的模式识别方法称为监督方法。

【无监督】

对于某些统计模式识别问题，如果**训练样本集**中的每个**样本**的所属**类别**是**未知的**，称为**样本不带标签**，对应的模式识别问题称为非监督问题，对应的模式识别方法称为**无监督方法**，也叫**非监督方法**。

聚类是最常见的无监督方法。



6.1 引言

【无监督学习可以用在两种场合】

- a) 直接对无标签的待分样本集划分子集；
- b) 对无标签的训练样本集划分子集，然后将这些子集视为**带标签的训练样本集**，从而利用前几章的方法设计分类器。



6.1 引言

【为什么要研究非监督学习问题】

获取带标签的训练样本集难度大

物体类别（种类）：

1000

图像：

1.2M训练

100k测试





6.1 引言

无监督模式识别的过程：

- 1) **原始特征获取**。对样本进行观测和预处理，获得样本的原始特征。
- 2) **特征提取与选择**。采用一定的算法对原始特征进行提取和选择。
- 3) **聚类**。选择相关的无监督模式识别方法，利用样本进行聚类分析。
- 4) **结果分析**。对聚类的结果进行评价；对聚类结果的合理性进行分析和解释；






6.1 引言

例：多光谱遥感图像的无监督分类

遥感图像分类的目的是区分图像中不同种类的地物，具有同种特性的地物集合成为一类，一类地物具有同一标志，**不同种类地物具有不同的光谱特性。**



多光谱遥感图像



聚类结果




6.1 引言

例：多光谱遥感图像的无监督分类

- ① 确定地物类别数；
- ② 选择相似性测度；
- ③ 利用聚类算法将像素分割为若干具有相同光谱特性的集合；
- ④ 对分割后的结果进行统计分布特性评估。



多光谱遥感图像



聚类结果



6.2 聚类原理


6.2.1 聚类分析

6.2.2 相似性测度

6.2.3 聚类准则函数

6.2.4 聚类方法

6.2.5 小结





6.2 聚类原理

1、聚类分析

一种常用的无监督学习方法，该方法基于样本之间的**相似和靠近程度**，对**无标签的样本**进行逐步聚合（称为聚类Clustering），实现子集的划分。

➤ **聚类的过程：**

- 迭代算法

➤ **假设条件：**

- 同类**样本相互 **“靠近”**
- 异类**样本相互 **“远离”**



6.2 聚类原理

2、相似性测度

- 聚类过程基于样本之间的相似和靠近程度来逐步进行，因此，用来**衡量样本间的相似性程度的数学度量或测度**，称为相似性测度。
- 利用样本间的相似性测度值对样本进行归类或子集划分，从而实现聚类。
 - (1) 欧氏距离
 - (2) 明氏距离
 - (3) 马氏距离
 - (4) 互相关函数



6.2 聚类原理

2、相似性测度

设 x 为 x' 两个样本的特征向量， d 为样本空间维数。

(1) 欧氏距离

- 又称为欧几里得度量 (Euclidean Metric) , 定义于欧几里得空间中

$$D = ||x - x'||_2 = \sqrt{\sum_{i=1}^d |x_i - x_i'|^2}$$

- 是最常见的两点之间或多点之间的距离表示方法
- 在聚类中多数采用该距离测度

问题分析：将样本的不同属性（即各变量）之间的差别等同看待，未区分不同属性差异。实际应用中可通过特征归一化方式，减少该问题。



6.2 聚类原理

2、相似性测度

设 x 为 x' 两个样本的特征向量， d 为样本空间维数。

(2) 明氏距离

$$M'(x, x') = \left(\sum_{i=1}^d |x_i - x_i'|^q \right)^{\frac{1}{q}} \quad \text{其中 } q \geq 1$$

➤ 当 $q = 1$ 时，明氏距离等价于曼哈顿距离。

$$M'(x, x') = \sum_{i=1}^d |x_i - x_i'|$$

➤ 当 $q = 2$ 时，明氏距离等价于欧氏距离。

➤ 当 $q = \infty$ 时，明氏距离等价于切比雪夫距离。

$$M'(x, x') = \max_{1 \leq i \leq n} |x_i - x_i'|$$



6.2 聚类原理

2、相似性测度

设 x 为 x' 两个样本的特征向量， d 为样本空间维数。

(3) 马氏距离

马氏距离 (Mahalanobis Distance) 是由马哈拉诺比斯 (P. C. Mahalanobis) 提出的，**表示数据的协方差距离**。它是一种有效的计算两个未知样本集的相似度的方法。

$$M(x, x') = ((x - x')^T \Sigma^{-1} (x - x'))^{\frac{1}{2}}$$

Σ 为**样本集的协方差矩阵**。当协方差矩阵为单位矩阵时，马氏距离简化为欧氏距离；当协方差矩阵为对角阵时，各特征完全相互独立。



6.2 聚类原理

2、相似性测度

- **方差**：方差是标准差的平方，而标准差的意义是数据集中各个点到均值点距离的平均值。**反映了数据的离散程度。**
- **协方差**：当存在多维数据时，需要知道每个维度的变量中间是否存在关联。协方差是**衡量多维数据集中变量之间相关性的统计量。**
- **协方差矩阵**：用协方差矩阵来**衡量多个变量之间的相关性。**

假设 X 是以 n 个随机变量（其中的每个随机变量是也是一个向量，**是一个行向量**）组成的列向量： $X =$

$$\begin{bmatrix} X_1 \\ X_2 \\ \cdot \\ \cdot \\ \cdot \\ X_n \end{bmatrix}$$



6.2 聚类原理

2、相似性测度

令 μ_i 是第 i 个元素的期望值, 即 $\mu_i = E(X_i)$, 则**协方差矩阵**定义为:

$$\Sigma = \begin{bmatrix} E[(X_1 - \mu_1)(X_1 - \mu_1)] & E[(X_1 - \mu_1)(X_2 - \mu_2)] & \cdot & \cdot & \cdot & E[(X_1 - \mu_1)(X_n - \mu_n)] \\ E[(X_2 - \mu_2)(X_1 - \mu_1)] & E[(X_2 - \mu_2)(X_2 - \mu_2)] & \cdot & \cdot & \cdot & E[(X_2 - \mu_2)(X_n - \mu_n)] \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot & \cdot & \cdot \\ E[(X_n - \mu_n)(X_1 - \mu_1)] & E[(X_n - \mu_n)(X_2 - \mu_2)] & \cdot & \cdot & \cdot & E[(X_n - \mu_n)(X_n - \mu_n)] \end{bmatrix}$$

协方差矩阵中的第 (i, j) 个元素是 X_i 与 X_j 的协方差。



6.2 聚类原理


2、相似性测度

- **举例：**假设以厘米为单位来测量人的身高，以克为单位测量人的体重，每个人被表示为一个两维向量，如一个人身高173cm，体重50000g (50kg)，表示为 $(173, 50000)$ ，根据身高体重的信息来判断体型的相似程度。

已知小明 $(160, 60000)$ ；小王 $(160, 59000)$ ；小李 $(170, 60000)$ 。

利用欧氏距离判断，则小明与小李体型相似；协方差归一化，则小明与小王相似。

(不同特征的度量标准之间存在差异会导致判断出错)






6.2 聚类原理

2、相似性测度

- 当求距离时，由于随机向量的每个分量之间量级不一样。例如 x_1 可能取值范围只有零点几，而 x_2 有可能时而是2000，时而是3000，因此两个变量的离散度具有很大差异；
- 马氏距离通过除以协方差矩阵，将各个分量之间的方差除掉了，**消除了量纲影响。**





6.2 聚类原理

2、相似性测度

(4) 互相关函数可作为聚类的相似性测度

➤ 角度相关系数

$$\cos(x, x') = \frac{x^T x'}{\|x\| \cdot \|x'\|} = \frac{x^T x'}{[(x^T x)(x'^T x')]^{\frac{1}{2}}}$$

表征两个向量的夹角余弦。两个向量越相似，该值越接近1，越不相似，该值越接近-1。



6.2 聚类原理

2、相似性测度

(4) 互相关函数可作为聚类的相似性测度

➤ 皮尔逊相关系数

$$r(x, x') = \frac{(x - \bar{x})^T (x' - \bar{x}')}{[(x - \bar{x})^T (x - \bar{x})(x' - \bar{x}')^T (x' - \bar{x}')]^{\frac{1}{2}}}$$

其中 $\bar{x}$ 和 $\bar{x}'$ 分别为这两个样本集的平均向量。

- ① 两个向量之间的协方差除以它们各自标准差的乘积。系数的取值总是在-1.0到1.0之间。
- ② 当相关系数的绝对值越大，相关性越强。当相关系数为0时，两向量之间不相关（不存在线性关系）。



6.2 聚类原理

3、聚类准则函数

➤ 准则1：误差平方和准则（简单且应用广泛的准则函数）

设有样本集合 $Z = \{x_1, x_2, \dots, x_n\}$ ；要划分成 C 个不相交的子集 $Z_1, Z_2, \dots, Z_C$

令 N_i 表示子集 Z_i 中样本的数量， m_i 表示子集 Z_i 样本的均值向量：
$$m_i = \frac{1}{N_i} \sum_{x \in Z_i} x$$

误差平方和准则定义为： $J_e = \sum_{i=1}^C \sum_{x \in Z_i} \|x - m_i\|^2$

- 一个好的聚类方法应能使每个子集中的所有向量与这个均值向量的“误差向量”长度平方之和最小。
- J_e 的值取决于类别的数目和样本的分布情况，**使得该值最小的划分应该是最优的聚类，或称为最小方差聚类。**




6.2 聚类原理


3、聚类准则函数

➤ 准则1：误差平方和准则


- **误差平方和准则适用于**各类样本比较密集且样本数目差异不大的情况
- **当不同类型的样本数目相差很大**，如果采用误差平方和准则，有可能把样本数目多的类型分开，以使得总的 J_e 最小：



比较密集且样本数目差异不大的情况



合理聚类，但 J_e 值较大



不合理聚类，但 J_e 值较小

不同类型的样本数目相差很大



6.2 聚类原理

3、聚类准则函数

➤ 准则2：离散度准则

离散度矩阵**不仅**反映同类样本的聚合程度，**而且**也反映不同类之间的分离程度。因此，可以利用离散度矩阵来定义离散度准则，可以对聚类的质量进行全面的描述和评价。



6.2 聚类原理

3、聚类准则函数

➤ 准则2：离散度准则

设 N_i 是聚类 Z_i 的样本数，聚类 Z_i 的均值向量为 $m_i = \sum_{x \in Z_i} x$ ； N 是样本总数，样本总均值向量为 $m = \frac{1}{N} \sum_{x \in Z} x = \frac{1}{N} \sum_{i=1}^C N_i m_i$ ，则

- ① 聚类 Z_i 的离散度矩阵定义为： $S_i = \sum_{x \in Z_i} (x - m_i)(x - m_i)^T$
- ② 总的类内离散度矩阵定义为： $S_w = \sum_{i=1}^C S_i$
- ③ 类间离散度矩阵定义为： $S_b = \sum_{i=1}^C (m - m_i)(m - m_i)^T$
- ④ 全部样本的总离散度矩阵定义为： $S_t = S_w + S_b = \sum_{x \in Z_i} (x_i - m)(m_i - m)^T$

对于给定样本集，类内散度减小，将导致类间散度增加。对某一聚类结果，类内散度越小越好，类间散度越大越好。



6.2 聚类原理

3、聚类准则函数

➤ 准则2：离散度准则

现定义如下聚类准则：

① 离散度矩阵迹准则

$$J_1 = tr(S_w^{-1}S_b) \quad J_2 = tr(S_w^{-1}S_t) \quad tr \text{表示矩阵的迹，即矩阵对角线元素之和}$$

② 离散度矩阵行列式准则

$$J_3 = |S_w^{-1}S_b| \quad J_4 = |S_w^{-1}S_t| \quad |\cdot| \text{表示行列式。}$$

以上准则同时考虑了类内散度和类间散度。为了得到好的聚类结果，它们的取值越大越好。



6.2 聚类原理

4、聚类方法

➤ 基于划分的聚类方法

基于划分的聚类方法是一种**自顶向下的方法**，对于给定的由 N 个样本数据组成的数据集 Z ，将该数据集划分为 C 个分区，其中每个分区代表一个簇。

给定要构建的分区数 C ，首先创建一个**初始划分**，然后采用**迭代重定位**技术，通过把对象从一个组移动到另一个组来改进划分。一个**好的划分准则**是：同一个簇中的相关对象尽可能相互“接近”或相关，而不同簇中的对象尽可能地“远离”或不同。

最经典的基于划分的聚类方法：**K-均值聚类**。指定聚类中心，再通过迭代的方式更新聚类中心，由于每个点都被指派到距离最近的聚类中心，所以导致其**不能检测非球面类别的数据分布**。



6.2 聚类原理

4、聚类方法

➤ 基于层次的聚类方法

对给定的数据进行层次分解，直到满足某种条件为止。根据层次分解的顺序可分为凝聚和分裂的方法。

- ① **自下而上的聚合法**：将样本集中所有数据点当成初始聚类，共有 N 个聚类，第一步将相似性最强的两个类别合并，得到 $N-1$ 个聚类，以此类推直到所有数据点被分为预期的聚类数目。
- ② **自上而下的分解法**：顺序刚好相反，生成法从树的顶端开始进行聚类，首先将整个数据集看成一类，递归地进行划分，直至所有数据点都被分在了不同聚类中。



6.2 聚类原理

4、聚类方法

➤ 基于密度的聚类方法

基于距离的聚类算法只能发现球状簇，不适用于具有任意形状的簇。基于密度的聚类方法从数据对象分布区域的密度着手，**核心思想是寻找被低密度区域分离的高密度区域**。通过连接密度较大的区域，形成不同形状的簇，可消除孤立点和噪声对聚类的影响，**发现任意形状的簇**。

聚类中心周围都是密度比其低的点，同时这些点距离该聚类中心的距离相比于其他聚类中心来说是最近的。




6.2 聚类原理

4、聚类方法

➤ 基于密度的聚类方法

决策图：局部密度为横轴，距离为纵轴



点1和点10为类簇中心（具有高局部密度和相对较高距离）。



6.2 聚类原理

4、聚类方法

➤ 基于密度的聚类方法

算法优点：

- ① 该聚类算法可以得到非球形的聚类结果，可以很好地描述数据分布；
- ② 算法复杂度上比一般的K-means算法的复杂度低。
- ③ 算法只考虑点与点之间的距离，不需要将点映射到一个向量空间中。

算法缺点：需要事先计算好所有点与点之间的距离。如果样本太大，则整个距离矩阵的内存开销特别大。




6.2 聚类原理

4、聚类方法

基于网格


➤ 基于模型的聚类方法

首先给每个簇假定一个模型（数据对象在空间分布中的密度函数或者其他函数），然后寻找能够很好满足该模型的数据集。该聚类方法假定目标数据集是由一系列的概率分布所决定的。



基于距离的聚类结果

(将距离近的点聚集在一起)



基于模型的聚类结果

(按照特定的概率分布模型进行聚类)



6.2 聚类原理

5、小结

➤ 相似性度量

基于距离的测度：欧氏距离、马氏距离、明氏距离

基于相似性函数的测度：角度相关函数、皮尔逊相关系数

➤ 聚类准则函数

误差平方和准则： $J_e = \sum_{i=1}^C \sum_{x \in Z_i} \|x - m_i\|^2$

离散度准则：离散度矩阵迹准则、离散度矩阵行列式准则

➤ 聚类方法分类

基于划分的聚类方法（**K-均值**）、基于层次的聚类方法（**分级聚类**）

基于密度的聚类方法（**DBSCAN**）、基于模型的聚类方法



6.3 分级聚类

6.3.1 基于聚合法的分级聚类

6.3.2 算例分析

6.3.3 分级聚类小结



6.3 分级聚类

1、基于聚合法的分级聚类

分级聚类，也称为**层次聚类**（Hierarchical Clustering），是最常见的聚类分析算法。

给定 d 维特征空间中由 N 个数据点所构成的样本集 $D = \{x_1, x_2, \dots, x_N\}$,

聚类 $\Omega = \{\omega_1, \omega_2, \dots, \omega_C\}$ 将数据集划分成 C 个类别，假设类别与类别之间没有重合的数据点。

➤ 实现步骤

- ① **初始化**：首先将每个数据点都看成一类， $\Omega = \{\omega_1, \omega_2, \dots, \omega_N\}$, $\omega_i = \{x_i\}$
- ② **聚合**：计算所有**类别之间的相似性测度**，**将最相似的两个类别合并**。
- ③ **更新**：重复上述过程直至达到预期的类别个数。



6.3 分级聚类

1、基于聚合法的分级聚类

➤ 类别间相似性度量

两个类别之间的相似性测度通常采用数据点之间的欧氏距离或 L_2 范数:

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2 = \sqrt{\sum_{i=1}^d |x_i - y_i|^2}$$

(1) 最小距离法

对于类别 ω_i 和 ω_j , 最小距离法将两类别中最靠近的两个数据点作为类别的代表, 将类别之间的相似性测度定义为最靠近的这两个数据点之间的欧氏距离:

$$d(\omega_i, \omega_j) = \min\{d(\mathbf{x}, \mathbf{y}) | \mathbf{x} \in \omega_i, \mathbf{y} \in \omega_j\}$$



6.3 分级聚类

1、基于聚合法的分级聚类

➤ 类别间相似性度量

两个类别之间的相似性测度通常采用数据点之间的欧氏距离或 L_2 范数:

$$d(x, y) = ||x - y||_2 = \sqrt{\sum_{i=1}^d |x_i - y_i|^2}$$

(2) 最大距离法

对于类别 ω_i 和 ω_j , 最大距离法将两类别中相距最远的两个数据点作为类别的代表, 类间相似性测度定义为相距最远的这两个数据点之间的距离:

$$d(\omega_i, \omega_j) = \max\{d(x, y) | x \in \omega_i, y \in \omega_j\}$$



6.3 分级聚类

1、基于聚合法的分级聚类

➤ 类别相似性度量

两个类别之间的相似性测度通常采用数据点之间的欧氏距离或 L_2 范数:

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2 = \sqrt{\sum_{i=1}^d |x_i - y_i|^2}$$

(3) 均值距离法

将两个类别的均值点作为类别的代表，将均值点之间的距离作为类别相似性测度，这样的方法被称为均值距离法:

$$d(\omega_i, \omega_j) = d(\mathbf{m}_i, \mathbf{m}_j)$$

$$\text{其中 } \mathbf{m}_i = \frac{1}{N_i} \sum_{x \in \omega_i} x$$

N_i 表示类别 ω_i 中数据点的个数



6.3 分级聚类

1、基于聚合法的分级聚类

➤ 类别相似性度量

两个类别之间的相似性测度通常采用数据点之间的欧氏距离或 L_2 范数:

$$d(x, y) = ||x - y||_2 = \sqrt{\sum_{i=1}^d |x_i - y_i|^2}$$

(4) 组平均距离法

组平均距离法是将**两个类别之间所有点对距离的平均值**作为类别相似性测度。相比于最小距离法和最大距离法，组平均距离法可以有效避免类内特殊点带来的不利影响。

$$d(\omega_i, \omega_j) = \frac{\sum_{x \in \omega_i} \sum_{y \in \omega_j} d(x, y)}{N_i \cdot N_j}$$



6.3 分级聚类

1、基于聚合法的分级聚类

➤ 类别相似性度量

(5) 沃德距离法

又称最小方差法，将两个类别之间的相似性测度定义为**两个类别合并时的平方和误差（SSE）的增量**。

□ 给定一个聚类，其SSE定义为：

$$SSE_i = \sum_{x \in \omega_i} \|x - m_i\|_2^2$$

□ 当沃德距离将 ω_i 和 ω_j 合并成 ω_{ij} 时，将SSE值的变化量作为两个类别之间的相似性测度：

$$d(\omega_i, \omega_j) = SSE_{ij} - SSE_i - SSE_j$$



6.3 分级聚类

2、算例分析

假设有一无标签样本集共有5个数据点A、B、C、D、E: $A = [1 \ 3 \ 3]^T$, $B = [2 \ 0 \ 4]^T$, $C = [3 \ 2 \ 2]^T$, $D = [0 \ 2 \ 3]^T$, $E = [1 \ 2 \ 3]^T$, 现要求利用最小距离法将该样本集划分为两类。



6.3 分级聚类

2、算例分析

➤ 求解

起初每个数据点自成一类，即聚类成：

$$\omega_1 = \{A\}, \omega_2 = \{B\}, \omega_3 = \{C\}, \omega_4 = \{D\}, \omega_5 = \{E\}$$

计算类别之间的最小距离，并将类别之间的最小距离列在表中：

$d(\omega_i, \omega_j)$	$\omega_2 = \{B\}$	$\omega_3 = \{C\}$	$\omega_4 = \{D\}$	$\omega_5 = \{E\}$
$\omega_1 = \{A\}$	$\sqrt{11}$	$\sqrt{6}$	$\sqrt{2}$	1
$\omega_2 = \{B\}$		3	3	$\sqrt{6}$
$\omega_3 = \{C\}$			$\sqrt{10}$	$\sqrt{5}$
$\omega_4 = \{D\}$				1

合并 ω_1 和 ω_5



6.3 分级聚类

2、算例分析

➤ 求解

得到新的聚类结果： $\omega_1 = \{A, E\}$, $\omega_2 = \{B\}$, $\omega_3 = \{C\}$, $\omega_4 = \{D\}$,

利用最小距离法，重新计算类间最小距离。以 $d(\omega_1, \omega_2)$ 为例：

$$d(\omega_1, \omega_2) = \min\{d(A, B), d(E, B)\} = \sqrt{6}$$

同理可依次计算其他类间距离，得到新的类间最小距离：

$d(\omega_i, \omega_j)$	$\omega_2 = \{B\}$	$\omega_3 = \{C\}$	$\omega_4 = \{D\}$
$\omega_1 = \{A, E\}$	$\sqrt{6}$	$\sqrt{5}$	$\sqrt{1}$
$\omega_2 = \{B\}$		3	3
$\omega_3 = \{C\}$			$\sqrt{10}$

合并 ω_1 和 ω_4



6.3 分级聚类

2、算例分析

➤ 求解

得到新的聚类结果: $\omega_1 = \{A, E, D\}$, $\omega_2 = \{B\}$, $\omega_3 = \{C\}$

利用最小距离法, 重新计算类间最小距离。得到新的类间最小距离:

$d(\omega_i, \omega_j)$	$\omega_2 = \{B\}$	$\omega_3 = \{C\}$
$\omega_1 = \{A, E, D\}$	$\sqrt{6}$	$\sqrt{5}$
$\omega_2 = \{B\}$		3

合并 ω_1 和 ω_3

得到新的聚类结果: $\omega_1 = \{A, E, D, C\}$, $\omega_2 = \{B\}$

此时聚成两类, 聚类过程结束。



6.3 分级聚类

3、分级聚类小结

- 分级聚类最简单的聚类方法，
一遍迭代完成， $N \rightarrow C$ 。
- 原理简单易实现
一次合并掉一个聚类。
- 相似性测度采用欧氏距离
 - “靠近”和“远离”是真实意义的；
 - 采用不同距离计算方法，可能会导致结果差异。



6.4 动态聚类

6.4.1 动态聚类原理

6.4.2 K-均值聚类

6.4.3 ISODATA算法

6.4.4 小结


6.4.5 作业



6.4 动态聚类

1、动态聚类原理

基本思路：首先选择一批有代表性的样本作为**初始聚类中心**，将样本集进行初始分类；**然后根据聚类准则重新计算聚类中心**，**不断调整不合适的聚类样本**，进行重新聚类，直到满足给定的结束条件为止。（从初始的随意性划分到“最优”划分，是一个动态迭代过程）



动态聚类的基本流程图



6.4 动态聚类

2、K-均值聚类

又称“C-均值算法”，算法的基础是**误差平方和准则**。其基本思想是，通过迭代寻找 **C 个聚类的划分方案**，**使得用这 **C 个聚类的均值来表达相应各类样本时所得到的总体误差最小****。

若 **N_i 是第 **i 聚类 **ω_i 中的样本数目****， **m_i 是这些样本的均值**，即**

$$m_i = \frac{1}{N_i} \sum_{x \in \omega_i} x$$

把 **ω_i 中的各样本 **x 与均值 **m_i 间的误差平方和对所有类相加后为******

$$J_e = \sum_{i=1}^C \sum_{x \in \omega_i} \|x - m_i\|_2^2$$

J_e 是误差平方和聚类准则。



6.4 动态聚类

2、K-均值聚类

$$J_e = \sum_{i=1}^C \sum_{x \in \omega_i} \|x - m_i\|_2^2$$

- 该公式一定程度上刻画了类内样本围绕类均值向量的紧密程度， J_e **越小** 则类内样本 **相似度越高**。
- 对于不同的聚类，使 J_e 极小的聚类是误差平方和准则下的最优结果。
- 极小化 J_e 。需考察样本集所有可能的类划分，这是NP难题。因此，K-均值算法采用 **迭代优化近似求解**。



6.4 动态聚类

2、K-均值聚类

➤ **分析**，把样本 x 从 ω_k 类移入 ω_j 类对误差平方和的影响：

① 设从 ω_k 中移出 x 后的集合为 $\tilde{\omega}_k$ ，它相应的均值是 $\tilde{m}_k$

$$\tilde{m}_k = m_k + \frac{1}{N_k - 1} (m_k - x)$$

式中的 m_k 和 N_k 是 ω_k 的样本均值和样本数。

② 设 ω_j 接受 x 后的集合为 $\tilde{\omega}_j$ ，它相应的均值是 $\tilde{m}_j$

$$\tilde{m}_j = m_j + \frac{1}{N_j + 1} (x - m_j)$$

式中的 m_j 和 N_j 是 ω_j 的样本均值和样本数。



6.4 动态聚类

2、K-均值聚类

➤ **分析**，把样本 x 从 ω_k 类移入 ω_j 类对误差平方和的影响：

- ③ x 的移动只影响 ω_j 和 ω_k 两类,对其他类无任何影响,因此只需要计算这两类的新的误差平方和 $\tilde{J}_k$ 和 $\tilde{J}_j$

$$\tilde{J}_k = J_k - \frac{N_k}{N_k - 1} \|x - m_k\|_2^2 \quad \tilde{J}_j = J_j + \frac{N_j}{N_j + 1} \|x - m_j\|_2^2$$

如果

$$\frac{N_j}{N_j + 1} \|x - m_j\|_2^2 < \frac{N_k}{N_k - 1} \|x - m_k\|_2^2$$

则把样本 x 从 ω_k 移入到 ω_j 就会使总误差平方和减少。只有当 x 离 m_j 的距离比离 m_k 的距离更近时才满足上述不等式。



6.4 动态聚类

2、K-均值聚类

K-均值算法通过将样本不断重新划分，从而**调整相应聚类中心**，优化聚类结果，最终使得**误差平方和极小**。

➤ **基本流程**：假设聚成 C 类，则：

Step1：确定 C 个初始聚类，计算相应的聚类中心 $m_1, m_2, \dots, m_C$

Step2：选择一个备选样本 x ，设 x 现在在 ω_i 中

Step3：若 $N_i = 1$ ，则转2，否则继续

Step4：计算将样本 x 移入到第 j 个类别所引起的误差平方和变化

$$d_j = \begin{cases} \frac{N_j}{N_j + 1} \|x - m_j\|_2^2, & j \neq i \\ \frac{N_i}{N_i - 1} \|x - m_i\|_2^2, & j = i \end{cases}$$



6.4 动态聚类

2、K-均值聚类

Step5: 若样本 x 移动到第 k 个类别, 所产生的误差平方和变化最小, 即

$$d_k = \min d_j (j \in [1, c], k \in [1, c], k \neq i)$$

则把样本 x 从 ω_i 移到 ω_k 中

Step6: 重新计算 m_i 和 m_k 的值, 并修改 J_e

$$J_e = \sum_{i=1}^c \sum_{x \in \omega_i} \|x - m_i\|_2^2$$

Step7: 反复迭代, 直至所有样本均不能移动, J_e 不发生变化。

以上聚类算法通过**不断计算和修改聚类准则函数数值**, 会导致**计算量较大**, 为进一步优化算法可采用更为简单的计算方法。



6.4 动态聚类

2、K-均值聚类

➤ 基本流程优化版:

Step1: 任意选取 C 个样本作为初始的聚类中心 $m_1, m_2, \dots, m_C$

样本集初始化分

Step2: 遍历所有待分类的样本 x_i , 计算该样本与每个聚类中心样本的距离, 按照最小距离原则将样本划分到 C 类中的某一类;

Step3: 重新计算新分类后的聚类中心, 按照步骤2, 进行样本集重新划分;

Step4: 重复步骤3, 如果任意一个类的聚类中心都不再发生变化, 则结束, 否则转步骤2

上述算法中, 通过**计算和修改聚类中心**, **没有直接运用聚类准则函数进行分类**, 减少了运算。



6.4 动态聚类

2、K-均值聚类

➤ 关键问题1：样本集初始划分

第一步：代表点的选择

- ① **方式1：**凭经验选择代表点：从数据中找出从直观上看来是比较合适的代表点；
- ② **方式2：**将全部数据随机地分成 C 类，计算每类重心，将这些重心作为每类代表点；
- ③ **方式3：**用前 C 个样本点作为代表点。

以上选择代表点的方法都是带有**启发性的**，不同的方法得到不同的初始代表点，它将影响到聚类的结果。



6.4 动态聚类

2、K-均值聚类

➤ 关键问题1：样本集初始划分

第二步：确定代表点后进行样本集初始分类

- ① **初始划分方式1**：将其余样本点按照与代表点距离最近原则，划分到相应类中（代表点保持不变）；
- ② **初始划分方式2**：每个代表点自成一类，将样本依顺序归入与其最近的代表点那一类，并立即重新计算该类的重心以代替原来的代表点（代表点进行动态更新）。然后再计算下一个样本的归类，直至所有的样本都归到相应的类为止。

由以上各种方法获得的初始划分只能作为一个**迭代过程的初始条件**，需按**准则函数极值化的方向对初始划分进行修正**。



6.4 动态聚类

2、K-均值聚类

➤ 关键问题2：类别间相似性测度

类别间相似性测度的选择影响分类的结果。

① 欧氏距离、明氏距离、马氏距离

② 相关性测度




6.4 动态聚类

2、K-均值聚类

➤ 关键问题3：类别数的确定

- ① 方式1：根据经验人为确定类别数；
- ② 方式2：通过算法自动产生

例如： J_e -C曲线、聚类有效性评价函数



准则函数 J_e 随类别数C的变化曲线



6.4 动态聚类

2、K-均值聚类

➤ 关键问题3：类别数的确定

聚类有效性评价函数。到目前为止，已提出了多种聚类有效性标准，其共同目标是**使分类结果达到类内紧密、类间远离。**

以SD有效性函数为例，2000年提出，是基于聚类平均散布性和聚类间总体分离性的一种相对度量方法。

■ 聚类平均散布性：

$$Scat(C) = \frac{1}{C} \sum_{i=1}^C \frac{\|\sigma(\omega_i)\|}{\|\sigma(\Omega)\|}$$

$\sigma(\Omega)$ ：样本集 Ω 的方差

$\sigma(\omega_i)$ ：聚类 ω_i 的方差



6.4 动态聚类

2、K-均值聚类

➤ 关键问题3：类别数的确定

■ 聚类总体分离性：

$$Dis(C) = \frac{D_{max}}{D_{min}} \sum_{i=1}^C \left(\sum_{j=1}^C ||\mathbf{m}_i - \mathbf{m}_j|| \right)^{-1}$$

其中 D_{max} 和 D_{min} 分别表示聚类中心间的最大和最小距离：

$$D_{max} = \max(||\mathbf{m}_i - \mathbf{m}_j||) \quad D_{min} = \min(||\mathbf{m}_i - \mathbf{m}_j||)$$

■ 则SD聚类有效性函数：

$$SD(C) = aScat(C) + Dis(C)$$

具有最小SD值所对应的C即是最佳的类别数



6.4 动态聚类

2、K-均值聚类

➤ 算例分析：

已知无标签样本集：

$$\begin{aligned}x_1 &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} & x_2 &= \begin{bmatrix} 1 \\ 1 \end{bmatrix} & x_3 &= \begin{bmatrix} 1 \\ 0.5 \end{bmatrix} & x_4 &= \begin{bmatrix} 0.5 \\ 1 \end{bmatrix} & x_5 &= \begin{bmatrix} 2 \\ 0.5 \end{bmatrix} \\x_6 &= \begin{bmatrix} 6 \\ 2 \end{bmatrix} & x_7 &= \begin{bmatrix} 7 \\ 1 \end{bmatrix} & x_8 &= \begin{bmatrix} 6 \\ 1 \end{bmatrix} & x_9 &= \begin{bmatrix} 7 \\ 2 \end{bmatrix} & x_{10} &= \begin{bmatrix} 8 \\ 3 \end{bmatrix}\end{aligned}$$

试用K-均值算法将这些样本聚成两类。



6.4 动态聚类

2、K-均值聚类

➤ 算例求解:

① 初始代表点可以任意选取，在这里选

$$m_1(0) = x_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad m_2(0) = x_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

② 因为 $\|x_1 - m_1(0)\|_2 < \|x_1 - m_2(0)\|_2$ 所以 $x_1 \in \omega_1(1)$

$\|x_2 - m_1(0)\|_2 < \|x_2 - m_2(0)\|_2$ 所以 $x_2 \in \omega_2(1)$

$\|x_3 - m_1(0)\|_2 < \|x_3 - m_2(0)\|_2$ 所以 $x_3 \in \omega_2(1)$

.....

得到: $\omega_1(1) = \{x_1\}, N_1 = 1;$ $\omega_2(1) = \{x_2, x_3, \dots, x_{10}\}, N_2 = 9$

样本集初始化分



6.4 动态聚类

2、K-均值聚类

➤ 算例求解:

③ 计算新的聚类中心:

$$\mathbf{m}_1(1) = \frac{1}{N_1} \sum_{x_i \in \omega_1(1)} \mathbf{x}_i = \mathbf{x}_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\mathbf{m}_2(1) = \frac{1}{N_2} \sum_{x_i \in \omega_2(1)} \mathbf{x}_i = \frac{1}{9} (\mathbf{x}_2 + \mathbf{x}_3 + \dots + \mathbf{x}_{10}) = \begin{bmatrix} 4.28 \\ 1.33 \end{bmatrix}$$

④ 因为 $\mathbf{m}_1(1) \neq \mathbf{m}_1(0)$ $\mathbf{m}_2(1) \neq \mathbf{m}_2(0)$ 所以转到 (2)

⑤ 得到: $\omega_1(2) = \{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4, \mathbf{x}_5\}, N_1 = 5$

$\omega_2(2) = \{\mathbf{x}_6, \mathbf{x}_7, \mathbf{x}_8, \mathbf{x}_9, \mathbf{x}_{10}\}, N_2 = 5$

样本集重新划分



6.4 动态聚类

2、K-均值聚类

➤ 算例求解:

⑥ 计算新的聚类中心:

$$m_1(2) = \frac{1}{N_1} \sum_{x_i \in \omega_1(2)} x_i = \frac{1}{5} (x_1 + x_2 + x_3 + x_4 + x_5) = \begin{bmatrix} 0.9 \\ 0.6 \end{bmatrix}$$

$$m_2(2) = \frac{1}{N_2} \sum_{x_i \in \omega_2(2)} x_i = \frac{1}{5} (x_6 + x_7 + x_8 + x_9 + x_{10}) = \begin{bmatrix} 6.8 \\ 1.8 \end{bmatrix}$$

⑦ 因为 $m_1(2) \neq m_1(1)$ $m_2(2) \neq m_2(1)$ 所以转到 (2)

⑧ 求得的分类结果与前一次的结果相同, 即:

$$\omega_1(3) = \omega_1(2) \quad \omega_2(3) = \omega_2(2)$$

样本集重新划分




6.4 动态聚类

2、K-均值聚类

➤ 算例求解：

⑨ 各聚类中心也与前一次的相同, $m_1(3) = m_1(2)$ $m_2(3) = m_2(2)$

因为 $m_1(3) = m_1(2)$ $m_2(3) = m_2(2)$, 不会再出现新的类别划分, 至此分类过程结束。



K-均值聚类后的分类结果



6.4 动态聚类

2、K-均值聚类

➤ 问题分析1:

随机的初始中心选择对计算结果和迭代次数有较大的影响

改进方法: **K-Means++**

K-means++按照如下的思想选取 C 个聚类中心:

- 在选取第一个聚类中心($n = 1$)时同样通过随机的方法。
- 假设已经选取了 n 个初始聚类中心($0 < n < C$), 则在选取第 $n + 1$ 个聚类中心时: 距离当前 n 个聚类中心越远的点会有更高的概率被选为第 $n + 1$ 个聚类中心。

K-Means++初始的聚类中心之间的相互距离要尽可能的远, 可有效解决随机初始中心选择的问题。



6.4 动态聚类

2、K-均值聚类

➤ 问题分析2:

聚类数量 C 需要预先设定

通过**K-Means++**可有效解决随机初始中心选择的问题，但是对于聚类数量的预先设定，在K-Means++中也没有很好的解决。



6.4 动态聚类

3、ISODATA算法

➤ 算法思路：

Iterative **S**elf-**O**rganizing **D**ata **A**nalysis **T**echniques **A**lgorithm
(迭代自组织数据分析方法)

在K-均值算法基础上增加对聚类结果的“合并”和“分裂”：

- **聚类合并**：当两个聚类中心之间距离值小于某个阈值时，将这两个聚类合并成一个；
- **聚类分裂**：当某个聚类的样本方差（描述样本分散程度）大于一定的阈值且该聚类内样本数量超过一定阈值时，将该聚类分裂为两个聚类。

经过以上两个操作，可**有效解决聚类数量需要设定的问题**。



6.4 动态聚类

3、ISODATA算法

➤ ISODATA算法的输入：

① 预期的聚类中心数目 C ：

虽然在ISODATA运行过程中聚类中心数目是可变的，但还是需要由用户指定一个参考标准。事实上，该算法的聚类中心数目变动范围也由 C 决定。具体地，最终输出的聚类中心数目范围是 $[C/2, 2C]$ 。

② 每个类所包含的最少样本数目 $N_{\min}$ ：

用于**判断**当某个类别所包含样本分散程度较大时**是否可以分裂操作**。如果分裂后会导致某个子类别所包含样本数目小于 $N_{\min}$ ，就不会对该类别进行分裂操作。



6.4 动态聚类

3、ISODATA算法

➤ ISODATA算法的输入：

③ 最大方差Sigma：

用于**衡量某个类别中样本的分散程度**。当样本的分散程度**超过这个值**时，则有可能进行**分裂操作**（注意同时需要满足②中所述的条件）。

④ 两个类别对应的聚类中心之间所允许最小距离 $d_{\min}$ ：

如果**两个类别靠得非常近**（即这两个类别对应聚类中心之间的距离非常小），则需要对这两个类别进行**合并操作**。是否进行**合并的阈值由 $d_{\min}$ 决定**。

聚类间距离： $d_{ij} = ||m_i - m_j||_2$



6.4 动态聚类

3、ISODATA算法

➤ 算法流程：

- ① 从数据集中随机选取 C_0 个样本作为**初始聚类中心** $\{m_1, m_2, \dots, m_{C_0}\}$;
- ② 针对每个样本 x_i , 计算它到 C_0 个聚类中心的距离, 并将该样本分到与其**距离最小**的聚类中心所对应的类中;
- ③ 判断上述每个类中的样本数量是否小于 $N_{\min}$ 。如果是, 则需要删除该类, 令 $C_0 = C_0 - 1$, 并将该类中的样本重新分配到剩下与其距离最小的类中;
- ④ 针对每个类别, **重新计算它的聚类中心**;
- ⑤ 如果当前类别数 $C_0 \geq 2C$, 表明当前类别数 C_0 太多, 需进行**合并**操作;
- ⑥ 如果当前类别数 $C_0 \leq C/2$, 表明当前类别数 C_0 太少, 需进行**分裂**操作;
- ⑦ 如果达到最大迭代次数则终止, 否则回到第2步继续执行。

样本
集
初始
化分

样本
集
重新
划分



6.4 动态聚类

3、ISODATA算法

➤ 算法流程:

ISODATA-合并操作

- ① 计算当前所有类别聚类中心两两之间的距离，用矩阵 D 表示；
- ② 对于 $D(i, j) < d_{\min}(i \neq j)$ 的两个类别 ω_i 和 ω_j 进行合并操作，形成一个新的类，该类的聚类中心为：

$$\mathbf{m}_{new} = \frac{1}{N_i + N_j} (N_i \mathbf{m}_i + N_j \mathbf{m}_j)$$

N_i 和 N_j 为两个类别 ω_i 和 ω_j 中的样本个数，新的聚类中心可看作是对这两个类别进行加权求和。



6.4 动态聚类

3、ISODATA算法

➤ 算法流程：

ISODATA-分裂操作

- ① 计算每个类别下所有样本在每个维度下的方差；
- ② 从每个类别的所有维度方差中挑选出最大的方差 σ_{max} ，用于衡量该类别中样本的分散程度；
- ③ 如果某个类别的 $\sigma_{max} > \text{Sigma}$ 并且该类别中所包含的样本数量 $N_i \geq 2N_{min}$ ，则进行分裂操作，前往步骤4。如果不满足上述条件则退出分裂操作；
- ④ 将满足步骤3条件的类分裂成两个子类，并令 $C_0 = C_0 + 1$ 。



6.4 动态聚类

3、ISODATA算法

➤ 小结

该算法能够在聚类过程中根据各个类所包含样本的实际情况**动态调整聚类中心的数目**。

- a) 如果某个类中样本分散程度较大（通过方差进行衡量）并且样本数量较大（ $N_i \geq 2N_{min}$ ），则对该类进行分裂操作；
- b) 如果某两个类别靠得比较近（通过聚类中心的距离衡量， $D(i, j) < d_{min}(i \neq j)$ ），则对它们进行合并操作。



6.4 动态聚类

4、小结

➤ K-均值聚类

基本思想：设定初始聚类中心、迭代更新、直至收敛

问题分析：初始聚类中心选择问题（K-means++）、选定聚类数量问题

➤ ISODATA聚类

基本思想：在K-均值聚类基础上增加对聚类结果的“合并”和“分裂”，
可有效解决聚类数量需要设定的问题。



6.5 基于密度的聚类

6.5.1 DBSCAN算法

6.5.2 DBSCAN算法相关概念

6.5.3 DBSCAN算法基本实现流程

6.5.4 DBSCAN算法算例分析

6.5.5 DBSCAN算法小结



6.5 基于密度的聚类

1、DBSCAN算法


- DBSCAN(**D**ensity-**B**ased **S**patial **C**lustering of **A**pplications with **N**oise)是比较有代表性的基于密度的聚类算法。
- 其将簇（类）定义为密度相连的点的最大集合，能够把具有足够高密度的区域划分为簇，并可在噪声的空间数据库中发现任意形状的聚类。
- 该算法不需要确定聚类的数量，而是基于数据推测聚类的数目，能够针对任意形状产生聚类。



6.5 基于密度的聚类

2、DBSCAN算法相关概念

- **Eps邻域**：与点的距离小于等于 Eps 的所有点的集合。
- **密度值**：对每个数据点为圆心，以 Eps 为半径画个圈（称为邻域eps-neighbourhood），然后数有多少个点在这个圈内，这个数就是该点密度。





6.5 基于密度的聚类

2、DBSCAN算法相关概念


- **核心点**（或称为核心对象，**core object**）：如果一个对象在其半径 Eps 内含有超过 $MinPts$ 数目的点，则该对象为核心点。 $MinPts$ 为定义核心点时的阈值。
- **边界点**：如果一个对象在其半径 Eps 内含有点的数量小于 $MinPts$ ，但是该对象落在核心点的邻域内，则该对象为边界点。
- **噪声点**：既不是核心点也不是边界点的点。

通俗地讲，核心点对应**稠密区域**内部的点，边界点对应稠密区域边缘的点，而噪声点对应稀疏区域中的点。



6.5 基于密度的聚类

2、DBSCAN算法相关概念



假设 $MinPts = 5$, Eps 如图中箭头线所示。

点A: 在其 Eps 邻域内含有7个点, **核心点**;

点B: 在其 Eps 邻域内含有4个点, 少于 $MinPts$ 。落在了点A的 Eps 邻域内, 因此为**边界点**;

点C: 在其 Eps 邻域内含有3个点, 少于 $MinPts$ 。没有落在任何核心点邻域内, 因此为**噪声点**。



6.5 基于密度的聚类


2、DBSCAN算法相关概念

- **密度直达 (directly density-reachable)**: 假设有样本点 p, q 。其中 p 是核心点, q 在 p 的 Eps 邻域内, 则 p 密度直达 q 。
- **密度可达 (density-reachable)**: 对于对象链: $p_1, p_2 \dots p_n$, 且 $p_{(i+1)}$ 由 p_i 密度直达, 则 p_n 由 p_1 密度可达。
- **密度相连 (density-connected)**: 对于样本点 p, q , 若存在样本点 k 使得 p, q 均由 k 密度可达, 则称 p, q 密度相连。
- **密度聚类簇**: 由核心点和与其密度可达的所有对象构成一个密度聚类簇。



6.5 基于密度的聚类

2、DBSCAN算法相关概念







6.5 基于密度的聚类

2、DBSCAN算法相关概念

假设 $MinPts = 5$



(a)



(b)

- 如图(a)所示，点 A 为核心点，点 B 为边界点，则 A 密度直达 B 。
- 如图(b)所示，点 C 和 A 为核心点。 C 密度直达 A ， A 密度直达 B ，所以 C 密度可达 B 。 A 密度直达 B ， A 密度直达 C ， B 和 C 密度相连。



6.5 基于密度的聚类

2、DBSCAN算法相关概念

➤ 密度聚类簇

由密度可达关系导出的最大密度相连的样本集合，即为最终聚类的一个簇。
(由核心点和与其密度可达的所有对象构成一个密度聚类簇)

- ① 簇里面可以有一个或者多个核心点。
- ② 如果只有一个核心点，则簇里其他的非核心点样本都在这个核心点的 E_{ps} 邻域里。
- ③ 如果有多个核心点，则簇里的任意一个核心点的 E_{ps} 邻域中一定有一个其他的核心点。这些核心点的 E_{ps} 邻域里所有的样本的集合组成一个DBSCAN 聚类簇。



6.5 基于密度的聚类

3、DBSCAN算法基本实现流程

输入：数据集 Ω ，邻域半径 Eps ，阈值 $MinPts$;

输出：密度联通簇。

➤ 算法基本流程

- ① 找寻数据集中的核心点，形成核心点集合 Ω_1 ;
- ② while $\Omega_1 \neq \text{null}$:
 - a) 从 Ω_1 中任意选取核心点作为种子点，找出由该核心点密度可达的所有样本点，形成一个簇;
 - b) 将在该簇中的核心点从 Ω_1 中清除;
 - c) 再从更新后的 Ω_1 中随机选取一个核心点作为种子点，找出由该核心点密度可达的所有样本点，生成下一个簇;
 - d) 重复以上步骤，直至 Ω_1 为空。



6.5 基于密度的聚类

4、DBSCAN算法算例分析

➤ DBSCAN算法样本数据集

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \mathbf{x}_2 = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \quad \mathbf{x}_3 = \begin{bmatrix} 2 \\ 4 \end{bmatrix} \quad \mathbf{x}_4 = \begin{bmatrix} 4 \\ 3 \end{bmatrix}$$

$$\mathbf{x}_5 = \begin{bmatrix} 5 \\ 8 \end{bmatrix} \quad \mathbf{x}_6 = \begin{bmatrix} 6 \\ 7 \end{bmatrix} \quad \mathbf{x}_7 = \begin{bmatrix} 6 \\ 9 \end{bmatrix} \quad \mathbf{x}_8 = \begin{bmatrix} 7 \\ 9 \end{bmatrix}$$


$$\mathbf{x}_9 = \begin{bmatrix} 9 \\ 5 \end{bmatrix} \quad \mathbf{x}_{10} = \begin{bmatrix} 1 \\ 12 \end{bmatrix} \quad \mathbf{x}_{11} = \begin{bmatrix} 3 \\ 12 \end{bmatrix} \quad \mathbf{x}_{12} = \begin{bmatrix} 5 \\ 12 \end{bmatrix} \quad \mathbf{x}_{13} = \begin{bmatrix} 3 \\ 3 \end{bmatrix}$$

问题：利用DBSCAN进行样本聚类，取 $Eps = 3$, $MinPts = 3$ 。



6.5 基于密度的聚类

4、DBSCAN算法算例分析





6.5 基于密度的聚类

4、DBSCAN算法算例分析

➤ 核心点计算:

x_1 的Eps邻域为 $\{x_1, x_2, x_3, x_{13}\}$

x_2 的Eps邻域为 $\{x_1, x_2, x_3, x_4, x_{13}\}$

x_3 的Eps邻域为 $\{x_1, x_2, x_3, x_4, x_{13}\}$

x_4 的Eps邻域为 $\{x_3, x_4, x_{13}\}$

x_{13} 的Eps邻域为 $\{x_1, x_2, x_3, x_4, x_{13}\}$


x_5 的Eps邻域为 $\{x_5, x_6, x_7, x_8\}$

x_7 的Eps邻域为 $\{x_5, x_6, x_7, x_8\}$

x_8 的Eps邻域为 $\{x_5, x_6, x_7, x_8\}$

x_{11} 的 Eps 邻域为 $\{x_{11}, x_{10}, x_{12}\}$

建立核心点集合 $\Omega_1 = \{x_1, x_2, x_3, x_4, x_{13}, x_5, x_7, x_8, x_{11}\}$





6.5 基于密度的聚类

4、DBSCAN算法算例分析

第一步：从核心点集合 Ω_1 依顺序选取核心点，首先取 $x_1(1,2)$ 。

以 x_1 为核心点建立簇 C_1 ，即找出所有从 x_1 密度可达的点。

① x_1 Eps邻域内的点 $\{x_1, x_2, x_3, x_{13}\}$ 都是 x_1 密度直达的点，所以 $\{x_1, x_2, x_3, x_{13}\}$ 都属于 C_1 。

② 寻找 x_1 密度可达的点。

- a) 核心点 x_2 的Eps邻域为 $\{x_1, x_2, x_3, x_4, x_{13}\}$ ，因为 x_1 密度直达 x_2 ， x_2 密度直达 x_4 ，所以 x_1 密度可达 x_4 。因此 x_4 也属于 C_1 。
- b) 核心点 x_3 的Eps邻域为 $\{x_1, x_2, x_3, x_4, x_{13}\}$ ，其Eps邻域的点均已在 C_1 中
- c) 核心点 x_{13} 的Eps邻域为 $\{x_1, x_2, x_3, x_4, x_{13}\}$ ，其Eps邻域的点均已在 C_1 中。
- d) 核心点 x_4 的Eps邻域为 $\{x_3, x_4, x_{13}\}$ ，其Eps邻域内所有点均已被处理。


③ 以 x_1 为核心点出发的那些密度可达的对象全部处理完毕，得到簇 C_1 ，包含点 $\{x_1, x_2, x_3, x_{13}, x_4\}$ 。

将在簇 C_1 中的核心点从核心点集合 Ω_1 中清除，得到新的 $\Omega_1 = \{x_5, x_7, x_8, x_{11}\}$



6.5 基于密度的聚类

4、DBSCAN算法算例分析



将在簇 C_1 中的核心点从核心点集合 Ω_1 中清除，得到新的 $\Omega_1 = \{x_5, x_7, x_8, x_{11}\}$



6.5 基于密度的聚类

4、DBSCAN算法算例分析

第二步：从新的核心点集合 $\Omega_1 = \{x_5, x_7, x_8, x_{11}\}$ 中继续遍历核心点，取到 $x_5(5,8)$ 。

以 x_5 为核心点建立簇 C_2 ，即找出所有从 x_5 密度可达的点。

① 核心点 x_5 的Eps邻域为 $\{x_5, x_6, x_7, x_8\}$ 。邻域内的点都是 x_5 密度直达的点，所以 $\{x_5, x_6, x_7, x_8\}$ 都属于 C_2 。

② 寻找 x_5 密度可达的点。

a) 核心点 x_6 的Eps邻域为 $\{x_5, x_6, x_7, x_8\}$ ，Eps邻域的点均已在 C_2 中。

b) 核心点 x_7 的Eps邻域为 $\{x_5, x_6, x_7, x_8\}$ ，Eps邻域的点均已在 C_2 中。

c) 核心点 x_8 的Eps邻域为 $\{x_5, x_6, x_7, x_8\}$ ，Eps邻域的点均已在 C_2 中。


③ 以 x_5 为核心点出发的那些密度可达的对象全部处理完毕，得到簇 C_2 ，包含点 $\{x_5, x_6, x_7, x_8\}$ 。

将在簇 C_2 中的核心点从核心点集合 Ω_1 中清除，得到新的 $\Omega_1 = \{x_{11}\}$



6.5 基于密度的聚类

4、DBSCAN算法算例分析



将在簇 C_2 中的核心点从核心点集合 Ω_1 中清除，得到新的 $\Omega_1 = \{x_{11}\}$



6.5 基于密度的聚类

4、DBSCAN算法算例分析

第三步，从新的核心点集合 $\Omega_1 = \{x_{11}\}$ 中继续遍历核心点，仅有 $x_{11}(3,12)$


- ① 核心点 x_{11} 的Eps邻域为 $\{x_{11}, x_{10}, x_{12}\}$ 。
- ② x_{11} 邻域内的点都是 x_{11} 密度直达的点，所以 $\{x_{11}, x_{10}, x_{12}\}$ 都属于 C_3 。
- ③ 寻找 x_{11} 密度可达的点。没有更多的核心点，所有无密度可达的点。
- ④ 此时，以 x_{11} 为核心点出发的那些密度可达的对象全部处理完毕，得到簇 C_3 ，包含点 $\{x_{11}, x_{10}, x_{12}\}$ 。

将在簇 C_3 中的核心点从核心点集合 Ω_1 中清除，得到新的 $\Omega_1 = \text{null}$ ，至此遍历结束，得到最终聚类结果。



6.5 基于密度的聚类

4、DBSCAN算法算例分析



最终，样本聚为3类。

簇 C_1 包含点 $\{x_1, x_2, x_3, x_{13}, x_4\}$

簇 C_2 包含点 $\{x_5, x_6, x_7, x_8\}$

簇 C_3 包含点 $\{x_{11}, x_{10}, x_{12}\}$

x_9 为异常点




6.5 基于密度的聚类

4、DBSCAN算法算例分析

➤ 由聚类结果看出：

- ① 每个簇里面可以有一个或者多个核心点。
- ② 如果只有一个核心点，则簇里其他的非核心点样本都在这个核心点的Eps邻域里。
- ③ 如果有多个核心点，则簇里的任意一个核心点的Eps邻域中一定有一个其他的核心点。这些核心点的Eps邻域里所有样本的集合组成一个DBSCAN 聚类簇。





6.5 基于密度的聚类

4、DBSCAN算法小结

➤ 优点:

- ① 不用人为设定簇的个数;
- ② 可以在聚类的同时发现异常点, 对数据集中的**异常点不敏感**。
- ③ 能**发现任意形状的空间聚类**, 如能识别“非球形”的簇, 而K-均值这种基于距离的聚类方法只能找出球状的簇;
- ④ 聚类结果**几乎不依赖于遍历的顺序**, 而**K-均值聚类算法的初始值对聚类结果有很大影响**。



6.6 模糊聚类

6.6.1 问题引入

6.6.2 模糊理论

6.6.3 FCM算法



6.6 模糊聚类

1、问题引入

➤ K-均值算法

一种硬聚类算法，算法的依据是类内误差平方和最小化准则，给集合中的**每个样本赋予一个明确的类别**。但在实际应用中，有时样本在形态和类属方面存在中介性，不存在严格的属性划分。

➤ 模糊C均值算法 (Fuzzy C-Means, FCM)

为了更好的解决这类问题，**将模糊理论引入K-均值算法**（也称C-均值算法），从硬聚类推广到模糊聚类，即FCM算法。



6.6 模糊聚类

2、模糊理论

模糊控制是自动化控制领域的一项经典方法。其原理则是模糊数学、模糊逻辑。1965年美国加州大学柏克莱分校的扎德教授发表模糊集合 “Fuzzy Sets” 的论文，首次引入隶属度函数的概念，打破了经典数学 “非0即1” 的局限性，用 $[0,1]$ 之间的实数来描述中间状态。


很多经典的集合（即：论域 U 内的某个元素是否属于集合 A ，可以用一个数值来表示。在经典集合中，要么0，要么1）不能描述很多事物的属性，需要用模糊性词语来判断。比如天气冷热程度、人的胖瘦程度等等。模糊数学和模糊逻辑把只取1或0二值（属于/不属于）的普通集合概念推广到 $0\sim 1$ 区间内的多个取值，即隶属度。用 “隶属度” 来描述元素和集合之间的关系。



6.6 模糊聚类

2、模糊理论

➤ 举例



如图所示，对于冷热程度，采取三个模糊子集：冷、暖、热。对于某一个温度，可能同时属于两个子集。要进一步具体判断，就需要提供一个描述“程度”的函数，即隶属度。



6.6 模糊聚类

2、模糊理论

➤ 传统集合论思维方式

- a) 一个元素或者**属于**某个集合，或者**不属于**该集合；
- b) 二值逻辑

➤ 模糊集合论思维方式

- a) 一个元素以一定的程度属于某个集合，也可以同时以不同的程度属于多个集合；
- b) 模糊集合



6.6 模糊聚类

2、模糊理论


➤ 隶属度函数

表示一个对象 x 隶属于集合 A 的程度，记作 $\mu_A(x)$ ，取值范围是 $[0,1]$

a) $\mu_A(x) = 1$ ，表示 x 完全属于 A ，相当于 $x \in A$

b) $\mu_A(x) = 0$ ，表示 x 完全不属于 A ，相当于 $x \notin A$

常见的隶属度函数：





6.6 模糊聚类

2、模糊理论

➤ 模糊集

对于有限个对象 $\{x_1, x_2, \dots, x_n\}$, 模糊集合A为: $A = \{(\mu_A(x_i), x_i)\}$

➤ 常见的模糊集运算

并: 模糊集A和B的并集 $C = A \cup B$ 的隶属度函数定义为:

$$\mu_C(x) = \max\{(\mu_A(x), \mu_B(x))\}$$

交: 模糊集A和B的交集 $C = A \cap B$ 的隶属度函数定义为:

$$\mu_C(x) = \min\{(\mu_A(x), \mu_B(x))\}$$

有时也把交集的隶属度函数定义为

$$\mu_C(x) = \mu_A(x) \cdot \mu_B(x)$$

补: 模糊集A和补集 $C = A'$ 的隶属度函数定义为:

$$\mu_C(x) = 1 - \mu_A(x)$$



6.6 模糊聚类

3、FCM算法

- FCM（模糊C-均值）聚类融合了模糊理论的精髓。相较于K-均值的硬聚类，FCM提供了更加灵活的聚类结果。
- FCM通过为每个对象和每个簇赋予一个权值，指明对象属于该簇的程度。基于概率的方法也可以给出这样的权值，但是有时候很难确定一个合适的统计模型，因此使用非概率特性的FCM是一个比较好的选择。



6.6 模糊聚类

3、FCM算法

给定数据集 $X = \{x_1, x_2, \dots, x_N\}$, 聚类分析任务是形成 X 的 C 类划分。对于数据集 X 的 C 个子集 $X_1, X_2, \dots, X_C$ 。如果满足公式, 则称为 **X 的硬 C 划分**:

$$\begin{cases} X_1 \cup X_2 \cup \dots \cup X_C = X \\ X_i \cap X_k = \emptyset, 1 \leq i \neq k \leq C \\ X_i \neq \emptyset, X_i \neq X, 1 \leq i \leq C \end{cases}$$

隶属函数 $\mu_{ik} = \mu_{X_i}(x_k)$: 表示样本 x_k 与子集 X_i 的隶属关系。

硬划分中 μ_{ik} 为子集 X_i 的特征函数, 则有 $\mu_{ik} \in \{0, 1\}$ 。



6.6 模糊聚类

3、FCM算法

数据集 X 的硬 C 划分也可以用隶属函数表示，即用 C 个子集的特征函数值构成矩阵 $U = [\mu_{ik}]_{C \times N}$ 来表示。矩阵 U 中的第 i 行为第 i 个子集的特征函数，而矩阵 U 中第 k 列为样本 x_k 相对于 C 个子集的隶属函数。

此时，数据集 X 的硬 C 划分空间为：

$$M_{hc} = \{U = R^{CN} | \mu_{ik} \in \{0,1\}, \forall i, k; \sum_{i=1}^C \mu_{ik} = 1, \forall k; 0 < \sum_{k=1}^N \mu_{ik} < N, \forall i\}$$



6.6 模糊聚类

3、FCM算法

数据集X的模糊划分：利用模糊集理论将隶属函数 μ_{ik} 从 $\{0,1\}$ 二值扩展到 $[0,1]$ 区间，从而将硬C划分概念推广到模糊C划分。因此数据集X的模糊C划分空间为：

$$M_{hc} = \{U = R^{CN} | \mu_{ik} \in [0,1], \forall i, k; \sum_{i=1}^C \mu_{ik} = 1, \forall k; 0 < \sum_{k=1}^N \mu_{ik} < N, \forall i\}$$



6.6 模糊聚类

3、FCM算法

➤ FCM算法原理

$\{x_i, i = 1, 2, \dots, N\}$ 是有 N 个样本的集合, C 为预定的类别数目;

$m_j (j = 1, 2, \dots, C)$ 为每个聚类的中心, $\mu_j(x_i)$ 是第 i 个样本对于第 j 类的隶属度函数。

则基于隶属度函数定义的聚类损失函数为:

$$J_f = \sum_{j=1}^C \sum_{i=1}^N [\mu_j(x_i)]^b \|x_i - m_j\|^2$$

其中, $b > 1$ 为加权指数, 又称为平滑因子, 控制模式在模糊类间的分享程度, 多数情况取为2。



6.6 模糊聚类

3、FCM算法

$$J_f = \sum_{j=1}^C \sum_{i=1}^N [\mu_j(\mathbf{x}_i)]^b \|\mathbf{x}_i - \mathbf{m}_j\|^2$$

$$\sum_{j=1}^C \mu_j(\mathbf{x}_i) = 1, \quad \forall i = 1, 2, \dots, n$$

FCM算法的数学模型其实是一个条件极值问题：利用拉格朗日乘数法把条件极值转化为无条件极值问题：

a) 需要引入 N 个拉格朗日因子，如下所示：

$$\min J_f' = \sum_{j=1}^C \sum_{i=1}^N [\mu_j(\mathbf{x}_i)]^b \|\mathbf{x}_i - \mathbf{m}_j\|^2 + \sum_{i=1}^N \lambda^i \left(\sum_{j=1}^C [\mu_j(\mathbf{x}_i)]^b - 1 \right)$$

b) 对各个变量 ($\mathbf{m}_j$ 和 $\mu_j(\mathbf{x}_i)$) 进行求导，得到各个变量的极值点。



6.6 模糊聚类

3、FCM算法

$$\mathbf{m}_j = \frac{\sum_{i=1}^N [\mu_j(\mathbf{x}_i)]^b \mathbf{x}_i}{\sum_{i=1}^N [\mu_j(\mathbf{x}_i)]^b}, j = 1, 2, \dots, C$$

$$\mu_j(\mathbf{x}_i) = \frac{\left(\frac{1}{\|\mathbf{x}_i - \mathbf{m}_i\|^2}\right)^{\frac{1}{b-1}}}{\sum_{k=1}^C \left(\frac{1}{\|\mathbf{x}_i - \mathbf{m}_k\|^2}\right)^{\frac{1}{b-1}}}, \quad i = 1, 2, \dots, N; j = 1, 2, \dots, C$$

采用迭代方法求解如上两公式，直至满足收敛条件，得到最优解。



6.6 模糊聚类

3、FCM算法

c) 迭代的终止条件:

$$\max\{|\mu_j(x_i)^{(k+1)} - \mu_j(x_i)^{(k)}|\} < \delta$$

其中: k 为迭代步数, δ 为误差阈值

继续迭代下去, 隶属程度也不会发生较大的变化。即认为隶属度不变了, 已经达到比较优 (局部最优或全局最优) 状态了。该过程收敛于目标 J_f 的局部最小值或鞍点。



6.6 模糊聚类

3、FCM算法

➤ 算法步骤

FCM算法的基本思路是给每个样本赋予属于每个簇的隶属度函数，通过隶属度值大小来将样本归类，具体步骤归纳如下：

Step1: 设定聚类数目 C 和参数 b ;

Step2: 初始化各个聚类中心 m_i ;


Step3: 重复下面的运算，直到各个样本的隶属度值稳定：

- ① 用当前的聚类中心计算隶属度函数;
- ② 用当前的隶属度函数更新各类聚类中心。

当算法收敛时，即可根据各类的聚类中心和各个样本对于各类的隶属度值完成模糊聚类划分。

$$\mu_j(x_i) = \frac{\left(1/\|x_i - \mathbf{m}_j\|_2^2\right)^{1/(b-1)}}{\sum_{k=1}^C \left(1/\|x_i - \mathbf{m}_k\|_2^2\right)^{1/(b-1)}}$$

$$\mathbf{m}_j = \frac{\sum_{i=1}^N [\mu_j(x_i)]^b x_i}{\sum_{i=1}^N [\mu_j(x_i)]^b}$$





作业

1、针对分级聚类算例，假设有一无标签样本集共有5个数据点A、B、C、D、E：
 $A = [1 \ 3 \ 3]^T$, $B = [2 \ 0 \ 4]^T$, $C = [3 \ 2 \ 2]^T$, $D = [0 \ 2 \ 3]^T$, $E = [1 \ 2 \ 3]^T$ ，现要求利用最大距离法、均值距离法将该样本集划分为两类。

2、有以下样本

$$x_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad x_2 = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad x_3 = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \quad x_4 = \begin{bmatrix} 2 \\ 2 \end{bmatrix} \quad x_5 = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$$

$$x_6 = \begin{bmatrix} 7 \\ 1 \end{bmatrix} \quad x_7 = \begin{bmatrix} 8 \\ 1 \end{bmatrix} \quad x_8 = \begin{bmatrix} 7 \\ 2 \end{bmatrix} \quad x_9 = \begin{bmatrix} 8 \\ 3 \end{bmatrix} \quad x_{10} = \begin{bmatrix} 8 \\ 0 \end{bmatrix}$$

试用K-均值算法将这些样本聚成两类。



北京航空航天大学
BEIHANG UNIVERSITY

德才兼备 知行合一

The end