



北京航空航天大学
BEIHANG UNIVERSITY

模式识别

第八章 卷积神经网络

北京航空航天大学宇航学院



主要内容

8.1 卷积神经网络基本结构

8.2 卷积神经网络的特性

8.3 卷积网络的目标函数

8.4 卷积网络的训练

8.5 经典的卷积神经网络

8.6 卷积网络的一般设计方法



8.1 卷积神经网络基本结构

8.1.1 卷积层

8.1.2 激活函数层

8.1.3 池化层

8.1.4 全连接层


8.1.5 搭建一个简单的卷积网络



8.1 卷积神经网络基本结构

卷积神经网络 (convolutional neural networks, CNNs) 是一种深度前馈型人工神经网络，可以实现数据的端到端处理，在图像视觉领域发挥了巨大的潜力。卷积神经网络是当下深度学习领域的基本模型。

一个卷积神经网络通常包括若干个**卷积层**、**激活函数**、**池化层**、**全连接层**。输入信号通常是多通道的二维图像数据，输出是分类或拟合结果。




卷积神经网络的基本组成



8.1 卷积神经网络基本结构

1、卷积层

卷积层 (convolution layer) 是卷积神经网络的核心模块，其通过权值共享的卷积核以滑动窗口的方式提取二维数据中的局部特征。这个二维数据，通常是图像。



卷积神经网络的基本组成



8.1 卷积神经网络基本结构

1、卷积层

(1) 卷积操作

➤ 单通道（二维）卷积操作

设输入图像数据为 I ，卷积核为 K ，卷积核大小为 $M * N$ ，则对任意一点 (i, j) ，卷积结果为

$$S_{i,j} = (I * K)(i, j) = \sum_{m=1}^M \sum_{n=1}^N I(i + m, j + n) K(m, n)$$

1	0	1
0	1	0
1	0	1

卷积核

1	2	3	4	5
6	7	8	9	0
9	8	7	6	5
4	3	2	1	0
1	2	3	4	5

输入数据



27	28	29
28	27	16
23	22	21

卷积结果（特征）



8.1 卷积神经网络基本结构

1、卷积层

(1) 卷积操作

➤ 数据填充

- 卷积核尺寸一般大于 1×1 ，导致卷积输出数据尺寸小于输入数据。解决的办法就是对数据进行填充操作（padding），也叫补全操作。
- 常用的填充方法包括：**0填充、重复填充、常数填充**

1	0	1
0	1	0
1	0	1

卷积核

0	0	0	0	0	0	0
0	1	2	3	4	5	0
0	6	7	8	9	0	0
0	9	8	7	6	5	0
0	4	3	2	1	0	0
0	1	2	3	4	5	0
0	0	0	0	0	0	0

输入数据



8	16	19	12	14
16	27	28	29	10
19	28	27	16	15
14	23	22	21	10
4	8	7	6	6

卷积结果（特征）



8.1 卷积神经网络基本结构


1、卷积层

(1) 卷积操作

➤ 三维卷积操作

如果有 c 个通道，则 i, j 位置的卷积输出为

$$y_{i,j} = \sum_{r=1}^c \sum_{k=1}^h \sum_{l=1}^w f_{r,k,l} \times x_{i+k,j+l}$$



三维场景卷积操作
大小: 3*4*3

卷积特征



8.1 卷积神经网络基本结构

1、卷积层

(2) 卷积核的偏置


- 卷积核对于输入图像的卷积，相当于神经元对信号的加工。
- 与人工神经元数学模型相同，每个卷积核对应了一个偏置参数 b 。偏置是对神经元激活状态的控制，当神经元的信号大于偏置时被激活，小于阈值时被抑制。

用 $I * K$ 表示卷积核 K 对输入图像 I 的卷积，卷积核对应偏置为 b ，则卷积操作、偏置与人工神经元数学模型的对应关系如下图所示

卷积网络

人工神经元模型

$$y = f\left(\frac{(I * K) + b}{\sum_{i=1}^n w_i x_i + b}\right)$$



人工神经元模型示意图



8.1 卷积神经网络基本结构

1、卷积层

(3) 卷积的作用

卷积的作用就是提取特征，可获得图像或数据的局部信息。随着网络加深，可以学得图像的边缘、颜色、形状、纹理等众多基本模式，并逐渐被抽象为具有高层语义的“概念”表示，最后对应到具体的样本类别。

卷积核

0	-4	0
-4	16	-4
0	-4	0

-1	-2	-1
0	0	0
1	2	1

-1	0	1
-2	0	2
-1	0	1



整体边缘滤波



横向边缘滤波



纵向边缘滤波



8.1 卷积神经网络基本结构


1、卷积层

(4) 卷积层及参数

卷积层包含若干个尺寸相等的卷积核，卷积核的通道数等于前一层输入的通道数。每个卷积核对输入数据进行卷积得到一个特征图（feature map）

D个卷积核可以得到D个特征图，特征图的大小通常用 $H*W*D$ 表示。

例如，下图中卷积核的通道数等于4，6个卷积核得到了6个特征图，0填充，步长为1，则输出特征图大小为 $64*64*6$ 。





8.1 卷积神经网络基本结构

1、卷积层

(4) 卷积层及参数

输入：大小为 $W_1 * H_1 * D_1$ ，其中 $W_1 * H_1$ 为输入特征图尺寸， D_1 为通道数

卷积核：一共 k 个卷积核，大小为 $F * F$ ，移动步长 S ，边界扩充尺寸为 P

输出：大小为 $W_2 * H_2 * D_2$ ，其中 $W_2 * H_2$ 为输入特征图尺寸， D_2 为通道数

$$W_2 = \frac{W_1 - F + 2P}{S} + 1 \quad H_2 = \frac{H_1 - F + 2P}{S} + 1 \quad D_2 = k$$

每个卷积核还对应一个偏置参数，因此该卷积层参数总量为： $(F \times F \times D_1) \times k + k$




8.1 卷积神经网络基本结构

2、激活函数

卷积层的运算是线性的，线性运算的堆叠仍然是线性的。如果网络只有卷积层，那么不管其规模如何庞大，最终都只能实现线性映射。

激活函数（activative fuction）的作用是去线性化，用来实现网络的非线性表达，增强网络的映射能力。



卷积神经网络的基本组成




8.1 卷积神经网络基本结构

2、激活函数

(1) 神经网络的梯度消失问题

- 卷积神经网络**利用反向传播算法实现参数更新**，其原理是根据复合函数求导的链式法则实现梯度的传播。
- **梯度从网络末端传递到前端**，**经历激活函数导数和各层网络参数的连乘**。网络越深，传递链路越长，如果激活函数的导数小于1，则经过层层传递，梯度会急剧下降，直到梯度消失。

例如：下图是一个多层神经网络，假设 w_i 和 b_i 是神经元 i 的连接权值和偏置，激活函数为 σ ， y 是输出，则目标函数为 C 对 b_1 的导数为：

$$\frac{\partial C}{\partial b_1} = \frac{\partial C}{\partial y} \sigma'(z_4) w_4 \sigma'(z_3) w_3 \sigma'(z_2) w_2 \sigma'(z_1)$$





8.1 卷积神经网络基本结构

2、激活函数

(2) 激活函数的一般要求

一般要求激活函数具有

- 非线性
- 良好的可导性
- 计算简单
- 非饱和性
- 单调性
- 合理的输出范围





8.1 卷积神经网络基本结构

2、激活函数


(3) 常用的激活函数

- **ReLU函数**：是分段函数， $x \geq 0$ 时消除了梯度饱和和效应，有助于梯度下降法收敛，成为当前卷积网络的首选。但 $x < 0$ 时梯度为0，出现“死区”。


$$\text{ReLU}(x) = \max\{0, x\} = \begin{cases} x & x \geq 0 \\ 0 & x < 0 \end{cases}$$

- **Leaky ReLU**：引入超参数 α ，作为一个网络中可学习的变量融入模型的整体训练过程，解决“死区”问题。


$$\text{Leaky ReLU}(x) = \begin{cases} x & x \geq 0 \\ \alpha x & x < 0 \end{cases}$$




ReLU函数



ReLU梯度



Leaky ReLU函数



Leaky ReLU梯度



8.1 卷积神经网络基本结构


2、激活函数

(3) 常用的激活函数

➤ Swish激活函数

- 一种自门控 (Self-Gated) 激活函数
- 能够替换以单个标量作为输入的激活函数 (如 ReLU), 而无需改变参数数量。
- 该激活函数在深层模型上的效果一般会优于 ReLU

$$f(x) = x \cdot \text{sigmoid}(\beta x) = x \cdot \frac{1}{1 + e^{-\beta x}}$$






8.1 卷积神经网络基本结构

3、池化层

- 池化层（pooling layer）的作用是对卷积层中提取的特征进行挑选。使模型更关注是否存在某些特征而不是特征的具体位置。
- 是降采样过程，可以提高后续特征的感受野，并减少计算量。
- 池化层一般没有模型参数，反向传播过程中不需要进行权值优化。



卷积神经网络的基本组成




8.1 卷积神经网络基本结构

3、池化层


(1) 池化层的计算

常见的池化操作有最大池化和平均池化。池化层是由矩阵窗口滑动来进行计算的，求窗口中的最大值和平均值等。

如图，最大池化和平均池化的计算示例，其中滤波核的大小为 2×2 ，步长为2



最大池化



平均池化



8.1 卷积神经网络基本结构

3、池化层

(2) 池化层的特征图尺寸

输入：大小为 $W_1 * H_1 * D_1$ ，其中 $W_1 * H_1$ 为输入特征图尺寸， D_1 为通道数

池化核参数：尺寸 $F * F$ ，移动步长 S

输出：大小为 $W_2 * H_2 * D_2$ ，其中 $W_2 * H_2$ 为输出特征图尺寸， D_2 为通道数

$$W_2 = \frac{W_1 - F}{S} + 1$$

$$H_2 = \frac{H_1 - F}{S} + 1$$


$$D_2 = D_1$$



8.1 卷积神经网络基本结构

4、全连接层

全连接层每一个结点都与上一层的所有结点相连，用来把前边提取到的特征综合起来。






8.1 卷积神经网络基本结构

4、全连接层

- 全连接层起到“分类器”的作用。
- 卷积层、池化层和激活函数层等操作是将原始数据映射到隐层特征空间，是特征提取的过程。
- 全连接层则将学到的特征表示映射到样本的标记空间。






8.1 卷积神经网络基本结构

5、搭建一个简单的卷积网络

以云识别卷积网络为例，遥感图像中经常会出现云，对遥感图像中的云区进行检测和识别，对于气象预报、生态环境监测、气象灾害的预防等方面都有积极的作用。






8.1 卷积神经网络基本结构

5、搭建一个简单的卷积网络

下图是一个遥感图像中云区域识别的网络，包括4个卷积层和2个全连接层，卷积层之间插入了激活函数层（ReLU）和池化层（ Pooling ）

- 输入图像块大小为 $55 \times 55 \times 3$ ，输出为该图像块是云和非云的概率。
- 卷积核尺寸为 3×3 ，步长为1
- 池化层的核尺寸为2，步长也为2






8.1 卷积神经网络基本结构

5、搭建一个简单的卷积网络

表中给出了每一层的参数个数，例如卷积层1中，由于输入是3通道的，因此卷积核的通道数为3，该层有48个卷积核，每个卷积核对应一个偏置，则该层参数为 $(3*3*3)*48+48=1344$ ，其他层可以做类似的分析

层	参数个数
Conv1	$(3*3*3)*48+48=1344$
Conv2	$(3*3*48)*64+64=27712$
Conv3	$(3*3*64)*128+128=73856$
Conv4	$(3*3*128)*256+256=295168$
FC1	$(6*6*256)*128=1179684$
FC2	$128*2=256$





8.2 卷积神经网络的特性

8.2.1 权值共享

8.2.2 感受野

8.2.3 深度特征的层次性


8.2.4 深度特征的分布式表示




8.2 卷积神经网络的特性

1、卷积层权值共享

一个卷积核计算出一个特征图，计算过程中参数不变，这就是卷积网络中的权值共享



卷积神经网络的基本组成






8.2 卷积神经网络的特性

1、卷积层权值共享

权值共享的作用在于，**每个特征具有平移不变性**，同一个特征可以出现在不同数据的不同位置，可以用同一个卷积核来提取这一特征。同时，通过权值共享，**减少了卷积层的参数**。

层	参数个数
Conv1	$(3*3*3)*48+48=1344$
Conv2	$(3*3*48)*64+64=27712$
Conv3	$(3*3*64)*128+128=73856$
Conv4	$(3*3*128)*256+256=295168$
FC1	$(6*6*256)*128=1179684$
FC2	$128*2=256$






8.2 卷积神经网络的特性

2、感受野

在卷积操作中，后层的一个神经元对应前层一个区域的大小，就是**感受野**。

例如：后层的卷积核为 7×7 ，则后层的每个神经元对应的感受野大小为 7×7 ，因为它可以接收到前层中 7×7 大小的区域作为输入，并通过卷积操作得到相应的输出。






8.2 卷积神经网络的特性

2、感受野

- 小卷积核可以通过多层叠加取得与大卷积核同等规模的感受野。
- 小卷积核加深了网络深度进而增大了网络容量，并能减少参数个数。





3×3 的卷积核经过3次叠加可以达到 7×7 卷积核相同的感受野，且参数减少了近1/2



8.2 卷积神经网络的特性

3、深度特征的层次性

一个卷积网络具有多个卷积层，前端对应低层特征，后端对应高层特征。低层特征一般对应边缘、纹理等细节。越到高层，一个特征点对应前端的感受野越大，越能抽象出物体的轮廓和整体，也就对应高层语义特征。






8.2 卷积神经网络的特性

3、深度特征的层次性

例如


AlexNet网络包含5层卷积。2014年，Zeiler利用反卷积技术对该网络特征进行可视化，来验证深度特征的层次性。





8.2 卷积神经网络的特性


3、深度特征的层次性



Layer 1



第一层对应边缘和方向（细节信息）




第二层对应纹理特征



8.2 卷积神经网络的特性

3、深度特征的层次性




第三层开始出现一些高层语义模式，如车轮、文字和人脸形状的模式



8.2 卷积神经网络的特性

3、深度特征的层次性

第四层和第五层，则更具分辨能力的模式被卷积网络所捕获






8.2 卷积神经网络的特性

4、深度特征的分布式表示

- 分布式表示是指语义概念到神经元的一种多对多映射。
- 每个语义概念由许多分布在不同神经元中被激活的模式表示（见下图横向），而每个神经元又可以参与到许多不同语义概念的表示中去（见下图纵向）。




在ImageNet数据集上训练了一个网络，最后一层pooling层的响应张量是 $7*7*512$ ，选取其中4张与两张鸟的原图叠加，得到有高亮部分的可视化结果。




8.3 卷积神经网络的目标函数

损失函数 (loss)

- 也叫目标函数，网络模型的指挥棒，通过样本的预测结果与真实标记之间产生的误差反向传播，指导网络学习，获得模型参数。
- 网络任务不同，损失函数的设计也不同，已有很多多种loss。如用于分类任务的有交叉熵loss、合页loss、中心损失函数、大间隔交叉熵loss等；用于回归任务的有 $l1$ loss、 $l2$ loss等。



分类任务举例



回归任务举例



8.3 卷积神经网络的目标函数


1、用于分类任务的目标函数

(1) 交叉熵损失函数


交叉熵是信息论中的概念，主要用于度量两个概率分布之间的差异性。**交叉熵损失函数**又称**Softmax损失函数**，其将预测值和实际值之间的差异转换为样本分类概率分布的距离，其数学表达式为：

$$\text{CrossEntropy} = -\frac{1}{m} \sum_{i=1}^m \sum_{j=1}^n y_{ij} \log(\hat{y}_{ij})$$

- m 是样本数， n 是分类数（网络输出层神经元数量）
- $\hat{y}_{ij}$ 是第 i 个样本网络输出的第 j 个分量
- y_{ij} 是第 i 个样本真实标签的第 j 个分量



输入一颗卫星图像





8.3 卷积神经网络的目标函数


1、用于分类任务的目标函数

(2) 合页损失函数


合页损失函数既可以用于分类任务，也可以用于回归任务。它是一种平滑的损失函数，可以有效减少模型训练中误差的幅度，其数学表达式为：

$$\text{HingeLoss} = \frac{1}{m} \sum_{i=1}^m \max(0, 1 - y_i \cdot \hat{y}_i)$$

m 是样本数
 y_i 是真实标签向量
 $\hat{y}_i$ 是网络预测向量



输入一颗卫星图像






8.3 卷积神经网络的目标函数

2、用于回归任务的目标函数

(1) 均方误差 (MSE) 损失函数

MSE (Mean Squared Error) 是最常见的回归问题损失函数。它将每个样本的预测值与实际值之间的差值平方求和，再除以样本数量，得到一个均方误差。MSE损失函数对异常值比较敏感，其数学表达式为：

$$\text{MSE} = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$





8.3 卷积神经网络的目标函数

2、用于回归任务的目标函数

(2) L1损失函数

L1损失函数的定义为：


$$L1 = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|$$

(3) SmoothL1损失函数

SmoothL1（平滑L1）损失函数的定义为：

$$\text{SmoothL1} = \begin{cases} 0.5x^2, & |x| < 1 \\ |x| - 0.5, & |x| \geq 1 \end{cases}$$

x 是网络预测值与真值之间的差异





8.4 卷积神经网络的训练

8.4.1 数据集处理

8.4.2 网络训练


8.4.3 从头训练和迁移学习




8.4 卷积神经网络的训练

1、数据集处理

- 数据在深度学习中占据着非常重要的地位，一个高质量的数据集往往能够提高模型训练的质量和预测的准确率。
- 已有许多开源数据，比如ImageNet数据集和COCO数据集，当公开数据不能满足要求时，需要制作面向特殊应用的数据集。



COCO数据集



天基卫星目标数据集




8.4 卷积神经网络的训练


1、数据集处理

(1) 数据集清洗

在数据集中去除掉不符合要求或者错误的数据，保留有效的数据，包括**去除重复数据、去除缺失数据、去除异常值等**



COCO数据集



天基卫星目标数据集



8.4 卷积神经网络的训练

1、数据集处理

(2) 数据预处理

向卷积网络模型输入数据时，需要进行数据**标准化处理**，得到均值为0、标准差为1的服从标准正态分布的数据，移除共同部分，凸显个体差异。

例如，均值方差标准化 $x^* = \frac{x - \mu}{\sigma}$ ，其中， μ 为样本均值， σ 是样本标准差

(3) 数据增广

深度网络参数量大，需要大样本数据库进行训练。当**训练样本不足**时，可采用**随机裁剪、旋转、翻转、缩放、噪声**等方式进行扩充，扩充后数据量可达原有数据量的几十倍。



原图



水平反转



随机抠取



8.4 卷积神经网络的训练

2、网络训练

(1) 超参数设置

- **学习率**：学习率控制着权重更新的速度，过小会导致训练速度慢，过大会导致模型不稳定
- **批大小**：在深度学习中，批处理是一种训练数据的处理方式，它将一组样本一起输入到神经网络中进行前向传播和反向传播，以进行参数更新
- **正则化系数**：正则化可以帮助减少过拟合，通常采用L1、L2正则化。正则化系数越大，对权重的惩罚也就越大，从而对网络的权重参数起到约束作用
- **迭代次数**：在训练神经网络时，通常设置一个迭代次数，当迭代次数达到设定值时，训练就停止。迭代次数过小会导致模型欠拟合，迭代次数过大会导致模型过拟合。



8.4 卷积神经网络的训练

2、网络训练

(2) 参数初始化

➤ 随机初始化

- 将网络参数随机初始化为**一组小的随机数**，实际应用中，随机参数服从高斯分布或均匀分布

例如：假设网络某一层输入神经元个数 n_{in} ，输出神经元个数为 n_{out} ，则服从高斯分布的参数随机初始化为

$$w = 0.001 .* \text{randn}(n_{in}, n_{out});$$

其中0.001为控制参数量纲的因子，可使得参数期望能保持在接近0的较小数值范围内。

- 通常**适用于较浅的网络**，如只有一层或两层的网络。
- 随机初始化**可以打破对称性**，使网络参数具有不同的初始值，从而更好地探索参数空间。



8.4 卷积神经网络的训练

2、网络训练

(2) 参数初始化

➤ Xavier初始化

针对一个层，网络输出数据分布的方差会随着输入神经元个数而改变，为解决这一问题，会在初始化的同时加上对方差大小的规范化，有更快的收敛速率。适合于卷积层参数的初始化。

$$w \sim N\left(0, G \frac{2}{\text{in} + \text{out}}\right)$$

in表示前一层的输入维度，out表示当前层的输出维度，G用户指定的增益。



8.4 卷积神经网络的训练

2、网络训练

(3) 网络优化算法

- 优化算法给出了如何根据损失函数的梯度迭代、更新网络参数，使目标函数逼近最优。
- 有多种经典的优化方法，如批量梯度下降法、随机梯度下降法、动量优化算法、AdaGrad法、Adadelat法、RMSProp法、Adam法等。
- 以批量梯度下降法为例，批量梯度下降法使用所有样本计算梯度，表达式为

$$w^{(t)} = w^{(t-1)} - \eta \frac{1}{m} \sum_{i=1}^m \frac{\partial L(w, x_i)}{\partial w^{(t-1)}}$$

其中， $L(w, x_i)$ 为目标函数， m 为数据集样本总数， w 为各层参数， x_i 为第 i 个样本， η 为学习率。



8.4 卷积神经网络的训练

2、网络训练


(4) 网络正则化

➤ 针对损失函数进行的操作，防止参数过大而导致的过拟合，包括 l_1 正则化、 l_2 正则化、随机失活 (dropout) 等

➤ l_1 正则化和 l_2 正则化是两个常用的正则化方式，假设待正则化的网络层参数为 w_i ($0 < i \leq n$,

是网络的所有参数)，它们的定义为： $l_1 = \sum_{i=1}^n |w_i|$ $l_2 = \frac{1}{2} \sum_{i=1}^n w_i^2$

实际训练中参数更新用： $\text{loss} + \lambda l_2$ ，其中 λ 控制正则项的大小，较大的取值将较大幅度地约束模型的复杂度。






8.4 卷积神经网络的训练

2、网络训练

(5) 批规范化 (Batch Normalization, BN)

- 卷积网络在训练时，内部各隐层的输入数据和输出数据存在分布差异，并且随着网络深度增大而越来越大，它破坏了独立同分布假设。
- 批规范化操作是对网络中某一结点的输出进行处理，使数据接近均值为0、方差为1的正态分布，从而缓解训练中的梯度消失和爆炸现象，加快模型的训练速度。





8.4 卷积神经网络的训练

2、网络训练

(5) 批规范化 (Batch Normalization, BN)

➤ 批规范化操作是针对卷积层后的特征图进行的操作，例如，并行输入100张图，得到100个参数调整的结果，然后对应位置进行减均值除方差。**批规范化步骤如下：**

S1: 计算批处理数据均值 μ

S2: 计算批处理数据方差 σ

S3: 规范化。减均值除方差， $\hat{x}_i = \frac{x_i - \mu}{\sqrt{\sigma^2 + \epsilon}}$

S4: 尺度变换和偏移。 $y_i = \alpha \hat{x}_i + \beta$ ，两个参数通过学习得来，能再学习一个分布




8.4 卷积神经网络的训练

3、从头训练和迁移学习

(1) 从头训练

卷积网络需要大样本量数据进行训练，当我们有足够的训练样本时，可以采用从头学习方式训练，即从头训练网络模型，从0开始学习。



层	参数个数
Conv1	$(3*3*3)*48+48=1344$
Conv2	$(3*3*48)*64+64=27712$
Conv3	$(3*3*64)*128+128=73856$
Conv4	$(3*3*128)*256+256=295168$
FC1	$(6*6*256)*128=1179684$
FC2	$128*2=256$

一个很小的网络也有很大的参数量




8.4 卷积神经网络的训练

3、从头训练和迁移学习

(2) 迁移学习

- 当训练样本不足时，可以采用迁移学习的方式。
- 迁移学习是把已训练好的模型参数迁移到新的模型来帮助新模型训练。通过迁移学习可将已学到的模型参数通过某种方式分享给新模型，从而加快并优化模型的学习效率。

例如，采用残差网络进行卫星或飞机目标分类，可以用原来在ImageNet上的参数做初始值，然后用卫星或飞机样本继续训练网络，解决卫星或飞机样本不足问题。



- 两个不同的领域共享的因素越多，迁移学习就越容易，否则就越困难，甚至出现“负迁移”，产生副作用。
- 据研究，数据集样本足够时，从头学习和迁移学习差别不大。



8.5 经典的卷积神经网络

8.5.1 LeNet

8.5.2 AlexNet

8.5.3 VGGNet

8.5.4 GoogLeNet

8.5.5 ResNet



8.5.6 Unet



8.5 经典的卷积神经网络

1、LeNet

- Yann LeCun在1998年设计的用于手写数字识别的卷积神经网络，是早期卷积神经网络中最有代表性的实验系统之一。
- LeNet采用的结构、部件至今仍被广泛使用。可以说，LeNet就是学习卷积神经网络的“Hello World”，是学习其他网络结构的基础。






8.5 经典的卷积神经网络

1、LeNet

LeNet-5的结构，网络共有7层（不包含输入层），包含了卷积层、池化层、全连接层等卷积神经网络的基本模块。输入图像大小为32*32*1，输出为对应10个类别（数字0-9）的概率



层	类型	输出尺寸	参数量
输入层	输入	32×32×1	0
卷积层1	卷积	28×28×6	$(5\times5\times1+1)\times6$
池化层1	池化	14×14×6	$(1+1)\times6$
卷积层2	卷积	10×10×16	$(5\times5\times3+1)\times6$ $(5\times5\times4+1)\times(6+3)$ $(5\times5\times6+1)\times1$
池化层2	池化	5×5×16	$(1+1)\times16$
卷积层3	卷积	1×1×120	$(5\times5\times16+1)\times120$
全连接层1	全连接	1×1×84	$(120+1)\times84$
输出层	输出	1×1×10	84×10




8.5 经典的卷积神经网络

2、ALexNet

是Hinton和他的学生Alex Krizhevsky设计的，在2012年ImageNet竞赛目标识别任务上获得冠军，远超第二名十个百分点。那年之后，更多更深的神经网络被提出。

- 有8层，卷积核 11×11 ，采用双GPU实现
- 用ReLU作为激活函数，解决了Sigmoid在网络较深时的梯度弥散问题
- 引入Dropout方法，解决过拟合







8.5 经典的卷积神经网络

3、VGGNet

- 牛津大学Visual Geometry Group提出，2014年ImageNet竞赛定位任务第一名和分类任务的第二名。
- VGG可看成是AlexNet的加深版，都是卷积层+全连接层
- 在当时是非常深的网络（高达十多层），其论文名字“**Very Deep Convolutional Networks for Large-Scale Visual Recognition**”，当然现在看VGG真的称不上是very deep网络。



- VGGNet使用多层小卷积核替代较大的卷积核。VGGNet用 3×3 的卷积核，代替了AlexNet中的大卷积核（ 5×5 、 11×11 ），节省了工作量，加深了网络深度，增加了网络特征提取能力。
- 可堆叠的块状网络结构。VGGNet多次重复使用统一尺寸的卷积核，这种通过重复使用简单的基础模块来构建深度网络的思想，在VGGNet之后被广泛使用。




8.5 经典的卷积神经网络

4、GoogLeNet


GoogLeNet是由谷歌团队提出的，在2014的ImageNet分类任务上夺得冠军。GoogLeNet引入一种网中网结构（Inception）代替了单纯的卷积+激活的传统操作，网络达到了22层。

GoogLeNet结构




Inception 是一种 **网中网** (Network In Network) 的结构，即原来的结点也是一个网络。

Inception v1模块



Inception v2模块






8.5 经典的卷积神经网络

5、ResNet

- 传统的卷积网络在信息传递的时候会存在信息丢失，同时还会导致梯度消失或者梯度爆炸，从而很深的网络无法训练。
- 何凯明2015年提出ResNet，直接将输入信息绕道传到输出，**整个网络只需要学习输入、输出差别的那部分，简化学习目标和难度。**可达上百层。




一个34层的残差网络




8.5 经典的卷积神经网络

5、ResNet




常规网络单元




残差网络单元

常规网络单元与残差网络单元对比



常规残差模块



瓶颈残差模块

ResNet两种残差模块



-
- 输入图像
- 输出分割图像
- 1 64 64
 512×512 512×512 512×512
 128 128
 256² 256² 256²
 256 256
 128² 128² 128²
 512 512
 64 64
 32 32 32
 1024 1024
 64 64 64
 512 512
 128² 128² 128²
 256 256
 512 256
 256² 256² 256²
 128 128
 512×512 512×512 512×512 512×512
 128 64 64 3
- 3×3 卷积, ReLU
 → 拼接
 ↓ 2×2 最大池化
 ↑ 2×2 上采样
 → 1×1 卷积



8.6 卷积网络的一般设计方法

8.6.1 一般的设计思路

8.6.2 卷积网络设计举例





8.6 卷积网络的一般设计方法

1、一般的设计思路

(1) 网络深度

- **参考一些经典的网络：**例如AlexNet、VGG等，LeNet包含7层、AlexNet包含8层、VGG十多层、ResNet达到上百层，小卷积核替代大卷积核，增加网络深度
- **设计一种或几种卷积模块（block）：**由几种不同的操作组合而成，例如卷积、激活、批量归一化（Batch Normalization, BN）等。如：LeNet、VGG没有模块，GoogLeNet、ResNet开始有了模块






8.6 卷积网络的一般设计方法

1、一般的设计思路


(2) 多尺度

多尺度输入网络：是使用多个尺度的图像输入（图像金字塔），然后将其结果进行融合

多尺度特征融合：在网络处理阶段，计算不同尺度下的特征图，最后提取到的特征融合以便进行下游任务。



Inception模块包括四个并行的分支，提取多尺度特征



多尺度的思路



8.6 卷积网络的一般设计方法

1、一般的设计思路

(3) 注意力机制




注意力集中到熊猫的身上，而忽略背景。

空间域：空间注意力机制将图像中的空间域信息作对应的空间变换并自动获取重要区域特征，从而能将关键的信息提取出来。

通道域：通道注意力机制将全局空间信息压缩至一系列通道描述符中，然后在通道维度进行特征学习，形成各个通道重要性，最后对各个通道分配不同权重。

混合域：将空间和通道相结合的注意力机制






8.6 卷积网络的一般设计方法

2、卷积网络设计举例

多光谱遥感图像容易受到雾的干扰，造成图像清晰度下降，地物信息损失。对多光谱遥感图像进行去雾，可以提高多光谱遥感图像的质量，为后续解译任务的有效进行提供保障。



带有雾干扰的遥感图像




8.6 卷积网络的一般设计方法

2、卷积网络设计举例

(1) 多光谱遥感图像去雾网络框架

对于输入图像，先进行特征升维，然后采用残差结构进行特征提取和高维空间去雾，最后通过特征降维，输出去雾以后的结果。






8.6 卷积网络的一般设计方法

2、卷积网络设计举例

(2) 网络结构的设计

网络的第一层为卷积层，卷积核大小为 3×3 ，滤波器个数为16，用于实现图像数据的高维映射，使得后续的权重层可以在高维空间学习。






8.6 卷积网络的一般设计方法

2、卷积网络设计举例

(2) 网络结构的设计

网络中间层为一个残差块结构，由两个多尺度卷积层、一个特征融合层和一个残差相减层组成。






8.6 卷积网络的一般设计方法

2、卷积网络设计举例

(2) 网络结构的设计

多尺度卷积层用于提取雾的多尺度特征。每个多尺度卷积层是由3个不同尺度的卷积的并联构成，卷积核大小分别为 $\{1 \times 1, 3 \times 3, 5 \times 5\}$ 。每种尺度的卷积产生16张特征图，共输出64张特征图。







8.6 卷积网络的一般设计方法

2、卷积网络设计举例

(2) 网络结构的设计

特征融合层用于不同尺度的信息整合。在不同尺度的特征图之间进行逐元素取平均，经过特征融合层后，特征图个数由64降为16，与升维后输入图像的维度一致。**特征融合层的输出结果表征了雾成分。**



特征融合层结构




8.6 卷积网络的一般设计方法

2、卷积网络设计举例

(2) 网络结构的设计

残差相减层将融合后的特征图从升维后的输入图像中减去，可看作是**高维空间的去雾操作**。






8.6 卷积网络的一般设计方法

2、卷积网络设计举例

(2) 网络结构的设计

网络的**最后一层**同样为卷积层，卷积核大小为 3×3 ，用于**将特征图映射到原始图像维度**，实现特征降维并输出恢复后的清晰图像。





8.6 卷积网络的一般设计方法

2、卷积网络设计举例

(3) 损失函数设计

卷积神经网络被用来解决回归问题，网络采用欧氏距离作为损失函数：

$$L = \frac{1}{2N} \sum_{n=1}^N \|\hat{g}_n - g_n\|^2$$

其中， N 为图像个数， $\hat{g}_n$ 为网络的实际输出结果， g_n 为真值图像。



8.6 卷积网络的一般设计方法


2、卷积网络设计举例

(4) 数据集

Landsat 8 OLI卫星传感器采集的多光谱遥感图像

波段	波长/ μm
波段1 (海岸波段)	0.433~0.453
波段2 (蓝波段)	0.450~0.515
波段3 (绿波段)	0.525~0.600
波段4 (红波段)	0.630~0.680
波段5 (近红外波段)	0.845~0.885
波段6 (短波红外波段I)	1.560~1.660
波段7 (短波红外波段II)	2.100~2.300
波段8 (全色波段)	0.500~0.680
波段9 (卷云波段)	1.360~1.390

容易受到雾的影响






8.6 卷积网络的一般设计方法

2、卷积网络设计举例

(4) 数据集



Landsat 8 OLI卫星传感器采集的多光谱遥感图像各波段示例



8.6 卷积网络的一般设计方法

2、卷积网络设计举例

(5) 训练设置


参数设置	具体操作
网络优化算法	小批量梯度下降法
学习率及衰减	初始为 $1e-7$ ，在损失函数值达到稳定时减小为原来的一半
批规范化	10
图像预处理	归一化到 $[0,1]$ 之间
模型初始化	卷积核参数均采用均值为0、方差为0.01的高斯函数进行初始化
损失函数	欧式距离
网络正则化	正则化衰减项为0.0001。



8.6 卷积网络的一般设计方法

2、卷积网络设计举例

(6) 去雾结果展示






作业

- 1、假设输入数据是 $27 \times 27 \times 4$ ，卷积核是 3×3 ，步长为1，且采用0填充，卷积核个数是8，请计算该卷积层上的参数总量。
- 2、输入数据为 $24 \times 24 \times 6$ ，池化核尺寸为 2×2 ，步长为2，请计算输出特征图的大小。



作业

3、假设有卫星目标图像，共20个类别，每个类别有足够的图像数据，图像大小为 55×55 ，请设计一个简单的卷积网络，对卫星目标进行分类。要求画出网络具体结构、给出每层参数（卷积、池化、激活函数等）、所采用的loss函数等关键环节，且要求不能与本章所讲的云检测和去雾网络相同。





北京航空航天大学
BEIHANG UNIVERSITY

德才兼备 知行合一

The end